



UNIVERSITÀ DEGLI STUDI GUGLIELMO MARCONI

DIPARTIMENTO DI SCIENZE INGEGNERISTICHE

**CORSO DI LAUREA MAGISTRALE IN
INGEGNERIA INFORMATICA**

*Career Compass AI: un sistema di orientamento
professionale basato su LLM e tassonomie ufficiali, con
approccio Human-Centered e fairness-aware*

Relatore

Prof. Ernesto William De Luca

Candidato:

Alessandro Baragona
Matricola 0045669

Indice

Capitolo 1: Introduzione

- 1.1 Contesto e motivazioni
- 1.2 Obiettivi della Tesi
- 1.3. Contributo Scientifico e Tecnologico

Capitolo 2: Stato dell'Arte

- 2.1 Sistemi di Orientamento Professionale Tradizionali e Digitali
- 2.2 Intelligenza Artificiale nell'HR Tech e nell'Orientamento
- 2.3. Large Language Models (LLM) per Comprensione e Generazione Testuale
- 2.4 Tecniche di Prompt Engineering per LLM
- 2.5 Fairness Algoritmica nell'HR Tech e nello User Modeling

Capitolo 3: Progettazione del Sistema

- 3.1 Architettura Generale del Sistema
- 3.2 Fonti di Dati Utilizzate
- 3.3 Modulo di Profilazione Utente basato su LLM e recupero Professioni
- 3.4 Modulo di Ranking Finale basato su LLM
- 3.5 Modulo di Identificazione Professioni Affini

Capitolo 4: Implementazione

- 4.1 Ambiente di Sviluppo e Tecnologie
 - 4.1.1 Librerie Chiave
 - 4.1.2 Ambiente di sviluppo
 - 4.1.3 Riflessione metodologica
- 4.2 Struttura del Codice e Funzioni Chiave
 - 4.2.1 Funzione principale
 - 4.2.2 Funzioni della pipeline di analisi
 - 4.2.3 Funzioni per il meccanismo di fallbackk
 - 4.2.4 Aspetti trasversali
- 4.3 LangSmith: Osservabilità e Valutazione dei Sistemi LLM
 - 4.3.1 Introduzione allo strumento
 - 4.3.2 Integrazione di LangSmith nel prototipo Career Compass AI

Capitolo 5: Discussione e prospettive future

5.1 Valutazione oggettiva del prototipo: punti di forza e limitazioni

5.2 Considerazioni etiche e bias

5.2.1 Il quadro normativo europeo e le sue implicazioni etiche

5.2.2 Il quadro accademico della fairness

5.3 Miglioramenti e sviluppi futuri

5.3.1 Miglioramenti funzionali e metodologici

5.3.2 Sviluppi futuri ispirati al quadro accademico

Capitolo 6: Conclusioni

6.1 Sintesi del Lavoro Svolto

6.2 Riflessioni Finali

Alle mie nonne, con gratitudine e affetto.

Indice Sigle

ATS: Applicant Tracking Systems

CACGS: Computer-Assisted Career Guidance Systems

CoT: Chain-of-Thought

EII: Eudaimonic Interaction Inventory

GNN: Graph Neural Networks

GPT: Generative Pre-trained Transformer

ICT: Information and Communication Technology

INAPP: Istituto Nazionale per l'Analisi delle Politiche Pubbliche

ISTAT: Istituto Nazionale di Statistica

JSON: JavaScript Object Notation

LLaMA: Large Language Model Meta AI

LLM: Large Language Models

MAE: Mean Absolute Error

MRR: Mean Reciprocal Rank

NEET: Not in Education, Employment, or Training

NER: Named Entity Recognition

NLP: Natural Language Processing

NLTK: Natural Language Toolkit

PaLM: Pathways Language Model

PoS: Part-of-Speech (Tagging)

Q&A: Question & Answering

RAG: Retrieval-Augmented Generation

SBJ: Informazioni di base

SDK: Software Development Kit

SEJ: Background educativo

SIGI: System of Interactive Guidance and Information

SKJ: competenze e specializzazioni

SSJ: auto-valutazione

SWJ: Esperienze lavorative

CAPITOLO 1: Introduzione

1.1 Contesto e Motivazioni

L'orientamento professionale rappresenta, per molti, un passaggio decisivo della vita, da cui dipende non solo il percorso individuale ma anche, in senso più ampio, lo sviluppo sociale ed economico di una comunità. Scegliere un mestiere o una carriera non significa soltanto valutare le proprie competenze tecniche: entrano in gioco anche interessi personali, aspirazioni, aspettative e, non da ultimi, i cosiddetti vincoli di contesto. Con questa espressione facciamo riferimento a tutti quei fattori esterni che sfuggono al controllo diretto del singolo e che possono incidere in maniera rilevante sulle opportunità concrete di lavoro. Rientrano in questa categoria, ad esempio, la posizione geografica, la situazione economica generale, il tessuto sociale di riferimento o ancora le condizioni istituzionali e politiche. Si tratta quindi di elementi che, a seconda dei casi, possono aprire nuove possibilità oppure costituire un ostacolo alla realizzazione dei propri progetti professionali. Essi comprendono condizioni geografiche, economiche, sociali e istituzionali che possono facilitare oppure limitare l'accesso a determinate opportunità lavorative.

In altre parole, anche un individuo preparato e motivato può trovarsi a dover adattare i propri obiettivi a causa della scarsità di offerte nel territorio in cui vive, di una congiuntura economica sfavorevole o di aspettative familiari e culturali che orientano le sue decisioni.

Tale complessità ha reso evidente, negli ultimi due decenni, la difficoltà di scegliere un cammino coerente con le proprie caratteristiche individuali. La fluidità del mercato del lavoro, caratterizzato da innovazioni tecnologiche e trasformazioni organizzative costanti, accentua ulteriormente questa difficoltà: professioni consolidate possono rapidamente diventare obsolete, mentre nuove figure emergono con competenze richieste ancora poco definite.

In questo quadro, gli strumenti tradizionali di orientamento, basati su test attitudinali standardizzati e su modelli teorici statici, appaiono spesso

inadeguati. Essi rischiano di proporre un adattamento superficiale tra individuo e lavoro, senza tenere conto della dimensione dinamica delle competenze e delle inclinazioni personali. Come evidenziato da Leung, i primi sistemi di orientamento informatizzato (CACGS) hanno cercato di rispondere a tali limiti informatizzando i questionari e mettendo in relazione i risultati con banche dati professionali, ma si sono rivelati poco efficaci nel cogliere la complessità del processo decisionale. Secondo la sua analisi, la debolezza intrinseca di questi strumenti consiste nell'incapacità di integrare le dimensioni narrative e contestuali del soggetto, privilegiando invece approcci statici e riduttivi che trascurano la natura evolutiva delle identità professionali.

Il dibattito accademico degli ultimi anni ha messo in evidenza come le tecnologie possano giocare un ruolo fondamentale nel superare questi limiti. I Computer-Assisted Career Guidance Systems (CACGS), descritti da Leung, rappresentano un primo passo in questa direzione: sistemi digitali che hanno permesso di informatizzare questionari sugli interessi e collegarli a banche dati di professioni.

Sebbene tali strumenti abbiano migliorato l'accessibilità alle informazioni, non sono stati in grado di rispondere appieno alla necessità di personalizzazione e flessibilità. Come osserva Leung, la debolezza principale di questi sistemi risiede nella loro incapacità di adattarsi dinamicamente ai bisogni dell'utente, limitandosi a incrociare risposte a test con schede standardizzate di professioni. In altre parole, mancava una capacità di interpretazione semantica e contestuale, che oggi solo l'intelligenza artificiale è in grado di offrire.

È proprio in questo passaggio che si innesta la motivazione principale di questo lavoro: la possibilità di progettare strumenti di orientamento che vadano oltre la semplice erogazione di informazioni, diventando sistemi di supporto attivo alle decisioni, in grado di integrare profili personali, dati ufficiali e tecniche di analisi automatica. Non si tratta soltanto di migliorare l'efficienza del processo, ma di favorire decisioni che rispecchino al meglio le propensioni degli individui e che siano verificabili attraverso un controllo

umano. Infatti, l'uso di sistemi intelligenti nell'orientamento deve essere sempre concepito come una forma di collaborazione uomo–macchina, in cui il sistema propone e l'utente (o un esperto del settore) valida.

Un altro elemento cruciale riguarda la dimensione del benessere personale. Jörs e De Luca sottolineano che la tecnologia, ormai compagna quotidiana della vita umana, non dovrebbe essere valutata soltanto in termini di funzionalità o di performance, ma anche in relazione alla sua capacità di promuovere esperienze eudaimoniche. Con questo termine, ripreso dalla tradizione aristotelica, si intende la possibilità per l'individuo di realizzare il proprio potenziale, coltivare virtù autentiche e vivere in modo pieno e significativo. Gli autori sostengono che le interazioni digitali possano contribuire a questa fioritura umana, a condizione che vengano progettate per stimolare autenticità, senso di significato e crescita personale.

Per rendere operativa tale prospettiva, Jörs e De Luca hanno sviluppato l'Eudaimonic Interaction Inventory (EII), un modello di misurazione che permette di valutare fino a che punto una tecnologia supporti l'utente nel perseguire obiettivi di autorealizzazione e nel rafforzare la propria identità. Applicato al contesto dell'orientamento professionale, ciò implica che un sistema digitale non dovrebbe limitarsi a proporre occupazioni compatibili con le competenze, ma dovrebbe anche favorire scelte capaci di alimentare soddisfazione, continuità e senso di identità.

Un orientamento che trascuri la dimensione eudaimonica rischia, al contrario, di ridursi a un processo meccanico, utile forse a collocare rapidamente le persone nel mercato, ma privo della capacità di sostenerle nella costruzione di percorsi di crescita coerenti e duraturi. È proprio la prospettiva eudaimonica a ricordarci che l'obiettivo ultimo non è solo l'efficienza del matching tra individuo e professione, bensì la promozione di un benessere integrale, in cui la scelta di carriera diventa parte di un progetto di vita.

Applicato al contesto dell'orientamento, ciò significa che un sistema digitale dovrebbe promuovere scelte lavorative che non solo siano adeguate sul piano delle competenze, ma che contribuiscano anche alla soddisfazione personale

e al senso di identità dell'utente. Un orientamento che non consideri questi aspetti rischia infatti di produrre frustrazione e instabilità, invece di consolidare percorsi di crescita coerenti e sostenibili.

Accanto a queste potenzialità, però, si collocano i rischi. L'uso dell'AI nei sistemi decisionali non è mai neutrale, e porta con sé il pericolo che si riproducano bias algoritmici. Con questa espressione si intende la tendenza dei sistemi di apprendimento automatico a ereditare e amplificare distorsioni presenti nei dati di addestramento. L'ambito delle risorse umane è stato spesso citato come esempio critico: vi sono casi documentati in cui strumenti di screening automatizzato dei CV hanno discriminato candidati appartenenti a minoranze di genere o etniche, penalizzandoli rispetto a profili equivalenti. Questi fenomeni sollevano interrogativi fondamentali sulla legittimità dell'uso dell'AI in processi che incidono direttamente sulla vita delle persone.

La letteratura scientifica affronta da tempo questo tema. Purificato, Boratto e De Luca (2024) sottolineano che gran parte delle metriche di fairness adottate finora sono concepite per scenari binari (es. assunto/non assunto). Tale pratica, sebbene diffusa, risulta problematica poiché riduce attributi nativamente multiclassi - come l'età o perfino il genere - a categorie dicotomiche artificiali. Questa semplificazione, come mostrano gli autori, può portare a valutazioni fuorvianti, nascondendo situazioni in cui un sottogruppo realmente svantaggiato appare invece favorito nel quadro binario.

Per superare tali limiti, l'articolo propone l'estensione di quattro metriche classiche - statistical parity, equal opportunity, overall accuracy equality e treatment equality - a contesti multigruppo e successivamente multiclasse. Questa generalizzazione consente di misurare la fairness in maniera più fine, rilevando discriminazioni che rimarrebbero invisibili in un'analisi binaria. Ad esempio, nei loro esperimenti, gruppi che apparivano equi in aggregato risultavano invece svantaggiati se osservati con metriche multigruppo: in certi casi, addirittura, interventi correttivi basati su valutazioni binarie avrebbero aggravato le disuguaglianze.

Il contributo metodologico di Purificato et al. mostra dunque come una valutazione eticamente responsabile richieda di andare oltre la logica del “due gruppi” e di considerare la reale distribuzione delle categorie sensibili. Solo così è possibile garantire che sistemi di AI applicati all’orientamento professionale non perpetuino discriminazioni nascoste, ma offrano invece un supporto equo e trasparente.

In questa direzione, Stuart Russell (2019) richiama l’attenzione sui limiti strutturali dell’attuale modello di ricerca in intelligenza artificiale, sottolineandone i rischi intrinseci. Secondo l’autore, definire il successo dei sistemi intelligenti esclusivamente come la capacità di raggiungere obiettivi fissati dall’uomo porta con sé una pericolosa rigidità: gli algoritmi, infatti, possono perseguire il compito assegnato in modo cieco, senza considerare valori, conseguenze non previste o contesti mutati. Per questo, Russell propone di ripensare la progettazione dell’AI in termini di allineamento agli interessi e ai valori umani, suggerendo che i sistemi debbano operare con un grado di incertezza sugli obiettivi stessi, così da mantenere aperta la possibilità di correzione e controllo da parte delle persone.

«The standard model of AI research, in which the primary definition of success is getting better and better at achieving rigid human-specified goals, is fundamentally flawed and potentially dangerous.»¹

Un’analisi più fine, capace di tenere conto della varietà dei gruppi sociali e delle loro interazioni, si rivela indispensabile per garantire equità e trasparenza nei risultati. Applicato al contesto dell’orientamento, ciò significa che sistemi basati su AI devono essere progettati con strumenti di monitoraggio che rilevino e correggano possibili discriminazioni, pena la perdita di affidabilità e credibilità dell’intero processo.

¹ S. Russell, *Human Compatible: Artificial Intelligence and the Problem of Control*, Penguin, 2019

È in questo quadro che si inserisce il concetto di Responsible AI, trattato da Virginia Dignum. Secondo l'autrice, l'intelligenza artificiale deve essere costruita seguendo principi che garantiscano trasparenza, responsabilità e rispetto dei valori umani. Non basta che un algoritmo sia accurato dal punto di vista tecnico; esso deve anche essere giusto e comprensibile. La Responsible AI si fonda sull'idea che la progettazione dei sistemi debba considerare le conseguenze etiche e sociali delle decisioni prodotte, integrando meccanismi di spiegabilità e consentendo all'utente di comprendere le logiche alla base dei suggerimenti ricevuti. Questo approccio è particolarmente rilevante nei sistemi di orientamento, dove l'obiettivo non è semplicemente fornire un elenco di professioni, ma accompagnare l'individuo in una scelta significativa per la sua vita.

In letteratura, diversi studiosi hanno sottolineato la necessità di una tale prospettiva. Stuart Russell (2019) ha insistito sul fatto che lo sviluppo dell'AI deve essere compatibile con i valori umani, richiamando il rischio che sistemi non adeguatamente controllati possano prendere decisioni dannose o contrarie agli interessi degli individui. Ben Shneiderman (2022) ha posto invece l'accento sul paradigma della Human-Centered AI, sostenendo che ogni tecnologia deve restare "controllabile dall'umano" e deve rafforzare, non sostituire, la capacità decisionale delle persone.

«The goal is not to replace people but to empower them by making design choices that give humans control over technology.»²

Infine, Timnit Gebru (2021) ha portato un contributo fondamentale nell'analisi dei rischi di discriminazione, evidenziando come dataset distorti e processi di addestramento poco trasparenti possano produrre risultati ingiusti, soprattutto in contesti sensibili come il reclutamento e l'orientamento professionale.

² B. Shneiderman, *Human-Centered AI*, Oxford University Press, 2022

«We propose that every dataset be accompanied with a datasheet that documents its motivation, composition, collection process, recommended uses, and so on, ... Datasheets for datasets will facilitate better communication between dataset creators and dataset consumers, and encourage the machine learning community to prioritize transparency and accountability.»³

In sintesi, il contesto odierno pone una duplice sfida: da un lato, sviluppare strumenti più potenti e personalizzati per aiutare gli individui a scegliere percorsi coerenti con le proprie capacità; dall'altro, garantire che tali strumenti rispettino i principi della Responsible AI, minimizzando i rischi di bias e promuovendo trasparenza e benessere. È da questa duplice motivazione che nasce la presente tesi: non basta che un algoritmo sia tecnicamente accurato: deve essere anche comprensibile e giusto, così da guadagnare la fiducia di chi lo utilizza. Tale prospettiva risulta particolarmente rilevante nel contesto di questa ricerca, che mira a sviluppare un prototipo di sistema di orientamento professionale basato su Large Language Models e fonti ufficiali come ISTAT e INAPP. Integrare i principi della Responsible AI significa, in questo caso, garantire che il modello non solo produca suggerimenti coerenti con le competenze e le inclinazioni dell'utente, ma che lo faccia in modo trasparente, verificabile e rispettoso delle diversità sociali [1,2,3,4,5,6,7].

1.2 Obiettivi della Tesi

Gli obiettivi di questa tesi si radicano nella convinzione che l'orientamento professionale debba trasformarsi da semplice erogazione di informazioni a vero e proprio strumento di supporto alle decisioni.

Non si tratta di costruire un prototipo fine a sé stesso, ma di delineare un modello di intelligenza artificiale che sia capace di guidare le persone in un momento cruciale della loro vita, traducendo desideri, aspirazioni e

³ T. Gebru et al., Datasheets for Datasets, arXiv preprint arXiv:1803.09010, 2021

competenze in possibilità concrete e verificabili. L'idea centrale è che un sistema di orientamento, per essere davvero utile, debba unire la potenza interpretativa dei Large Language Models (LLM) con la solidità delle classificazioni ufficiali e con la trasparenza di un'interfaccia che permetta a chiunque di comprenderne i meccanismi.

La scelta di affidarsi ai LLM nasce dalla loro capacità di interpretare testi scritti in linguaggio naturale, senza la necessità che l'utente adotti terminologie tecniche o formule prestabilite. Nella vita reale, infatti, le persone non descrivono i propri profili attraverso codici o categorie, ma raccontano sé stesse: parlano delle loro esperienze di studio, di un lavoro svolto in passato, delle attività che li appassionano o delle aspirazioni che nutrono per il futuro. Un sistema che voglia davvero essere inclusivo deve partire da questa ricchezza narrativa, capace di rivelare più di quanto non facciano i test attitudinali standardizzati. L'obiettivo è allora quello di creare un ponte: raccogliere espressioni libere, spesso frammentarie, e ricondurle a un linguaggio comune, riconosciuto e validato a livello istituzionale.

Per questa ragione, la tassonomia ISTAT delle professioni a cinque cifre rappresenta il fulcro metodologico del progetto. Essa garantisce la possibilità di collocare ogni suggerimento in un quadro chiaro e standardizzato, permettendo non solo di associare a ciascun profilo un insieme coerente di professioni, ma anche di garantire che le raccomandazioni siano comparabili, misurabili e verificabili. L'adozione di una classificazione ufficiale consente inoltre di superare uno dei limiti più ricorrenti negli strumenti digitali di orientamento: la mancanza di ancoraggio a sistemi di riferimento riconosciuti. Un suggerimento che non possa essere tradotto in un codice professionale rischia infatti di restare vago e inutilizzabile, mentre l'uso della tassonomia ISTAT permette di inserire ogni esito in un contesto istituzionale stabile.

Accanto a questo, l'integrazione con altre fonti di dati costituisce un obiettivo altrettanto rilevante. L'uso di strutture JSON locali, dedicate a conoscenze, abilità, attitudini e attività, consente di arricchire la comprensione del profilo utente con dettagli che vanno oltre la semplice classificazione. Non ci si

limita quindi a etichettare, ma si forniscono descrizioni articolate che tengono conto delle diverse sfaccettature delle professioni. Laddove disponibili, gli endpoint forniti dall'INAPP contribuiscono a consolidare ulteriormente questo quadro, offrendo informazioni aggiornate e complete, che garantiscono affidabilità e coerenza delle raccomandazioni. L'obiettivo, in questo caso, non è soltanto tecnico, ma anche epistemologico: costruire un sistema che sia tracciabile, in cui ogni suggerimento abbia un'origine chiara e documentata, riducendo così l'opacità che spesso caratterizza i sistemi basati su AI.

Il processo di trasformazione dell'input utente in un output strutturato e motivato non si riduce a un passaggio unico, ma è concepito come una pipeline multi-stadio. Questo approccio riflette l'idea che l'orientamento non sia un atto istantaneo, bensì un percorso che accompagna la persona attraverso più fasi. Si parte dalla profilazione, in cui il testo libero dell'utente viene analizzato per estrarre competenze, esperienze e aspirazioni. Si procede quindi al recupero delle possibili professioni all'interno della tassonomia ISTAT, per poi applicare filtri e normalizzazioni che eliminano incoerenze o eccessi di generalizzazione. Infine, si giunge al ranking, cioè alla presentazione ordinata delle professioni ritenute più pertinenti, ciascuna accompagnata da un punteggio di rilevanza e da una motivazione sintetica. L'obiettivo non è dunque restituire un semplice elenco, ma costruire un percorso argomentato che permetta all'utente di comprendere perché una professione gli è stata suggerita e in che misura essa rispecchia le sue caratteristiche.

Questa impostazione metodologica non ha solo un valore pratico, ma anche scientifico. La pipeline multi-stadio consente infatti di rendere il sistema trasparente e migliorabile. Ogni fase può essere valutata separatamente, monitorata e, se necessario, ottimizzata. Questo permette non solo di affinare progressivamente le prestazioni del prototipo, ma anche di dimostrare che è possibile progettare sistemi di intelligenza artificiale per l'orientamento che non si presentino come “scatole nere”, ma come strumenti leggibili e verificabili.

Un ulteriore obiettivo riguarda la qualità del servizio. Un sistema non può essere valutato unicamente in base alla correttezza teorica dei suoi algoritmi, ma deve dimostrare di poter funzionare in maniera sostenibile anche in scenari reali. Per questo, la tesi prevede la definizione di indicatori di misurabilità concreti, che comprendono il monitoraggio dei costi computazionali, l'analisi della latenza complessiva e la registrazione strutturata delle esecuzioni. Questi elementi permettono non solo di comprendere i limiti del prototipo, ma anche di valutarne la scalabilità. Un sistema troppo costoso o troppo lento rischia di non essere utilizzabile in contesti concreti: stabilire criteri di qualità del servizio consente invece di orientare lo sviluppo verso soluzioni realistiche e sostenibili.

Ma un sistema di orientamento non è fatto solo di algoritmi e dati: al centro vi è sempre l'utente. Per questa ragione, uno degli obiettivi cardine della tesi è la realizzazione di una piattaforma user-friendly, pensata per essere intuitiva, accessibile e trasparente. L'interfaccia non deve essere un ostacolo, ma un facilitatore: l'utente deve poter inserire liberamente il proprio testo, ricevere raccomandazioni chiare e soprattutto comprendere le motivazioni che hanno portato a ciascun suggerimento. In questo senso, la semplicità non è un vezzo estetico, ma una componente essenziale della correttezza metodologica del sistema. Un utente che non riesce a decifrare le logiche alla base dei suggerimenti difficilmente potrà considerare affidabile lo strumento; al contrario, un'interfaccia trasparente favorisce fiducia, senso di controllo e maggiore soddisfazione nell'esperienza di orientamento.

Infine, non si può trascurare la dimensione etica. L'uso dell'intelligenza artificiale in ambiti che incidono direttamente sulla vita delle persone solleva interrogativi inevitabili legati a possibili discriminazioni. È noto come alcuni sistemi di selezione automatizzata abbiano penalizzato candidati in base al genere, all'età o al background culturale, riproducendo e amplificando bias presenti nei dati di partenza. Per questa ragione, tra gli obiettivi della tesi figura l'allineamento ai principi della Responsible AI, con un'attenzione particolare alla fairness. L'intento non è semplicemente quello di dichiarare l'assenza di discriminazioni, ma di predisporre strumenti metodologici che

permettano di valutarla in modo rigoroso. In questo contesto, si è scelto di andare oltre le metriche tradizionali, che riducono la complessità a semplici dicotomie, e di orientarsi verso definizioni più avanzate, come la statistical parity e l'equal opportunity in scenari multiclasse e multigruppo. Anche se il modulo di valutazione non è ancora parte integrante del prototipo, la sua inclusione tra gli obiettivi rappresenta un impegno chiaro: costruire un sistema che non solo sia tecnicamente valido, ma che rispetti principi di equità e trasparenza, evitando di rafforzare disuguaglianze preesistenti.

Riassumendo, gli obiettivi della tesi possono essere sintetizzati come la costruzione di un prototipo di orientamento professionale che unisca potenza interpretativa e solidità metodologica, che integri dati ufficiali e trasparenza, che offra all'utente un'esperienza chiara e accessibile e che si ponga fin dall'inizio il problema della giustizia e della responsabilità. In questo senso, il sistema non si limita a proporre professioni, ma si propone come modello di collaborazione tra esseri umani e intelligenza artificiale, capace di guidare le persone verso scelte lavorative più consapevoli e coerenti con le proprie potenzialità [8,9,10,11].




Figura 1 - Interfaccia utente del prototipo *Career Compass AI* con report di analisi, suggerimenti professionali e audit di fairness.⁴

⁴ Screen test prototipo. Sviluppato da A. Baragona
[https://github.com/Alessandro765/TESI_MAGISTRALE_BARAGONA]




Figura 2 - Interfaccia del prototipo Career Compass AI durante l’analisi del profilo utente, con visualizzazione dei moduli di output (professioni consigliate, percorsi correlati, ragionamento dell’IA e dati di classificazione).⁵

Testo del test: “Vorrei tanto provare a fare il cuoco. Ho fatto l'alberghiero e sono sempre stato affascinato dal mondo della ristorazione. In quali categorie professionali potrei rientrare?”

1.3 Contributo Scientifico e Tecnologico

Il contributo scientifico e tecnologico di questa tesi si articola su più livelli, che vanno dalla dimensione metodologica a quella applicativa, fino a incidere sul dibattito più ampio riguardante l’uso responsabile dell’intelligenza artificiale nei processi di orientamento professionale. In questo senso, il lavoro non si limita a proporre una soluzione tecnica, ma intende mostrare come sia possibile ripensare l’orientamento in chiave integrata, responsabile e trasparente, attraverso una combinazione originale di strumenti e approcci.

⁵ Screen test prototipo. Sviluppato da A. Baragona
[\[https://github.com/Alessandro765/TESI_MAGISTRALE_BARAGONA\]](https://github.com/Alessandro765/TESI_MAGISTRALE_BARAGONA)




Figura 3 - Schema generale dei sistemi di raccomandazione lavorativa. Fonte: Job recommender systems: a systematic literature review, applications, open issues, and challenges.⁶

Uno dei principali elementi di originalità è rappresentato dalla scelta di combinare modelli linguistici di grandi dimensioni (LLM) con la tassonomia ufficiale delle professioni ISTAT. Questa integrazione permette di superare un limite strutturale dei sistemi di job recommender tradizionali, che hanno spesso sofferto di due debolezze: da un lato, la difficoltà di interpretare input complessi e non standardizzati, come il racconto libero dell'utente; dall'altro, la mancanza di un legame solido con classificazioni istituzionali. La letteratura mostra come molti sistemi di raccomandazione lavorativa abbiano puntato su tecniche di filtraggio collaborativo o contenutistico, con risultati utili ma parziali, soprattutto quando si trattava di cogliere la varietà e la complessità delle identità professionali. La tesi qui presentata colma questa lacuna, dimostrando che è possibile costruire un sistema che parta dalla

⁶ Çelik Ertuğrul, D., Bitirim, S. Job recommender systems: a systematic literature review, applications, open issues, and challenges. J Big Data 12, 140 (2025). <https://doi.org/10.1186/s40537-025-01173-y>

ricchezza narrativa dell'utente e la traduca in un linguaggio standardizzato, riducendo lo scarto tra esperienza personale e categorie formali.

Un altro aspetto rilevante del contributo riguarda la progettazione di un approccio multi-stadio, che non si limita a elaborare un input e a restituire un output, ma costruisce un percorso graduale e motivato. L'intero processo, che va dalla profilazione alla restituzione finale dei suggerimenti, si articola in più fasi, ognuna delle quali aggiunge un livello di interpretazione e controllo. La profilazione consente di estrarre competenze, interessi e aspirazioni dal testo libero; il recupero si incarica di esplorare l'intera tassonomia per individuare le professioni candidate; il filtraggio elimina ridondanze o incoerenze, garantendo coerenza semantica; infine, il ranking presenta le opzioni ordinate, corredate da un punteggio di pertinenza e da una motivazione sintetica. Questo schema, sebbene ispirato alla logica dei sistemi complessi, assume in questa tesi una forma innovativa perché viene applicato a un dominio che raramente ha visto approcci tanto articolati. Non si tratta soltanto di un artificio tecnico, ma di un metodo che rende più trasparente e verificabile il processo di raccomandazione, restituendo all'utente non un risultato opaco, ma una traccia chiara del percorso logico che ha condotto alla proposta.

La novità tecnologica sta quindi nell'aver concepito l'orientamento come un processo "argomentato", in cui ogni passaggio ha un senso e un valore specifico. Questa impostazione, oltre a migliorare la qualità delle raccomandazioni, permette di aprire un dialogo con l'utente, che può comprendere le ragioni dei suggerimenti e confrontarle con la propria esperienza. Tale caratteristica distingue nettamente il prototipo sviluppato rispetto alla maggior parte dei sistemi precedenti, che tendono a funzionare come "scatole nere", restituendo risultati privi di spiegazione e quindi difficili da accettare o validare.

Il contributo non si esaurisce però sul piano metodologico. Un aspetto centrale è l'allineamento della tesi con il dibattito sulla Responsible AI. L'inserimento di un modulo di valutazione della fairness, anche se in forma preliminare, rappresenta un elemento di forte discontinuità rispetto ai sistemi

esistenti. La letteratura ha più volte evidenziato come i sistemi di raccomandazione lavorativa e i tool di selezione automatizzata possano generare discriminazioni involontarie, penalizzando categorie di utenti in base al genere, all'età o al background culturale. Questa tesi prende posizione in modo netto, sottolineando che non è sufficiente proporre raccomandazioni pertinenti: occorre anche verificare che esse siano eque, trasparenti e rispettose delle diversità sociali.




Figura 4 - Cronologia dei principali incidenti che evidenziano bias riscontrati nei sistemi di IA rilevanti per o influenti nelle applicazioni di reclutamento.⁷

In questo senso, il contributo scientifico è duplice: da un lato, dimostra come le metriche di fairness possano essere integrate fin dalle prime fasi di progettazione di un sistema di orientamento, e non solo aggiunte ex post come strumenti di controllo; dall'altro, propone un approccio che supera i limiti delle metriche binarie, predisponendo le basi per valutazioni più sofisticate in scenari multiclasse e multigruppo. Anche se il modulo di fairness non è stato ancora pienamente implementato, la sua inclusione negli obiettivi e nelle specifiche metodologiche rappresenta un chiaro impegno: lo sviluppo di sistemi di AI non può più prescindere da un impegno concreto verso l'equità e la responsabilità.

Il contributo tecnologico della tesi è dunque strettamente legato a quello scientifico. Sul piano tecnico, il prototipo mostra la fattibilità di un sistema capace di integrare input narrativi, tassonomie istituzionali e criteri di ranking motivato. Sul piano scientifico, esso apre nuove prospettive per la ricerca,

⁷ D. F. MUJTABA, N. R. MAHAPATRA, Fairness in AI-Driven Recruitment: Challenges, Metrics, Methods, and Future Directions, arXiv preprint, 2024. [<https://arxiv.org/abs/2405.19699>].

indicando la possibilità di costruire modelli di orientamento che siano al tempo stesso precisi, trasparenti ed equi. In questo senso, il lavoro si pone come un esempio di come sia possibile conciliare rigore metodologico e attenzione ai valori umani, offrendo un modello che può essere ripreso, adattato e ampliato in contesti diversi. Va sottolineato che questa tesi vuole evidenziare il legame tra comunità accademica e mondo applicativo. L'uso di dati ufficiali, l'attenzione alla user-friendliness e la cura degli aspetti etici mostrano che è possibile concepire prototipi che non restino confinati alla sperimentazione, ma che abbiano reali potenzialità di applicazione. È in questa prospettiva che il lavoro trova la sua collocazione più ampia: come esempio di ricerca che propone una via concreta seppur preliminare per superare certi limiti, contribuendo a ridefinire il modo in cui l'intelligenza artificiale può supportare le persone nelle scelte professionali [12,13].

CAPITOLO 2: Stato dell'Arte

2.1 Sistemi di Orientamento Professionale Tradizionali e Digitali

L'orientamento professionale ha radici che risalgono alle prime teorie psicologiche del XX secolo, quando si affermò l'idea che fosse possibile guidare gli individui nella scelta della carriera attraverso strumenti sistematici di valutazione. Per lungo tempo il modello di riferimento rimase quello dei cosiddetti approcci trait-factor, derivati dal lavoro pionieristico di Frank Parsons e sviluppati successivamente nella psicologia vocazionale. In questa prospettiva, l'incontro tra persona e professione era interpretato come un problema di compatibilità: da un lato si assumeva che l'individuo possedesse caratteristiche relativamente stabili (tratti, attitudini, interessi), dall'altro che le occupazioni potessero essere descritte in termini altrettanto oggettivi e misurabili. Il compito dell'orientamento consisteva dunque nell'effettuare un matching tra profilo individuale e ambiente professionale, individuando la soluzione di maggiore congruenza.

Un'importante articolazione di questo paradigma fu rappresentata dal modello di Holland, che descriveva sei tipologie di personalità e ambienti lavorativi (realistico, investigativo, artistico, sociale, intraprendente, convenzionale). Tale schema divenne, a partire dagli anni Sessanta, una delle cornici teoriche più utilizzate nel career counseling, nonché la base di numerosi test psicometrici standardizzati. La logica sottostante restava tuttavia la stessa: raccogliere dati sulle preferenze individuali, confrontarli con una griglia di categorie occupazionali e produrre un suggerimento di carriera in linea con il profilo ottenuto.

Tra gli anni Ottanta e Novanta, l'informatizzazione crescente aprì nuove possibilità. I primi Computer-Assisted Career Guidance Systems (CACGS) furono concepiti per digitalizzare e automatizzare questo processo: questionari cartacei vennero trasformati in batterie di test al computer, i database cartacei di professioni furono sostituiti da archivi elettronici e i risultati potevano essere consultati in maniera più rapida ed efficiente. Secondo l'analisi di Leung, sistemi come SIGI (System of Interactive

Guidance and Information) e CHOICES rappresentarono due esempi emblematici di questa fase: piattaforme che combinavano valutazioni di interessi e abilità con schede professionali dettagliate, collegate a banche dati aggiornate sul mercato del lavoro.

Questi strumenti ebbero un impatto rilevante per almeno tre motivi. In primo luogo, consentirono un accesso più ampio a risorse di orientamento che in passato erano fruibili solo in contesti accademici o centri specializzati. In secondo luogo, resero possibile una standardizzazione dei percorsi di counseling, poiché le stesse batterie di test potevano essere somministrate a grandi numeri di utenti, garantendo uniformità metodologica. Infine, introdussero un primo livello di interattività, poiché l'utente non si limitava a ricevere passivamente un consiglio, ma poteva esplorare banche dati e scenari alternativi sulla base dei risultati.

Tuttavia, come evidenzia Leung, questi sistemi restavano prigionieri della logica trait-factor. La loro funzione principale era tradurre i punteggi dei test in una lista di occupazioni predefinite, senza considerare la dimensione narrativa e contestuale dell'individuo. In altre parole, ciò che veniva trascurato era la possibilità che le identità professionali fossero fluide, in evoluzione, e influenzate da vincoli sociali, economici e culturali mutevoli. Il rischio era quello di produrre raccomandazioni statiche e riduttive, in cui la ricchezza delle esperienze personali veniva compressa in categorie standardizzate.

Un ulteriore limite dei CACGS di prima generazione riguardava la personalizzazione. I sistemi potevano proporre corrispondenze tra profili e occupazioni, ma non erano in grado di adattare i suggerimenti alle trasformazioni del mercato del lavoro o agli obiettivi di lungo periodo dell'utente. Mancava inoltre una componente di aggiornamento dinamico: molte banche dati professionali risultavano rapidamente obsolete, con conseguente disallineamento rispetto alle reali opportunità disponibili.

È in questo scenario che si inserisce l'analisi di Bimrose, Kettunen e Goddard (2015), i quali hanno studiato i fattori critici per una integrazione efficace

delle ICT nell'orientamento professionale. Gli autori identificano tre condizioni imprescindibili:

1. Supporto istituzionale, ovvero il sostegno politico ed economico necessario affinché le tecnologie non restino iniziative isolate ma si inseriscano in un quadro organico di servizi.
2. Competenze digitali dei counselor, poiché la tecnologia da sola non basta: occorre che i professionisti dell'orientamento siano formati per utilizzarla in maniera consapevole ed efficace.
3. Design user-centered, vale a dire la capacità di costruire sistemi realmente centrati sui bisogni degli utenti, e non su vincoli organizzativi o modelli tecnici astratti.

L'assenza di uno o più di questi fattori spiegava perché molti dei primi sistemi digitali non fossero riusciti a esprimere appieno il loro potenziale. Laddove mancava il supporto istituzionale, i progetti si esaurivano rapidamente; laddove i counselor non possedevano adeguate competenze digitali, la tecnologia restava sottoutilizzata; laddove non si teneva conto dell'esperienza dell'utente, i sistemi risultavano poco attrattivi e scarsamente utilizzati.

Il contributo di Bimrose et al. consente quindi di comprendere meglio il fallimento parziale dei CACGS nel rispondere alle esigenze emergenti del mercato del lavoro. Non si trattava soltanto di limiti tecnici, ma anche di limiti culturali e organizzativi, che impedivano alla tecnologia di tradursi in un reale valore aggiunto per l'utente finale.

Nel complesso, il periodo compreso tra il 2000 e il 2015 può essere descritto come una fase di transizione. Da un lato, l'orientamento professionale si fondava ancora su teorie classiche e strumenti standardizzati; dall'altro, cominciava a sperimentare forme di informatizzazione che anticipavano le potenzialità odierne. L'esperienza dei CACGS mostra con chiarezza che la tecnologia può ampliare l'accesso e rendere più efficienti i processi, ma senza un'adeguata attenzione alla personalizzazione e all'esperienza dell'utente il rischio è quello di ridursi a meri cataloghi digitali di professioni.

Questa constatazione è fondamentale per comprendere il punto di partenza della ricerca attuale: se oggi si parla di sistemi di orientamento basati su intelligenza artificiale, ciò avviene anche perché le prime generazioni di strumenti digitali hanno mostrato cosa mancava e quali dimensioni occorresse integrare. In particolare, la necessità di una maggiore adattività, trasparenza e capacità interpretativa rappresenta il filo conduttore che collega i limiti del passato con le opportunità del presente.

Il percorso storico che va dai modelli tradizionali ai primi sistemi informatizzati evidenzia come l'orientamento professionale abbia sempre oscillato tra due poli: da un lato, la spinta alla standardizzazione e alla misurazione oggettiva; dall'altro, la ricerca di personalizzazione e significato. I sistemi digitali pre-AI hanno rappresentato un passo avanti importante, ma non sufficiente: hanno reso più veloce e accessibile il processo, ma senza modificarne la logica di fondo. Come sottolineano Leung e Bimrose, la vera sfida consiste nel superare la rigidità dei modelli trait-factor e nell'innestare la tecnologia in un disegno più ampio, in cui la dimensione narrativa e contestuale dell'individuo non sia sacrificata a favore di punteggi standardizzati.

È proprio da questa tensione irrisolta che prende le mosse la fase successiva, segnata dall'avvento massiccio dell'intelligenza artificiale. Le nuove soluzioni non si propongono solo di rendere più efficiente l'orientamento, ma di affrontarne la complessità, colmando i vuoti lasciati dai sistemi precedenti [1,14].

2.2 Intelligenza Artificiale nell'HR Tech e nell'Orientamento

L'ingresso dell'intelligenza artificiale (AI) nel settore delle risorse umane ha rappresentato una svolta radicale nel modo in cui le organizzazioni reclutano, selezionano e supportano i lavoratori. A partire dalla metà degli anni 2010, il volume crescente di candidature e la complessità delle competenze richieste nei mercati del lavoro globalizzati hanno reso sempre più difficile affidarsi unicamente a pratiche manuali o strumenti informatici tradizionali. L'AI si è così affermata come leva strategica per migliorare efficienza, scalabilità e

capacità di analisi dei processi HR, dando vita a un insieme di applicazioni che spaziano dallo screening automatico dei curricula al job matching basato su algoritmi di raccomandazione.

In passato, la selezione dei candidati si basava principalmente sulla lettura manuale dei CV, con tempi lunghi, alto rischio di errori e forte esposizione a bias umani. I primi Applicant Tracking Systems (ATS) informatizzati cercarono di ridurre questo carico attraverso semplici filtri di parole chiave: un approccio utile per gestire grandi volumi di candidature, ma incapace di cogliere la complessità semantica di un profilo. Una descrizione professionale, infatti, raramente è lineare: le competenze possono essere espresse con sinonimi, abbreviazioni, varianti linguistiche oppure date per scontate dal contesto, senza essere dichiarate esplicitamente.

L'introduzione dell'intelligenza artificiale ha mutato radicalmente il quadro, introducendo tecniche di Natural Language Processing (NLP) e machine learning capaci di interpretare testi non strutturati, estrarre informazioni rilevanti e inferire competenze latenti. Un contributo particolarmente significativo in questa direzione è quello di Gugnani e Misra (2020), che hanno presentato un sistema di job recommendation in grado di combinare moduli di skill extraction con algoritmi di document embedding. L'obiettivo era duplice: migliorare la robustezza dell'estrazione di competenze dai CV e dalle job description (JD) e, soprattutto, identificare le cosiddette implicit skills, ovvero abilità non menzionate esplicitamente ma deducibili dal contesto professionale e dal confronto con offerte simili.

Per stimare se un termine estratto da CV o JD fosse realmente una competenza, gli autori hanno sviluppato un Relevance Score, che combina i contributi di più sottosistemi (NER, PoS tagging, dizionari di skill, modelli embedding). La formula adottata è la seguente:

$$x = \frac{\alpha S_1 + \beta S_2 + \sum_{n=1}^3 \gamma_n S_{3n} + \lambda S_4}{\alpha + \beta + \sum_{n=1}^3 \gamma_n + \lambda}$$

Formula 1 - Calcolo del Punteggio di Rilevanza (Relevance Score) per l'Estrazione di Competenze.⁸

- S_1 = punteggio dal PoS Tagger (analisi della struttura sintattica).
- S_2 = punteggio dal modulo NER (riconoscimento di entità come concetti e parole chiave).
- S_{3n} = contributi dei tre dizionari specializzati (ONET, Hope, Wikipedia).
- S_4 = similarità coseno calcolata con il modello Word2Vec (analisi contestuale).
- $\alpha, \beta, \gamma, \lambda$ = pesi empirici determinati sperimentalmente per bilanciare l'importanza di ciascun modulo.

Questo schema consente di filtrare rumore testuale e di selezionare con maggiore affidabilità le reali competenze.

Una volta arricchite le JD con skill esplicite e implicite, il sistema esegue il matching con i profili dei candidati. Qui il contributo principale è l'introduzione di un Affinity Score, calcolato come media pesata di tre fattori: similarità semantica tra skill, frequenza relativa nel dataset e natura esplicita/implicita della competenza.

⁸ A. GUGNANI, H. MISRA, Implicit Skills Extraction Using Document Embedding and Its Use in Job Recommendation, in AA.VV., AAAI Conference on Innovative Applications of Artificial Intelligence, 2020. [https://akshaygugnani.github.io/pdf/AAAI_IAAI-20_paper_139.pdf].

La formula per il calcolo del peso di ciascun collegamento (Edge Weight) è:

$$Y = (\omega_1 E_1 + \omega_2 E_2 + \omega_3 E_3) / (\omega_1 + \omega_2 + \omega_3)$$

Formula 2 - Calcolo del Peso del Collegamento (Edge Weight) tra Competenze⁹

- Y = Peso del Collegamento (Edge Weight), che misura la forza della corrispondenza tra una competenza del candidato e una della Job Description.
- E_1 = Similarità Coseno tra i vettori delle due competenze (calcolata con Word2Vec).
- E_2 = Fattore di Frequenza della competenza all'interno dell'intero corpus di documenti.
- E_3 = Valore di Boosting, che assegna un punteggio maggiore se la competenza è esplicita (1) rispetto a quando è implicita (0.5).
- $\omega_1, \omega_2, \omega_3$ = Pesi scelti per bilanciare l'importanza dei tre fattori, con valori rispettivamente di 0.5, 0.2 e 0.3.

In questo modo, il sistema riesce a generare raccomandazioni bilanciate, che non penalizzano un candidato solo perché le sue competenze sono formulate diversamente o perché alcune abilità non erano dichiarate esplicitamente.

La metodologia proposta integra più strumenti: un modulo di Named Entity Recognition (NER) per individuare concetti e termini rilevanti; un PoS Tagger per riconoscere pattern sintattici tipici delle espressioni di competenza; un dizionario di oltre 53.000 skill derivate da fonti pubbliche; e un modello Word2Vec/Doc2Vec addestrato su oltre 1,1 milioni di JD eterogenei. L'unione di queste fonti produce un sistema capace di associare

⁹ A. GUGNANI, H. MISRA, Implicit Skills Extraction Using Document Embedding and Its Use in Job Recommendation, in AA.VV., AAAI Conference on Innovative Applications of Artificial Intelligence, 2020. [https://akshaygugnani.github.io/pdf/AAAI_IAAI-20_paper_139.pdf].

a ciascun termine un punteggio di rilevanza, evitando che abilità marginali o rumore testuale entrino nel matching.

Il passaggio decisivo riguarda proprio l'uso del Doc2Vec per individuare offerte di lavoro semanticamente simili a quella in analisi. Attraverso questo confronto, il sistema è in grado di arricchire ogni JD con un insieme di competenze implicite — ad esempio, una posizione che richiede conoscenza di Microsoft Word implica anche familiarità con strumenti di produttività da ufficio. Questo arricchimento semantico consente di superare i limiti del keyword matching, fornendo un profilo più realistico delle esigenze occupazionali.

I risultati sperimentali sono eloquenti: il sistema ha ottenuto una precisione di 0,78 e un recall di 0,88 nell'estrazione delle competenze, con un F1-score pari a 0,83. Ancora più rilevante è il miglioramento ottenuto nel matching tra CV e JD: introducendo le competenze implicite, l'accuratezza nella raccomandazione del primo lavoro proposto al candidato è passata da 0,68 a 0,88, con un incremento del 29,4% nel Mean Reciprocal Rank (MRR) rispetto alla baseline. Inoltre, entro i primi cinque suggerimenti, il sistema è stato in grado di individuare sempre almeno un job perfettamente compatibile.

In questo modo, il lavoro di Gugnani e Misra dimostra come l'AI possa affrontare due sfide centrali del recruiting moderno: da un lato, la capacità di processare testi complessi e non standardizzati; dall'altro, la possibilità di colmare i vuoti informativi presenti nei dati espliciti, ricostruendo competenze implicite che altrimenti sfuggirebbero ai sistemi tradizionali.

Parallelamente, studi applicativi come quello di Abhishek et al. (2025) hanno mostrato come l'automazione basata su AI possa rendere radicalmente più efficiente lo screening dei curricula. Il sistema proposto, denominato AI Resume Analyzer, si distingue dai tradizionali ATS perché non si limita a estrarre parole chiave, ma integra tecniche avanzate di Natural Language Processing (PyResparser, NLTK) con algoritmi di machine learning e una gestione strutturata dei dati attraverso database relazionali (MySQL). Grazie

a questa architettura, l'intero contenuto del CV – dalle informazioni anagrafiche alle esperienze lavorative, dalle competenze tecniche alle certificazioni – viene convertito in un formato tabellare normalizzato, pronto per analisi successive e confronti sistematici con i requisiti delle posizioni aperte.

Un aspetto particolarmente innovativo del modello è la sua interfaccia interattiva, sviluppata in Streamlit, che non solo facilita il caricamento dei CV ma fornisce anche visualizzazioni e feedback in tempo reale. Questo significa che i candidati ricevono suggerimenti concreti per migliorare il proprio curriculum: ad esempio, l'aggiunta di sezioni mancanti (come certificazioni o progetti) o la riformulazione di competenze in linea con i trend del mercato. L'inclusione di una funzione di punteggio ("resume score") rende il processo trasparente, stimolando i candidati a perfezionare progressivamente il documento.

Dal lato dei recruiter, il sistema offre analytics dettagliati sul mercato del lavoro: distribuzione delle competenze più frequenti, ruoli emergenti, background formativi prevalenti. Queste informazioni, normalmente frammentarie o difficili da aggregare manualmente, diventano strumenti decisionali immediatamente disponibili, riducendo il rischio di errori e garantendo un approccio più oggettivo alla selezione. Non meno rilevante è il contributo del sistema alla riduzione dei bias: sostituendo valutazioni soggettive con criteri standardizzati e data-driven, l'AI Resume Analyzer favorisce una selezione più equa e scalabile.

Negli ultimi anni, l'impiego dell'AI nelle prime fasi di selezione si è ampliato oltre la semplice analisi testuale, arrivando ad automatizzare vere e proprie interazioni preliminari con i candidati. Soluzioni come MYA hanno dimostrato la possibilità di condurre colloqui automatizzati con decine di migliaia di candidati, riducendo drasticamente i tempi del recruiting. Allo stesso modo, piattaforme come HireVue hanno introdotto algoritmi di computer vision e analisi vocale in grado di valutare non solo le risposte verbali, ma anche segnali paralinguistici e comportamentali. Questi strumenti, pur suscitando dibattito sul rischio di discriminazioni

algoritmiche, rappresentano una prima forma di estensione dell'AI oltre il semplice keyword matching, introducendo una dimensione multimodale al processo di valutazione.

Un passo ulteriore è stato compiuto da Lo et al. (2025), che hanno proposto un'architettura multi-agente basata su Large Language Models (LLM) per la valutazione dei CV e la generazione di feedback. Il sistema non si affida a un modello monolitico, ma suddivide il processo in quattro agenti specializzati:

1. Resume extractor - incaricato di estrarre e strutturare le informazioni chiave da CV non standardizzati (posizione richiesta, esperienze, competenze, formazione).
2. Resume evaluator - responsabile di attribuire punteggi alle varie sezioni, integrando criteri dinamici tramite Retrieval-Augmented Generation (RAG): ad esempio, recuperando certificazioni specifiche, ranking universitari o requisiti di settore. che assegna punteggi a ciascun candidato in base a cinque categorie di valutazione: auto-valutazione (S_s^J), competenze e specializzazioni (S_k^J), esperienze lavorative (S_w^J), informazioni di base (S_B^J) e background educativo (S_E^J).
3. Resume summarizer - che, attraverso tre sotto-agenti (CEO, CTO e HR), simula un processo decisionale collegiale, generando un feedback personalizzato che bilancia leadership, competenze tecniche e soft skills.
4. Score formatter - che standardizza i risultati in un formato numerico strutturato, facilmente integrabile nei sistemi ATS esistenti. Converte le valutazioni in array numerici standardizzati per facilitarne l'integrazione in pipeline decisionali

La struttura tecnica introduce un calcolo formale dei punteggi. Per ogni candidato che applica a una posizione J, il sistema genera un vettore di valutazione:

$$S^J = \{S_S^J, S_K^J, S_W^J, S_B^J, S_E^J\}$$

dove ciascun elemento rappresenta lo score attribuito a una delle cinque dimensioni chiave del profilo. Le categorie sono ponderate attraverso un set di pesi costanti:

$$W = \{w_S, w_K, w_W, w_B, w_E\}, \quad \sum w_i = 1$$

Il punteggio finale del candidato viene calcolato come media pesata:

$$S_{\text{final}}^J = \sum w_i S_i^J,$$

Un elemento distintivo del framework è l'integrazione del paradigma Retrieval-Augmented Generation (RAG) all'interno del resume evaluator. Invece di affidarsi unicamente ai dati pre-addestrati del modello, il sistema recupera conoscenze esterne contestuali – come ranking universitari, certificazioni richieste o pattern di competenze emersi da candidati eccellenti in passato – e le utilizza per costruire valutazioni aggiornate e specifiche al ruolo. Ciò permette di superare il limite dei modelli LLM statici, incapaci di adattarsi a requisiti dinamici del mercato del lavoro.

I risultati sperimentali confermano l'efficacia dell'approccio: rispetto a sistemi basati su un singolo LLM, il framework multi-agente RAG-LLM ha raggiunto valori più alti di correlazione con le valutazioni umane, riducendo al contempo l'errore medio assoluto (MAE = 0,90). Un'analisi di ablation ha inoltre dimostrato l'importanza del resume extractor: eliminando questa componente, le performance calano sensibilmente, evidenziando che la qualità del parsing iniziale è determinante per l'accuratezza dell'intero processo.

Mentre il resume summarizer rappresenta un'innovazione rilevante in termini di trasparenza: simulando un dibattito tra agenti specializzati, restituisce un feedback che non è solo numerico ma anche argomentato e personalizzato, riducendo la percezione di opacità tipica dei sistemi automatizzati. In prospettiva, Lo e colleghi sottolineano che l'adozione di

architetture multi-agente non serve soltanto ad aumentare l'efficienza, ma a rafforzare la spiegabilità e l'adattabilità, allineandosi così ai principi della Responsible AI [3,15,16,17,18].




Figura 5 - L'evoluzione delle tecnologie di assunzione basate sull'IA. Questa figura illustra la transizione dei metodi di selezione guidati dall'IA attraverso tre fasi principali: machine learning tradizionale (2010-2016), deep learning (2016-2022) e large language models (2022-oggi). Vengono evidenziati i principali avanzamenti nelle tecnologie di assunzione basate sull'IA e alcuni casi studio significativi che ne dimostrano le applicazioni reali.¹⁰

Quando si parla di integrare un agente basato su LLM in un sistema, occorre considerare attentamente se adottare una architettura a singolo agente (single-agent) o una architettura multi-agente (multi-agent). OpenAI nella sua guida pratica agli agenti distingue chiaramente questi due pattern di orchestrazione, ciascuno con vantaggi, limiti e scenari d'uso preferenziali.

¹⁰ F. P.-W. LO et al., AI Hiring with LLMs: A Context-Aware and Explainable Multi-Agent Framework for Resume Screening, arXiv preprint, 2024. [https://arxiv.org/pdf/2504.02870].

Nei sistemi a agente singolo o Single-Agent Systems, un unico agente dotato di strumenti (tool) compie l'intero workflow, iterando tra ragionamento e uso di tool finché non raggiunge una condizione di uscita.

- In questa modalità, man mano che crescono i requisiti, è possibile aggiungere strumenti (tool) all'agente, estendendone le capacità senza dover suddividere il sistema in agenti distinti.
- Il ciclo operativo tipico è un loop: l'agente valuta lo stato, decide un'azione o un tool da invocare, esegue, aggiorna lo stato, ripete. È previsto che l'agente continui finché non si verifica una condizione di terminazione, come un output definitivo, l'assenza di tool invocabili o il superamento di un limite di iterazioni.
- Il vantaggio principale risiede nella semplicità architetturale: c'è un unico punto di orchestrazione, contesto unico e facile estendibilità iniziale. Questo rende più gestibile la valutazione, il debugging e la manutenzione.
- Tuttavia, man mano che la complessità del dominio cresce, questa configurazione può diventare un collo di bottiglia: se l'agente deve ragionare su molteplici sotto-compiti, gestire molte condizioni e selezionare tra molti strumenti, il prompt e la logica rischiano di diventare troppo complessi da mantenere. In questi casi può emergere la necessità di splittare il logica in più agenti

Nei sistemi multi-agente, il workflow è suddiviso tra diversi agenti specializzati, ciascuno dedicato a un sotto-compito, sotto la supervisione o l'orchestrazione di un agente "capo" o di un sistema di coordinamento.

- Ogni agente può funzionare con una focalizzazione tematica: ad esempio, un agente per la ricerca, uno per il filtraggio, uno per la generazione esplicativa.
- Gli agenti possono collaborare: uno può invocare un altro agent come "tool", passargli dati o delegare parti di ragionamento. Nel SDK OpenAI, esistono esempi concreti in cui un "Portfolio Manager

Agent” coordina specialisti (macro, fondamentale, quantitativo) per produrre output elaborati

- Questo approccio è utile quando il dominio è complesso, le responsabilità sono molteplici e si vuole ottenere modularità, parallelismo, separazione di responsabilità e maggiore scalabilità.
- Tuttavia, introduce costi aggiuntivi: coordinamento degli agenti, gestione del contesto condiviso, comunicazione tra agenti, sincronizzazione, potenziale latenza indotta dall’orchestrazione. Inoltre la complessità di debug e monitoraggio sale.

OpenAI raccomanda di partire da un sistema single-agent e poi passare a una architettura multi-agent solo quando la complessità lo richiede. Di seguito vengono illustrati alcuni criteri utili:

- Se il task è relativamente lineare o con pochi passaggi, un singolo agente con tool ben costruiti è spesso sufficiente.
- Se il prompt comincia a essere troppo ramificato (molte condizioni, troppi strumenti), può diventare difficile mantenere la coerenza e l’efficacia: in questo caso conviene suddividere in agenti specializzati.
- Se è necessario che diversi agenti operino in parallelo o con memoria separata o contesti diversi, l’architettura multi-agent può essere giustificata.
- Un approccio misto è possibile: agenti che collaborano, oppure agenti “come tool” all’interno di un agente principale [19,20,21].

2.3 Large Language Models (LLM) per Comprensione e Generazione Testuale

Negli ultimi anni, i modelli di linguaggio di grandi dimensioni (LLM, Large Language Models) hanno rivoluzionato il campo del Natural Language Processing (NLP), segnando un punto di discontinuità rispetto ai metodi tradizionali. L’idea di fondo è che, addestrando modelli di rete neurale su enormi quantità di testi eterogenei, sia possibile sviluppare rappresentazioni

linguistiche generali, capaci di essere applicate a una vasta gamma di compiti senza la necessità di riaddestramenti specifici. Questa transizione, ben documentata dalla letteratura più recente, trova il suo snodo principale nella pubblicazione di GPT-3 (Brown et al., 2020), che ha dimostrato come l'aumento drastico della scala del modello e dei dati di training generi capacità emergenti inattese, tra cui il cosiddetto few-shot learning.

Parallelamente, il concetto di foundation models, introdotto da Bommasani et al. (2021), ha fornito la cornice teorica per interpretare questa nuova generazione di sistemi: modelli addestrati su larga scala, riutilizzabili e adattabili a molteplici compiti, ma al contempo portatori di rischi significativi legati a bias, opacità e implicazioni sociali. Infine, il GPT-4 Technical Report (OpenAI, 2023) ha descritto il passaggio a modelli multimodali, in grado di elaborare non solo testi ma anche immagini, segnando un ulteriore salto qualitativo nella capacità di comprensione e generazione contestuale.

In questo paragrafo verranno esaminati alcuni LLM attualmente in uso o di riferimento - GPT-3, GPT-4, PaLM e LLaMA - insieme ai concetti chiave che ne caratterizzano il funzionamento: few-shot learning, foundation models e multimodalità.

La pubblicazione di GPT-3 (Generative Pre-trained Transformer 3) da parte di Brown et al. (2020) rappresenta una pietra miliare nello sviluppo degli LLM. Con 175 miliardi di parametri e un addestramento su circa 300 miliardi di token provenienti da fonti eterogenee (web, Common Crawl filtrate, libri, articoli scientifici, codice, ecc). GPT-3 è stato dieci volte più grande rispetto a qualsiasi modello precedente. L'architettura rimane basata sul trasformatore, ma con ottimizzazioni specifiche come schemi di attenzione densa e sparsa alternata e una finestra di contesto di 2048 token, che consente di inglobare numerosi esempi nel prompt.

Il punto di rottura rispetto ai predecessori non risiede solo nella dimensione, ma nelle capacità emergenti che il modello ha dimostrato. L'aspetto più innovativo è il cosiddetto few-shot learning, ovvero la capacità di eseguire

un nuovo compito semplicemente osservando pochi esempi nel prompt, senza bisogno di riaddestramento. Brown et al. distinguono tre scenari:

- Zero-shot learning, quando il modello riceve solo un'istruzione testuale (“Traduci in francese: The book is on the table”) e riesce a completare il compito senza esempi.
- One-shot learning, quando viene fornito un singolo esempio per guidare il modello.
- Few-shot learning, quando vengono forniti alcuni esempi, che il modello generalizza per produrre risposte corrette a nuovi input.

Questa proprietà ha aperto la strada a usi concreti nel campo dell'orientamento professionale: con un prompt opportunamente costruito, GPT-3 è in grado di estrarre competenze da un CV in linguaggio libero, classificare esperienze lavorative o persino generare descrizioni sintetiche di profili professionali. Ciò significa che, a differenza degli approcci tradizionali che richiedevano sistemi specializzati per ogni task (es. modelli di named entity recognition per le skill, classificatori per le occupazioni), un singolo LLM può affrontare compiti diversi con un grado sorprendente di generalizzazione.

La versatilità di GPT-3 è stata dimostrata da Brown et al. in compiti eterogenei come traduzione, question answering, completamento di testi e persino ragionamento aritmetico di base. Questo risultato ha sancito la transizione verso un paradigma in cui la potenza del modello cresce con la scala, rendendo meno necessari gli adattamenti specifici e più centrale la progettazione del prompt, qui nasce in modo chiaro prompt engineering un insieme di tecniche e strategie per formulare delle istruzioni efficaci da fornire ad un LLM in modo tale da produrre risposte accurate, utili e coerenti con l'obiettivo dello sviluppatore. In pratica LLM risponderà ad un compito in modo strutturato come un algoritmo tradizionale, questo aspetto sarà approfondito nel paragrafo successivo.

Mentre GPT-3 forniva la dimostrazione empirica delle capacità emergenti legate alla scala, il report di Bommasani et al. (2021) ha introdotto il termine

foundation models per descrivere questa nuova generazione di modelli. La definizione è chiara: un foundation model è un sistema addestrato su dati massivi e generici, che può essere adattato a una grande varietà di compiti a valle (downstream tasks).

Le opportunità offerte da tali modelli sono evidenti:

- Versatilità → un unico modello può affrontare traduzione, riassunto, classificazione, generazione, riducendo la necessità di mantenere molteplici sistemi specializzati.
- Transfer learning esteso → le rappresentazioni linguistiche apprese durante il pre-training sono riutilizzabili in domini molto diversi, inclusi quelli specifici come l'analisi dei curricula al fine di sintetizzare informazioni pertinenti del candidato.
- Efficienza nello sviluppo → invece di addestrare modelli da zero, si parte da una base potente che può essere raffinata con poche risorse.

Tuttavia, Bommasani e colleghi sottolineano anche i rischi strutturali di questa impostazione:

- Emergence → capacità inaspettate che appaiono solo oltre una certa soglia di scala (come il few-shot learning in GPT-3), difficili da prevedere o controllare.
- Homogenization → tendenza a utilizzare lo stesso modello per compiti diversissimi, con il rischio che un singolo errore sistemico si propaghi a più applicazioni.
- Bias nei dati → poiché i foundation models sono addestrati su enormi quantità di dati non sempre curati, rischiano di ereditare e amplificare stereotipi e discriminazioni.
- Opacità → la scala rende difficile spiegare il processo decisionale, alimentando preoccupazioni sulla trasparenza.

- Dipendenza infrastrutturale → l'addestramento di modelli di queste dimensioni richiede risorse computazionali enormi, concentrando il controllo in poche grandi aziende tecnologiche.

Applicati all'orientamento professionale, questi aspetti assumono particolare rilevanza: un foundation model può estrarre e classificare competenze in maniera rapida ed economica, ma se i dati di addestramento sono distorti rischia di penalizzare interi gruppi di candidati. La nozione di Responsible AI si inserisce qui come cornice critica: sfruttare la potenza dei foundation models richiede parallelamente meccanismi di controllo, auditing e spiegabilità.

Il rilascio di GPT-4 Technical Report (OpenAI, 2023) segna una nuova fase nello sviluppo degli LLM, caratterizzata da tre elementi distintivi:

1. Miglioramento delle capacità di ragionamento contestuale → GPT-4 raggiunge prestazioni vicine a quelle umane in benchmark complessi, dimostrando una comprensione più fine delle sfumature linguistiche.
2. Multimodalità → per la prima volta un LLM diventa capace di elaborare input non solo testuali, ma anche visivi, come immagini.
3. Sicurezza e mitigazione delle allucinazioni → OpenAI dedica particolare attenzione a meccanismi di alignment, per ridurre le risposte non accurate o inappropriate.

La dimensione multimodale apre possibilità inedite per l'orientamento professionale: un sistema basato su GPT-4 potrebbe, ad esempio, analizzare non solo un CV testuale, ma anche la scansione di un attestato di certificazione, o persino un portfolio grafico di un candidato creativo. Questo consente un'integrazione più realistica delle informazioni, avvicinando il processo automatizzato alle modalità di valutazione adottate dai recruiter umani.

Il report evidenzia inoltre l'importanza di introdurre controlli di qualità e filtri di sicurezza, a dimostrazione che la potenza dei modelli va sempre accompagnata da meccanismi di supervisione. Anche in questo caso,

l'impatto sull'HR Tech è evidente: un sistema multimodale permette analisi più ricche e accurate, ma deve essere progettato in modo da non amplificare errori o discriminazioni.

Sebbene GPT-3 e GPT-4 siano i modelli più noti, il panorama degli LLM comprende altri sistemi di grande importanza.

PaLM (Pathways Language Model, Google) si distingue per la scala estrema (fino a 540 miliardi di parametri) e per la capacità di ragionamento su compiti numerici e logico-linguistici complessi. PaLM ha dimostrato che l'aumento della dimensione, se accompagnato da un addestramento diversificato, porta a prestazioni superiori in task di Q&A, traduzione e inferenza.

LLaMA (Large Language Model Meta AI, Meta) rappresenta invece un approccio opposto: un modello più contenuto nella dimensione ma rilasciato in forma open-source, pensato per la comunità accademica e di ricerca. LLaMA ha reso accessibile la sperimentazione con LLM anche a gruppi non dotati di risorse computazionali gigantesche, favorendo un ecosistema più distribuito e trasparente.

Il confronto tra GPT-4, PaLM e LLaMA mette in luce le tensioni attuali: da un lato, la spinta verso modelli sempre più grandi e performanti; dall'altro, l'esigenza di apertura e accessibilità, che garantisca possibilità di verifica indipendente e innovazione diffusa.

I tre concetti chiave che emergono dalla letteratura - few-shot learning, foundation models e multimodalità - non sono solo etichette tecniche, ma veri e propri paradigmi che orientano l'evoluzione degli LLM.

- Il few-shot learning, introdotto con GPT-3, mostra come la scala dei dati e dei parametri generi capacità emergenti, riducendo la necessità di modelli specializzati.
- I foundation models, teorizzati da Bommasani, rappresentano l'infrastruttura concettuale che giustifica il riuso degli LLM su compiti diversi, ma evidenziano anche i rischi etici e sociali.

- La multimodalità, realizzata in GPT-4, amplia ulteriormente le potenzialità, spostando gli LLM da strumenti puramente linguistici a sistemi capaci di integrare più tipi di informazione, avvicinandosi a un'intelligenza più generale.

Questi concetti hanno ricadute dirette sui sistemi di orientamento professionale: dalla capacità di analizzare descrizioni libere di competenze (few-shot), alla possibilità di riutilizzare modelli pre-addestrati per task HR senza costosi fine-tuning (foundation), fino all'integrazione di dati testuali e visivi in un'unica pipeline (multimodalità).

La traiettoria degli LLM, da GPT-3 a GPT-4, passando per PaLM e LLaMA, evidenzia un percorso di progressiva espansione delle capacità: dalla comprensione del linguaggio naturale alla multimodalità, dalla generalizzazione few-shot all'adattabilità dei foundation models. Allo stesso tempo, la letteratura avverte dei rischi: bias, opacità, concentrazione delle risorse in pochi attori industriali. Argomenti fondamentali per un corretto sviluppo tecnologico e che verranno trattati più avanti nell'elaborazione della tesi, che promettono significativi miglioramenti inerenti alla spiegabilità e alla correttezza della generazione della risposta.

Per i sistemi di orientamento professionale, ciò significa trovarsi di fronte a strumenti potenti ma da gestire con cautela: i LLM possono estrarre e classificare competenze, suggerire percorsi di carriera e persino analizzare portfolio multimodali, ma devono essere progettati e utilizzati in ottica di Responsible AI. Solo così è possibile garantire che la potenza tecnica si traduca in valore sociale, favorendo scelte lavorative più consapevoli, eque e sostenibili [22,23,24].

2.4 Tecniche di Prompt Engineering per LLM

Negli ultimi anni, l'emergere dei Large Language Models (LLM) ha reso evidente un cambiamento nel modo in cui l'intelligenza artificiale può essere utilizzata nei contesti applicativi. Se nella fase precedente dell'NLP era spesso necessario addestrare modelli specifici per ogni compito, gli LLM hanno introdotto un paradigma nuovo: un modello generico, addestrato su

miliardi di testi, può essere guidato ad adattarsi a compiti differenti semplicemente attraverso l'uso del prompt, ossia l'istruzione che l'utente fornisce in input. Questa constatazione ha dato vita a una disciplina emergente, denominata prompt engineering, che consiste nell'arte di formulare istruzioni testuali chiare e strutturate per ottenere dai modelli risposte affidabili e utili senza la necessità di riaddestramento.

Secondo la definizione di Vatsal e Dubey (2024), il prompt engineering può essere descritto come il processo di “comporre istruzioni in linguaggio naturale per estrarre conoscenza dai LLM in modo strutturato”. La portata di questa definizione è ampia: non si tratta solo di scrivere una domanda ben posta, ma di progettare veri e propri schemi di interazione che orientano il comportamento del modello. Ciò significa che anche utenti non esperti di machine learning possono, tramite semplici frasi testuali, programmare un comportamento complesso dell'AI, riducendo la distanza tra linguaggio naturale e linguaggio di programmazione.

La rilevanza di questo approccio è duplice. Da un lato, consente di sfruttare la potenza dei modelli linguistici senza costi computazionali enormi: non occorre costruire dataset annotati o avviare processi di fine-tuning, basta formulare un prompt ben disegnato. Dall'altro, rende gli LLM più flessibili e accessibili, poiché la qualità delle risposte dipende in gran parte dalla progettazione dell'input. Per questo motivo, il prompt engineering è destinato a giocare un ruolo centrale in applicazioni critiche come l'orientamento professionale, dove è necessario indurre il modello a estrarre competenze da testi liberi come, ad esempio, l'input di un utente, classificarle secondo tassonomie ufficiali (ISTAT) e fornire spiegazioni trasparenti delle scelte.

La survey di Vatsal e Dubey (2024) rappresenta una delle prime sistematizzazioni scientifiche del campo. Gli autori hanno catalogato 39 metodi di prompting applicati a 29 task NLP differenti, dimostrando come il prompt engineering sia ormai una disciplina con un proprio repertorio di tecniche. La classificazione distingue tra:

- Prompt descrittivi, che consistono nel fornire un’istruzione chiara e diretta (es. “Riassumi il seguente testo in tre punti”).
- Prompt con esempi, che includono dimostrazioni del compito atteso (few-shot prompting).
- Prompt avanzati e contestualizzati, che integrano ragionamenti intermedi, conoscenze esterne o sequenze iterative di istruzioni.

Il punto chiave sottolineato dagli autori è che il prompt engineering non è solo una scorciatoia pratica, ma una vera e propria interfaccia di programmazione in linguaggio naturale. L’LLM non viene modificato internamente: resta un foundation model addestrato su dati generici. Ciò che cambia è la cornice che l’utente costruisce attraverso il prompt, che funge da “programma” temporaneo.

Per il nostro contesto di tesi, ciò significa che è possibile indurre un modello come GPT-4 a comportarsi da “career counselor digitale” senza necessità di training dedicato: basta progettare un prompt che contenga contesto (profilo utente), obiettivo (classificazione ISTAT) ed esempi di output atteso.

Tra le tecniche di prompt engineering, una delle più rilevanti è il few-shot prompting, derivato dal paradigma introdotto da GPT-3 (Brown et al., 2020). In questo approccio, l’utente inserisce nel prompt alcuni esempi di input-output prima del testo da elaborare. In tal modo, il modello “apprende in contesto” (*in-context learning*) la modalità di risposta desiderata.

Vatsal e Dubey (2024) mostrano che il few-shot prompting è stato applicato con successo a una vasta gamma di compiti: traduzione, question answering, sentiment analysis, classificazione. Il principio è semplice ma potente: il modello non modifica i propri parametri, ma sfrutta il contesto fornito nel prompt come traccia per generare risposte coerenti.

In ambito di orientamento professionale, questo si traduce nella possibilità di presentare al modello uno o due esempi di CV annotati con le relative competenze estratte, e poi chiedere di replicare lo schema su un nuovo documento. Senza alcun addestramento supervisionato, il modello riesce a

imitare lo schema richiesto, adattandosi a compiti diversi (estrazione, classificazione, sintesi) con un livello sorprendente di accuratezza.

Il few-shot prompting rappresenta dunque una tecnica fondamentale non solo per la sua semplicità, ma anche perché evidenzia la natura adattiva dei foundation models. Grazie a essa, è possibile sfruttare la capacità degli LLM di generalizzare istruzioni senza la necessità di costosi dataset annotati.

Esempio di prompt da passare al fine di analizzare l'insieme dei messaggi condivisi da un utente per estrarre delle informazioni utili al fine di cercare un lavoro per un utente:

```
prompt_with_few_shoot = ""
```

Sei un assistente che riceve un testo libero scritto da un utente {memoria_utente}.

Il tuo compito è analizzare il testo ed estrarre i seguenti campi, restituendo sempre un output in formato JSON:

- regione (stringa)
- esperienza_lavorativa (lista di stringhe)
- titoli_studio (lista di stringhe)
- disoccupato (booleano: true/false)
- skill_hard (lista di stringhe)
- skill_soft (lista di stringhe)

Ecco alcuni esempi:

ESEMPIO 1

Input: "Mi chiamo Luca, vivo in Lombardia. Ho lavorato 3 anni come elettricista e 2 anni come tecnico impianti. Ho un diploma da perito industriale. Ora non lavoro."

Output:

```
{  
  "regione": "Lombardia",  
  "esperienza_lavorativa": ["Elettricista", "Tecnico impianti"],  
  "titoli_studio": ["Diploma Perito Industriale"],  
  "disoccupato": true,  
  "skill_hard": ["Impiantistica elettrica", "Manutenzione impianti"],  
  "skill_soft": ["Problem solving", "Lavoro in team"]  
}
```

ESEMPIO 2

Input: "Sono Maria, abito nel Lazio. Ho 5 anni di esperienza come insegnante di scuola primaria. Laureata in Scienze della Formazione. Attualmente insegno ancora."

Output:

```
{  
  "regione": "Lazio",  
  "esperienza_lavorativa": ["Insegnante scuola primaria (5 anni)"],  
  "titoli_studio": ["Laurea in Scienze della Formazione"],  
  "disoccupato": false,  
  "skill_hard": ["Didattica"],  
  "skill_soft": ["Empatia", "Comunicazione efficace"]  
}  
""
```

Un passo ulteriore è rappresentato dalle tecniche di reasoning prompting, tra cui spicca il Chain-of-Thought (CoT) introdotto da Wei et al. (2022). L'idea alla base è intuitiva: invece di chiedere al modello la sola risposta finale, lo si istruisce a produrre una sequenza di ragionamenti intermedi, simulando un processo di pensiero esplicito.

Gli esperimenti condotti da Google Research hanno mostrato che il CoT produce miglioramenti significativi nei compiti che richiedono ragionamento logico o aritmetico. Ad esempio, nei benchmark matematici, la semplice aggiunta dell'istruzione "pensa passo per passo" ha aumentato drasticamente l'accuratezza, mostrando che i modelli sono in grado di "spiegare a se stessi" prima di fornire una risposta.

Per il nostro caso, il CoT ha un valore ancora più strategico: un LLM utilizzato per il career counseling può essere istruito non solo a suggerire professioni, ma anche a spiegare i passaggi logici che lo hanno portato a quella scelta. Un prompt come: "Mostra passo-passo come hai selezionato le professioni più adatte, indicando le competenze chiave che hai rilevato" indurrebbe il modello a fornire una giustificazione argomentata. Questo non solo aumenta la trasparenza, ma anche la fiducia dell'utente, che non si trova davanti a una raccomandazione "opaca" bensì a un ragionamento verificabile.

Oltre al CoT, il survey di Vatsal e Dubey (2024) menziona altre tecniche avanzate:

- Self-consistency prompting, in cui il modello genera più catene di ragionamento e si sceglie la più frequente o coerente.

Esempio

Prompt = ""

Domanda: Un candidato ha lavorato 3 anni come sviluppatore software e 2 anni come analista dati.

Ha una laurea in Informatica.

Attualmente non ha un impiego.

In quale categoria professionale ISTAT rientra?

Spiega il ragionamento passo per passo e fornisci come output il codice ISTAT più appropriato.

Genera 3 possibili catene di ragionamento indipendenti.

""""

- Iterative prompting, che consiste nel raffinare l'output attraverso più cicli di istruzioni. Qui verranno eseguite più "passate" di prompt al fine di migliorare l'output finale.
- Contextual prompting, che prevede l'inserimento di informazioni esterne (ad esempio, una tassonomia come ISTAT) direttamente nel prompt per vincolare la generazione. Sarà illustrata più avanti nella tesi nel capitolo dedicato all'implementazione.

Queste varianti confermano che il prompt engineering non è una tecnica statica, ma un campo in evoluzione continua, dove la creatività nella formulazione delle istruzioni determina la qualità dei risultati.

Accanto alla letteratura accademica, le linee guida industriali hanno contribuito a consolidare pratiche di prompt engineering efficaci. Le Prompt Engineering Techniques pubblicate da Microsoft (2023), nell'ambito dell'Azure OpenAI Service, offrono consigli pratici che derivano dall'esperienza sul campo.

Tra le raccomandazioni principali figurano:

- Fornire contesto esplicito → includere nel prompt tutte le informazioni rilevanti, evitando di dare per scontato che il modello conosca il contesto.

- Delimitare chiaramente l'output atteso → specificare il formato (“Rispondi in JSON”, “Genera un elenco numerato di punti chiave”).
- Usare esempi positivi e negativi → mostrare al modello cosa è corretto e cosa non lo è, aumentando la precisione della risposta.
- Scomporre compiti complessi → formulare prompt passo-passo invece di richiedere un output complesso in un'unica istruzione.

Questi principi sono stati integrati anche nelle pratiche operative di OpenAI, che sottolineano l'importanza di prompt brevi, chiari e non ambigui. Nel nostro progetto, queste linee guida sono state decisive nella progettazione dei prompt multilivello: uno per la profilazione dell'utente, uno per l'estrazione delle competenze, uno per il matching con i codici ISTAT, e infine uno per la generazione di spiegazioni trasparenti.

L'importanza del prompt engineering non è astratta, ma ha applicazioni dirette e concrete nel campo dei sistemi di orientamento professionale. Un modello generico come GPT-4, se lasciato libero, potrebbe fornire risposte troppo generiche o incoerenti. Ma con un prompt ingegnerizzato in modo appropriato, è possibile guidarlo a:

- Estrarre dati strutturati da un CV in linguaggio libero.
- Classificare le competenze secondo codici ufficiali ISTAT.
- Generare spiegazioni passo-passo delle scelte effettuate.
- Proporre percorsi professionali in formato coerente e comparabile.

Queste funzionalità sono decisive perché l'utente non si limita a ricevere una raccomandazione, ma ottiene anche una traccia del processo decisionale. L'uso del Chain-of-Thought o di tecniche iterative può aumentare la spiegabilità, riducendo i rischi di opacità tipici dei modelli di AI.

Inoltre, il prompt engineering si inserisce pienamente nei principi della Responsible AI: non solo efficienza, ma anche trasparenza, affidabilità e rispetto per l'utente. Per un sistema di career counseling, significa fornire non semplici risposte, ma strumenti di comprensione e crescita.

Il prompt engineering, pertanto, si configura come la nuova frontiera dell'interazione con i modelli di linguaggio di grandi dimensioni. Definito da Vatsal e Dubey (2024) come l'arte di comporre istruzioni testuali per guidare i LLM, questo approccio consente di ottenere il massimo dalle capacità dei modelli senza costosi processi di fine-tuning. Tecniche fondamentali come il few-shot prompting e strategie avanzate come il Chain-of-Thought (Wei et al., 2022) mostrano che è possibile controllare non solo l'output finale, ma anche il processo logico che vi conduce.

Le linee guida industriali di Microsoft e OpenAI confermano l'importanza di regole pratiche chiare, contesto, esempi, formati vincolanti che si traducono in benefici concreti per progetti reali. Applicato all'orientamento professionale, il prompt engineering diventa lo strumento chiave per trasformare un LLM generico in un assistente capace di classificare competenze, generare suggerimenti di carriera e spiegare le proprie decisioni.

In prospettiva, il prompt engineering rappresenta la sintesi tra potenza tecnologica e controllo umano: una disciplina che permette di avvicinare l'AI alle esigenze concrete delle persone, garantendo al tempo stesso trasparenza e responsabilità [25,26,27,28].

2.5 Fairness Algoritmica nell'HR Tech e nello User Modeling

L'uso crescente di sistemi di intelligenza artificiale nei processi di selezione del personale, job matching e orientamento professionale solleva interrogativi cruciali sul tema della fairness algoritmica. La promessa di maggiore efficienza e scalabilità si accompagna infatti al rischio che tali sistemi possano riprodurre, o addirittura amplificare, discriminazioni preesistenti nella società. Esempi ormai noti riguardano algoritmi di recruiting che hanno penalizzato sistematicamente candidature femminili, o sistemi di valutazione automatica che hanno associato determinati background culturali a prestazioni inferiori.

Come osservano Purificato, Boratto e De Luca (2024), gran parte delle metriche di fairness nate in ambito di machine learning è stata concepita in scenari binari: si trattava, ad esempio, di confrontare l'esito "assunto/non

assunto” tra due gruppi protetti (es. uomini vs donne). Sebbene utili come punto di partenza, tali metriche risultano inadeguate per contesti complessi come l’HR Tech e lo user modeling, dove le decisioni non sono dicotomiche ma distribuite su una pluralità di classi, e i gruppi di riferimento sono molteplici e intersecati.

L’approccio tradizionale alla fairness algoritmica si fonda su metriche come:

- Statistical Parity Difference → la differenza nelle probabilità di ottenere un certo esito (assunto) tra due gruppi.
- Equal Opportunity → uguaglianza dei tassi di veri positivi tra gruppi (es. stessa probabilità di essere correttamente selezionati se qualificati).
- Disparate Impact/Mistreatment → misure di disparità nelle predizioni errate (falsi positivi o falsi negativi).

Tali metriche, come mostrato da Purificato et al. (2024), sono nate in contesti ristretti: un classificatore binario, due gruppi a confronto, un unico outcome di interesse. La loro applicazione diretta a scenari HR rischia di produrre una semplificazione fuorviante.

Si consideri, ad esempio, un sistema di job recommender che suggerisce posizioni a candidati in base al profilo: la scelta non è mai “assunto/non assunto”, ma un ventaglio di professioni con probabilità diverse.

Analogamente, i gruppi non si riducono a due categorie: genere e età si intersecano con etnia, livello socioeconomico, background formativo, generando combinazioni multiple. Ridurre tutto a un confronto binario significa trascurare la complessità delle interazioni sociali.

Purificato et al. sottolineano come questo problema porti a due conseguenze:

1. Perdita di informazione → l’analisi binaria non cattura disparità distribuite su più classi.

2. Illusione di equità → un sistema può apparire equo secondo una metrica binaria, pur penalizzando costantemente sotto-gruppi non considerati.

Questa critica alla binarizzazione rappresenta il punto di partenza per una riflessione più ampia: se vogliamo sistemi di orientamento professionale equi, dobbiamo superare la logica riduttiva e adottare metriche capaci di rappresentare scenari più realistici.

La proposta avanzata da Purificato et al. (2024) consiste nell'estendere le metriche tradizionali a contesti multiclasse e multigruppo. In particolare, gli autori definiscono e formalizzano misure come:

- Multigroup Statistical Parity (MSP) → valuta se la distribuzione delle predizioni su più classi è equa tra più gruppi protetti.
- Multigroup Equal Opportunity (MEO) → controlla se la probabilità di classificare correttamente un individuo qualificato in una classe desiderata è simile tra gruppi diversi.
- Multigroup Equalized Odds (MEOd) → estende la parità di falsi positivi e falsi negativi oltre il binario, verificando l'uguaglianza delle prestazioni per ciascuna classe e gruppo.

Queste metriche rappresentano un passo avanti fondamentale perché affrontano due dimensioni di complessità:

1. Molteplicità degli outcome → non più un solo esito, ma più categorie (es. “tecnico informatico”, “insegnante”, “infermiere”).
2. Molteplicità dei gruppi → non più due categorie, ma più dimensioni identitarie da considerare simultaneamente (genere, età, etnia, ecc.).

In questo modo, diventa possibile misurare disparità che prima restavano invisibili. Ad esempio, si può scoprire che un sistema di orientamento penalizza le donne over 50 con laurea in discipline umanistiche rispetto ad altri sottogruppi, anche se il confronto aggregato uomini/donne non mostrava differenze significative.

L'importanza di questa estensione metodologica è duplice: da un lato, rende la fairness una nozione più aderente alla complessità sociale; dall'altro, fornisce strumenti concreti per audit e monitoraggio dei sistemi AI applicati all'HR Tech.

L'analisi di Purificato et al. non si limita all'HR Tech, ma si inserisce nel più ampio tema dello user modeling, ossia la costruzione di rappresentazioni computazionali dell'utente per personalizzare raccomandazioni o decisioni.

Anche qui, l'uso di metriche binarie rischia di produrre modelli che ignorano la diversità degli utenti. Considerare solo due categorie (es. utenti "esperti" vs "novizi") trascura sfumature importanti e rischia di penalizzare utenti appartenenti a classi minoritarie. Le metriche multiclasse e multigruppo permettono invece di garantire che la personalizzazione non diventi discriminazione, assicurando che i benefici dell'adattività siano distribuiti equamente.

In applicazioni come l'orientamento professionale, questo significa che il sistema deve saper bilanciare raccomandazioni per utenti con background differenti, senza favorire sistematicamente certi profili a scapito di altri.

Nel contesto HR, la fairness algoritmica non è un tema astratto, ma una questione con impatti diretti:

- Selezione del personale → un algoritmo che penalizza certi gruppi può ridurre la diversità organizzativa e violare principi legali.
- Job recommender systems → suggerimenti distorti possono indirizzare gruppi specifici verso professioni meno remunerative o con minori opportunità di crescita.
- Valutazioni automatizzate → bias impliciti nei dati possono influenzare negativamente performance review o processi di promozione.

Purificato et al. mostrano come le metriche multiclasse siano particolarmente rilevanti nei sistemi di job matching, dove il modello deve

classificare un candidato in più categorie occupazionali. Solo monitorando la distribuzione delle predizioni su più classi e gruppi è possibile garantire che il sistema non produca sistematiche disuguaglianze.

Se il lavoro di Purificato et al. fornisce strumenti metodologici per misurare la fairness, il contributo di Joers e De Luca (2025) amplia la prospettiva introducendo la dimensione del benessere eudaimonico nelle interazioni con la tecnologia.

Gli autori sviluppano l'Eudaimonic Interaction Inventory (EII), uno strumento che misura se l'interazione con un sistema tecnologico promuove valori come autenticità, significato, crescita personale, eccellenza. L'idea di fondo è che un sistema tecnologico non dovrebbe limitarsi a essere “non discriminante”, ma dovrebbe anche contribuire al benessere dell'utente.

Applicato al contesto HR, questo significa che un sistema di orientamento non deve solo evitare bias (fairness formale), ma deve anche garantire che i candidati vivano l'interazione come un'esperienza costruttiva e significativa:

- Trasparenza nelle raccomandazioni.
- Spiegazioni comprensibili delle decisioni.
- Percezione di equità e rispetto.

In altre parole, fairness ed eudaimonia diventano due lati della stessa medaglia: la prima assicura giustizia distributiva, la seconda garantisce che l'interazione abbia un impatto positivo sul percorso personale dell'utente.

Dall'integrazione dei due contributi emergono alcune linee guida fondamentali per la progettazione di sistemi HR Tech equi e responsabili:

1. Dati bilanciati → costruire dataset rappresentativi di diverse categorie demografiche, riducendo squilibri a monte.
2. Metriche multiclasse/multigruppo → adottare strumenti come MSP e MEO per monitorare disparità su più categorie.

3. Audit continui → implementare sistemi di monitoraggio periodico per verificare la persistenza di bias nel tempo.
4. Spiegabilità → fornire agli utenti spiegazioni passo-passo (ad es. tramite tecniche di prompt engineering) per rendere trasparente il processo.
5. Eudaimonic design → progettare interazioni che favoriscano autenticità, significato e crescita, evitando che l'AI diventi un mero filtro opaco.

Il tema della fairness algoritmica nell'HR Tech e nello user modeling richiede di superare le metriche tradizionali e adottare approcci più sofisticati, capaci di rappresentare la complessità dei contesti reali. La proposta di Purificato et al. (2024) di estendere le metriche a scenari multiclasse e multigruppo offre una base metodologica solida per affrontare le disparità nascoste dai modelli binari. Parallelamente, la prospettiva di Joers e De Luca (2025) invita a integrare considerazioni etiche più ampie, legate al benessere eudaimonico degli utenti.

Insieme, questi contributi indicano che la fairness non è solo una questione di numeri e metriche, ma anche di esperienza umana. Nei sistemi di orientamento professionale, ciò significa creare soluzioni che siano al tempo stesso tecnicamente eque ed eticamente significative, capaci di garantire pari opportunità e di promuovere scelte lavorative autentiche e consapevoli [3,4].

CAPITOLO 3: Progettazione del Sistema

3.1 Architettura Generale del Sistema

L'architettura di Career Compass AI nasce dall'esigenza di tradurre un input non strutturato - il racconto dell'utente su competenze, esperienze, aspirazioni - in un output strutturato, trasparente e collegato al mondo reale del lavoro. La sfida non è solo tecnica, ma anche epistemologica: come trasformare un testo libero, ricco di ambiguità e sfumature, in classificazione professionali fondate su criteri oggettivi, spiegabili e ancorati a tassonomie ufficiali?

Per rispondere a questa domanda, il sistema adotta un'architettura a pipeline modulare, ispirata ai principi della progettazione software moderna: disaccoppiamento delle responsabilità, scalabilità, manutenibilità e possibilità di sostituire singole componenti senza dover riprogettare l'intero ecosistema. Ogni modulo della pipeline ha un ruolo chiaro e autonomo, ma contribuisce al processo complessivo di analisi e raccomandazione.

La filosofia di fondo non è quella della "black box" che restituisce un risultato finale opaco, ma di una catena di agenti e servizi specializzati, orchestrati per arricchire progressivamente l'informazione, dal testo grezzo fino al report di orientamento professionale. Ogni passaggio è tracciabile e ancorato a classificazioni standardizzate (ISTAT CP2021, API INAPP), così da garantire rigore, confrontabilità e aderenza al contesto socio-economico reale.

La spina dorsale del sistema non è un unico modello monolitico, ma un ecosistema che integra:

- interfacce utente e validazione iniziale;
- agenti LLM specializzati per compiti distinti (estrazione competenze, classificazione, ranking, audit etico);
- servizi esterni via API per arricchire i dati;
- meccanismi di fallback basati su knowledge base locali;

- algoritmi di scoring quantitativo e ranking qualitativo;
- moduli di output con JSON strutturato e spiegabile.

Questo approccio modulare rende l'architettura non solo più robusta, ma anche più aperta all'evoluzione futura: si possono introdurre nuove API (es. banche dati salariali, portali di offerte di lavoro, concorsi collegati alle professioni suggerite all'utente) o nuovi agenti LLM (es. per valutazioni psicometriche) senza compromettere la pipeline principale.

La visione architetturale complessiva del sistema Career Compass AI può essere vista come una catena unidirezionale di elaborazione, con punti di arricchimento e controllo. Il flusso dati parte dall'input utente attraversa moduli di validazione, estrazione e arricchimento, passa per fasi di scoring e ranking e si conclude con la generazione di un output strutturato.

La sequenza logica segue sette stadi fondamentali:

1. Input utente → raccolta di un testo libero tramite interfaccia Streamlit.
2. Validazione e aggregazione → controllo di sufficienza e qualità dell'input (evitando testi troppo brevi, incompleti o non pertinenti).
3. Estrazione e standardizzazione → trasformazione del testo in competenze codificate secondo tassonomie ISTAT/INAPP.
4. Arricchimento dati via API INAPP → recupero delle professioni associate alle competenze; fallback su knowledge base locale.
5. Filtro e scoring quantitativo → riduzione e ordinamento preliminare della lista di professioni.
6. Ranking qualitativo e audit di fairness → valutazione semantica e controllo etico dei suggerimenti.
7. Aggregazione finale e output → generazione di un JSON con raccomandazioni, motivazioni e audit, mostrato all'utente.

Il principio guida è la progressiva raffinazione: a ogni stadio l'informazione diventa più strutturata, più pertinente e più spiegabile.

Il diagramma architetturale del sistema, che sarà rappresentato graficamente in seguito, può essere descritto come una pipeline lineare arricchita da cicli di controllo e fallback.

- Input Utente (Streamlit) → il punto di ingresso della pipeline.
- Modulo LLM (agenti specializzati) → validazione, estrazione competenze, classificazione macro-aree, ranking qualitativo, audit etico.
- Modulo API INAPP → interfaccia con servizi esterni, arricchimento delle competenze in professioni, fallback su `profession_data.py`.
- Modulo Scoring e Ranking → riduzione e ordinamento quantitativo delle professioni (le migliori 40).
- Output → aggregazione e formattazione finale (JSON per la manipolazione dei dati in output + frontend user friendly streamlit).

Il flusso dei dati all'interno di Career Compass AI può essere descritto come un processo progressivo di arricchimento dell'informazione. Tutto inizia con l'input utente, che viene inserito in forma di testo libero attraverso l'interfaccia Streamlit. Questo primo contributo non viene però inoltrato direttamente al sistema: viene sottoposto a una fase preliminare di validazione, gestita da un agente LLM che ne verifica la completezza e la sufficienza, così da assicurare che solo contenuti adeguati proseguano nella pipeline.

Superata la validazione, il testo passa al modulo di estrazione delle competenze, dove un ulteriore agente LLM traduce le informazioni contenute nell'input in insiemi strutturati di abilità hard e soft, già mappate secondo i codici delle tassonomie ufficiali. A questo punto entra in gioco un agente dedicato alla classificazione generale, che identifica le macro-aree professionali ISTAT più rilevanti, così da fornire un contesto utile alle fasi successive.

Le competenze standardizzate vengono quindi inviate al modulo API INAPP, che arricchisce i dati collegandoli a professioni reali. Qualora le API non

fossero disponibili o non restituissero risultati soddisfacenti, interviene un meccanismo di fallback basato sulla knowledge base locale (profession_data.py), garantendo così la continuità del processo.

La lista di professioni ottenuta è inizialmente molto ampia e necessita di un filtraggio. Qui interviene il modulo di scoring quantitativo, che seleziona le posizioni più pertinenti e accessibili, riducendo l'elenco a un numero gestibile di opzioni. Su questa base agisce l'agente di ranking qualitativo, che valuta semanticamente la coerenza tra il profilo dell'utente e le professioni candidate, simulando il giudizio di un esperto di orientamento.

Prima della presentazione dei risultati, la pipeline prevede un ulteriore passaggio: l'audit etico. Un agente LLM specializzato controlla che le raccomandazioni non introducano bias sistematici a danno di particolari categorie di utenti, ad esempio in base a genere, età o background.

Infine, tutte le informazioni vengono raccolte nel modulo di output, che aggrega competenze, professioni suggerite, motivazioni del ranking e risultati dell'audit in un unico oggetto JSON. Questo report finale viene trasmesso al frontend Streamlit, dove l'utente può visualizzare i risultati in forma chiara, trasparente e interattiva.

Ogni freccia rappresenta un passaggio unidirezionale, ma con due punti di controllo importanti:

- Fallback (in caso di fallimento API → knowledge base locale (profession_data.py)).
- Audit etico (controllo intelligente tramite LLM della fairness).

Di seguito il codice utilizzato su Mermaid per la rappresentazione schematica dell'architettura:

graph TD

subgraph "Frontend (app_streamlit.py)"

A("Input Utente")

end

```

subgraph "Backend (backend_analysis.py)"
    B("Modulo LLM <br> <i>Agenti AI Specializzati</i>")
    C{"Modulo API INAPP <br> <i>Accesso Dati Esterni</i>"}
    D("Database Locale <br> <i>profession_data.py</i>")
    E("Modulo di Scoring/Ranking <br> <i>Filtro e Ponderazione</i>")
    F("Modulo di Output <br> <i>Aggregatore Risultati</i>")
end

G("Visualizzazione Risultati <br> <i>(Report su Streamlit)</i>")

%% Flusso dei Dati e Interazioni

A -- "1. Testo libero dell'utente" --> B;
B -- "2. Validazione OK" --> A;
A -- "3. Testo validato e aggregato" --> B;

B -- "4. Codici competenze (es. B01, C02)" --> C;
C -- "5. Chiamate API parallele" --> C;
C -. ->|"5a. Fallback in caso di errore"| D;

C -- "6. Dati professionali grezzi" --> E;
D -- "6a. Dati locali (se fallback)" --> E;

E -- "7. Lista professioni candidate (Top 40)" --> B;

```

B -- "8. Ranking qualitativo e Fairness Audit" --> B;

B -- "9. Risultati finali (Top 5 + Audit)" --> F;

F -- "10. JSON finale per il Frontend" --> G;

%% Stile dei Nodi

style A fill:#e7f0fa,stroke:#bce0ff,stroke-width:2px

style B fill:#f1f3f5,stroke:#adb5bd,stroke-width:2px

style C fill:#fff3cd,stroke:#ffeeba,stroke-width:2px

style D fill:#d4edda,stroke:#c3e6cb,stroke-width:2px

style E fill:#f8d7da,stroke:#f5c6cb,stroke-width:2px

style F fill:#d1ecf1,stroke:#bee5eb,stroke-width:2px

style G fill:#e2e3e5,stroke:#d6d8db,stroke-width:2px

Rappresentazione grafica dell'architettura eseguita tramite Mermaid:




Figura 6 - Architettura del prototipo Career Compass AI: flusso dati dalla validazione dell'input utente all'output finale con ranking e audit di fairness.¹¹

Di seguito viene proposta una breve descrizione dei moduli architetturali:

Modulo Input

Realizzato con Streamlit (app_streamlit.py), funge da porta di accesso al sistema. Non si limita a raccogliere il testo, ma gestisce un'interazione dialogica, facilitando l'utente nella formulazione dell'input. Include meccanismi di validazione minima, ad esempio verificando che il testo non sia vuoto e superi una soglia di lunghezza all'interno della text area predisposta all'inserimento dell'input testuale. Questo modulo agisce come gatekeeper: solo input di qualità sufficiente entrano nella pipeline, riducendo sprechi di risorse computazionali.

Modulo LLM

È il cervello cognitivo del sistema, ma non in senso monolitico. È composto da agenti specializzati, ognuno con un prompt dedicato, orchestrati nel file backend_analysis.py.

Gli agenti principali sono:

- Agente di Validazione → valuta la sufficienza dell'input.
- Agente di Estrazione Competenze → traduce il linguaggio naturale in codici ISTAT/INAPP, generando anche una motivazione (explainability).
- Agente di Classificazione Generale → individua le macro-aree professionali pertinenti.
- Agente di Ranking Qualitativo → simula il giudizio di un orientatore professionale, applicando criteri semantici e contestuali.

¹¹ Le rappresentazioni grafiche degli algoritmi sono state prodotte con l'ausilio dell'editor online Mermaid Live, disponibile all'indirizzo <https://mermaid.live/>.

- Agente di Audit Etico → verifica la fairness dei suggerimenti, segnalando possibili bias (es. penalizzazioni per età/genere).

Questo disaccoppiamento rende l'architettura flessibile e scalabile: ogni agente può essere aggiornato o sostituito senza intaccare gli altri, il che rende il codice facilmente migliorabile ogni agente ha il suo compito ben distinto e insieme agli altri sinergicamente contribuisce alla generazione di un output “giustificato” per l'utente.

Modulo API INAPP

Ponte tra il profilo utente astratto e il mondo del lavoro concreto mappato da ISTAT. Interroga le API ufficiali INAPP per ottenere liste di professioni associate ai codici ISTAT dei lavori.

Due caratteristiche chiave:

- Resilienza → se le API falliscono, interviene un meccanismo di fallback basato sul file `profession_data.py`, che contiene tutte le professioni al terzo digit della classificazione ISTAT.
- Performance → le chiamate API, tendenzialmente lente, vengono parallelizzate tramite un pool di thread, riducendo la latenza complessiva.

Modulo Scoring e Ranking

Riceve centinaia di professioni candidate e le riduce a una lista gestibile. Applica un algoritmo di scoring quantitativo, che pondera:

- Pertinenza semantica.
- Accessibilità della professione (livello di complessità, possibilità di ingresso).
- Allineamento con le macro-aree individuate dall'agente LLM.

Il risultato è una lista di professioni, successivamente sottoposte al ranking qualitativo.

Modulo Output

Responsabile della raccolta finale. Aggrega i risultati dei moduli precedenti in un oggetto JSON strutturato, che include:

- Lista di professioni raccomandate.
- Competenze estratte.
- Motivazioni del ranking.
- Audit etico.

Questo JSON viene poi inviato al frontend Streamlit per la visualizzazione interattiva.

Un pilastro fondamentale dell'architettura è rappresentato dall'integrazione con le tassonomie ufficiali, in particolare la classificazione ISTAT CP2021 e le API INAPP. L'adozione di queste strutture non è soltanto una scelta tecnica, ma risponde all'esigenza di collocare il sistema all'interno di un quadro condiviso e riconosciuto a livello istituzionale. Le tassonomie forniscono infatti un linguaggio comune, che permette di ancorare le raccomandazioni a un vocabolario standardizzato utilizzato da istituzioni come ISTAT. In questo modo, le informazioni generate non restano confinate all'interno dell'applicazione, ma possono eventualmente essere facilmente confrontate e integrate in contesti più ampi.

Oltre a garantire interoperabilità, i codici ISTAT offrono un fondamento solido per la spiegabilità. Ogni professione non è soltanto un'etichetta, ma un nodo collocato all'interno di una gerarchia che ne definisce relazioni, appartenenze e descrizioni dettagliate. Questo consente al sistema di motivare le proprie scelte in maniera trasparente: quando una raccomandazione viene prodotta, può essere collegata a una categoria ben definita, facilitando la comprensione del percorso logico che ha condotto a quel risultato.

Infine, le tassonomie agiscono da veri e propri abilitatori per sistemi intelligenti. I codici ISTAT, infatti, non svolgono soltanto la funzione di vincoli per input e output, ma rappresentano anche un punto di partenza per l'arricchimento delle informazioni. Attraverso questi riferimenti

standardizzati, il sistema può collegarsi a fonti esterne, come banche dati salariali, percorsi formativi o portali di offerte di lavoro, ampliando così la portata e l'utilità delle raccomandazioni fornite all'utente.

In parole povere l'architettura di Career Compass AI può essere sintetizzata come un ecosistema modulare che integra AI generativa, knowledge base ufficiali e servizi esterni, garantendo:

- Manutenibilità (moduli disaccoppiati).
- Scalabilità (possibilità di integrare nuove API o agenti).
- Trasparenza (spiegabilità via codici ISTAT e motivazioni testuali).
- Fairness (audit etico integrato tramite llm specializzato).

Un aspetto che merita una parola di approfondimento riguarda i temi della trasparenza e della fairness. La visione architetturale qui delineata non rappresenta soltanto una scelta tecnica, ma si configura come una prima dichiarazione metodologica: una tecnologia potente come quella degli LLM non deve generare risultati opachi o ingiustificabili, bensì deve essere progettata in modo da produrre output responsabili e spiegabili. I prossimi passi in questa direzione saranno affrontati nel capitolo dedicato agli sviluppi futuri [8,9,10,11].

3.2 Fonti di Dati Utilizzate

La solidità di un sistema di questo sistema di orientamento professionale basato su intelligenza artificiale non dipende soltanto dalla qualità degli algoritmi o dalla potenza dei modelli di linguaggio, ma si fonda anche sulla ricchezza e affidabilità delle fonti di dati che esso utilizza. Career Compass AI integra in modo coerente due tipologie di risorse: da un lato, un insieme di file JSON locali (attitudini.json, attivita_generalizzate.json, conoscenze.json, skills.json), derivati e organizzati a partire dalle tassonomie ufficiali; dall'altro, le API INAPP, che permettono di interrogare dinamicamente il canale ufficiale per la diffusione dei dati e dei metadati in formato machine readable, dell'Istituto per le Analisi e le Politiche Pubbliche. A queste si aggiunge un ulteriore elemento cruciale, il file

profession_data.py, che contiene l'intera classificazione ISTAT al terzo digit e funge da fallback quando i servizi esterni non sono disponibili o non restituiscono risposte pertinenti.

Questa combinazione di dati statici e dati dinamici rappresenta un compromesso virtuoso: i JSON locali garantiscono stabilità, controllo e immediatezza di accesso, mentre le API INAPP forniscono aggiornamento e collegamento diretto con le fonti istituzionali. Il fallback basato su profession_data.py assicura, infine, la resilienza del sistema, evitando che l'utente si trovi di fronte a un blocco in caso di problemi con i servizi remoti.

I file JSON presenti nella cartella dedicata costituiscono il vocabolario controllato su cui si appoggia la pipeline di analisi. La loro origine va ricondotta alla classificazione ISTAT CP2021 e agli adattamenti operati da INAPP per la rappresentazione delle competenze. In particolare, i quattro file principali sono:

conoscenze.json → include il repertorio delle conoscenze teoriche e pratiche, codificate con prefisso B. Un esempio tipico è il codice B10, associato a “Ingegneria e tecnologia”.

skills.json → raccoglie le competenze operative e applicative, codificate con prefisso C. Ad esempio, C12 corrisponde a “Adattabilità”.

attivita_generalizzate.json → descrive le attività lavorative generiche e trasferibili, con prefisso G. Un caso rappresentativo è G15, “Organizzare, pianificare e dare priorità al lavoro”.

attitudini.json → contiene le disposizioni personali e i tratti comportamentali rilevanti in ambito lavorativo, con prefisso D. Ad esempio, D6 è associato a “Originalità”.

Tutti questi file condividono una struttura a coppie chiave–valore, in cui la chiave è il codice alfanumerico ufficiale e il valore è la descrizione testuale della conoscenza, competenza, attività o attitudine. Ad esempio:

```
{
```

```
"B1": "Impresa e gestione di impresa",  
"B2": "Lavoro d'ufficio",  
"B3": "Economia e contabilità",  
"B4": "Commercializzazione e vendita",  
...  
}
```

Questa struttura semplice e standardizzata garantisce facilità di parsing da parte del backend (`backend_analysis.py`); immediata interpretabilità per gli agenti LLM, che vengono istruiti a mappare il testo libero dell'utente sui codici presenti; allineamento diretto con la tassonomia ISTAT, evitando l'introduzione di categorie spurie o arbitrarie.

All'interno della pipeline, i file JSON non si limitano a fornire un elenco di categorie, ma svolgono un ruolo essenziale sotto diversi aspetti. In primo luogo, agiscono come vincolo lessicale, impedendo al modello di generare etichette arbitrarie o non riconducibili a standard condivisi: ogni estrazione deve necessariamente riferirsi a una categoria predefinita. In secondo luogo, garantiscono un livello di standardizzazione, poiché tutte le informazioni individuate nel testo utente vengono tradotte in codici uniformi, compatibili con altri sistemi informativi e facilmente integrabili in processi esterni. Infine, i JSON contribuiscono alla spiegabilità delle raccomandazioni: l'uso di codici ufficiali permette infatti di collegare ogni suggerimento a una descrizione verificabile, rendendo più trasparente il percorso che ha portato a quel risultato. In sintesi, i JSON locali costituiscono la vera e propria base ontologica del sistema: senza di essi, l'LLM rischierebbe di produrre output vaghi, non confrontabili e di scarsa utilità in un contesto applicativo reale.

Se i JSON locali forniscono stabilità, le API INAPP rappresentano la componente dinamica e aggiornata dell'architettura. Attraverso queste interfacce, Career Compass AI interroga in tempo reale il sistema informativo nazionale sulle professioni gestito da INAPP, ottenendo informazioni sulle occupazioni collegate a specifiche competenze, attività o attitudini.

Dal codice di backend emerge che il sistema sfrutta principalmente l'endpoint:

<https://api.inapp.org/professioni/search.php> , a cui vengono passati parametri diversi a seconda del tipo di ricerca. Necessaria per ricercare ricorsivamente il codice ISTAT associato al lavoro di interesse.

Le risposte delle API sono restituite in formato JSON e includono tipicamente:

- codice ISTAT della professione (che arriva a foglia al più cinque digit);
- descrizione testuale della professione;
- eventuali collegamenti a descrizioni estese o a ulteriori competenze richieste.

Le API INAPP svolgono un ruolo di arricchimento: partendo dalle competenze estratte dai JSON locali, permettono di risalire alle professioni concrete in cui quelle competenze trovano applicazione. In questo modo, il sistema collega l'universo astratto delle skill ai lavori censiti da ISTAT, garantendo che i suggerimenti non siano soltanto coerenti sul piano teorico, ma anche utili e spendibili per l'utente.

Un elemento distintivo del sistema è la presenza di un meccanismo di fallback basato sul file `profession_data.py`. Questo file di input contiene una costante che rappresenta un dizionario JSON con l'elenco completo delle professioni ISTAT al terzo digit.

Ogni chiave del dizionario corrisponde a un codice numerico al terzo livello della classificazione ISTAT CP2021. A ciascun codice sono associati ulteriori campi che ne arricchiscono il significato. In particolare, per ogni terzo digit vengono riportati: il nome della categoria professionale, una descrizione breve e una descrizione estesa, alcuni esempi di professioni appartenenti a quella categoria, nonché un campo che indica la formazione generalmente richiesta e il settore di mercato in cui la professione trova più frequentemente applicazione.

La funzione principale di `profession_data.py` è quella di garantire la resilienza del sistema. Quando le chiamate alle API INAPP non sono disponibili (ad esempio per problemi di connessione o limiti di utilizzo), la pipeline non si interrompe: invece, consulta questa costante locale e restituisce comunque un insieme di professioni affidabile e conforme agli standard.

In questo modo, l'utente non si trova mai di fronte a un "vuoto di risposta": la qualità dei dati può variare (aggiornati via API o statici via fallback), ma la continuità del servizio è sempre garantita.

Il vero valore dei dati in input non risiede nell'uso isolato di queste risorse, ma nella loro integrazione sinergica:

- I JSON locali offrono una base stabile e controllata per la mappatura delle competenze.
- Le API INAPP arricchiscono dinamicamente i risultati, collegando competenze e attività a professioni aggiornate.
- Il fallback `profession_data.py` assicura continuità operativa, colmando eventuali lacune delle API.

Questa combinazione consente al sistema di bilanciare precisione e aggiornamento, robustezza e flessibilità. L'utente finale percepisce un servizio coerente, in cui le raccomandazioni non solo riflettono il proprio profilo, ma sono anche ancorate a fonti istituzionali e affidabili.

Le fonti di dati utilizzate da Career Compass AI non sono un elemento accessorio, ma rappresentano la spina dorsale dell'architettura. I JSON locali, le API INAPP e il file di fallback `profession_data.py` formano un ecosistema che permette di coniugare stabilità, aggiornamento e resilienza [8].

3.3 Modulo di Profilazione Utente basato su LLM e Recupero Professioni

Il primo passaggio cruciale della pipeline di Career Compass AI è la profilazione dell'utente. Questo modulo si occupa di trasformare una serie di messaggi informali e disordinati, tipici di chi descrive il proprio percorso professionale senza vincoli strutturali, in un profilo standardizzato e

interpretabile, arricchito successivamente con una prima lista di professioni candidate. È qui che avviene la transizione dal linguaggio naturale al linguaggio delle tassonomie ufficiali.

L'architettura adottata combina due approcci complementari. Da un lato, un modulo LLM multi-agente, che analizza semanticamente il testo e ne estrae significati latenti, competenze e attitudini; dall'altro, un meccanismo di recupero basato su API e database locali, che utilizza le informazioni estratte per restituire un primo elenco di professioni pertinenti. Il risultato è un approccio ibrido che supera i limiti della semplice ricerca per parole chiave e sfrutta le capacità degli LLM per produrre una classificazione nel dominio dei lavori censito da ISTAT robusta e verificabile.

La scelta metodologica alla base del modulo di profilazione riflette la necessità di bilanciare flessibilità semantica e rigore ontologico. Se da un lato il racconto di un utente può contenere descrizioni sfumate (“mi piace lavorare con i numeri”, “ho esperienza nel coordinare team”), dall'altro il sistema deve ricondurre queste espressioni a categorie strutturate e standardizzate, come quelle definite da ISTAT e INAPP.

Per questo motivo, il modulo non si limita a una semplice ricerca lessicale di keyword, che rischierebbe di essere superficiale e poco adattabile. Al contrario, impiega un modello di linguaggio di grandi dimensioni orchestrato tramite agenti specializzati. Ognuno di questi agenti è invocato con un prompt mirato e ha un compito distinto: validare l'input, estrarre le competenze, individuare le attitudini, classificare l'utente in macro-aree, motivare le scelte. Questa frammentazione delle responsabilità garantisce che ogni parte del processo sia ottimizzata e controllata, riducendo al minimo le ambiguità.

Una volta costruito il profilo semantico, interviene la fase di recupero delle professioni, che utilizza le informazioni codificate per interrogare le API INAPP. In questo modo, le skill e le attività non restano concetti astratti, ma vengono immediatamente tradotte in occupazioni reali. La combinazione dei due passaggi, profilazione e recupero, produce un output intermedio: una

lista grezza di professioni candidate, che costituirà la base per i moduli successivi di ranking e audit.

la funzione `select_best_categories` è un elemento fondamentale del modulo di profilazione, implementata in `backend_analysis.py`. Questa funzione riceve il testo libero inserito dall'utente e lo sottopone a un agente LLM con un prompt mirato. L'LLM ha il compito di mappare le affermazioni contenute nel testo su un vocabolario controllato, rappresentato dai file JSON locali (`conoscenze.json`, `skills.json`, `attivit _generalizzate.json`, `attitudini.json`). La funzione come le successive che verranno richiamate per spiegare ad alto livello il seguente modulo verranno analizzate nel dettaglio nel capitolo successivo, dedicato alla descrizione dell'implementazione del progetto Career Compass.

Il vincolo imposto dai JSON è essenziale, invece di generare liberamente etichette arbitrarie, l'LLM deve selezionare tra quelle disponibili. Questo processo riduce drasticamente l'ambiguit  e assicura che ogni estrazione abbia un risultato verificabile. Ad esempio, se l'utente scrive "mi piace programmare software", il modello non si limita a restituire la frase cos  com' , ma la traduce nel codice corrispondente del file `skills.json`, ad esempio C22 - Competenze di programmazione informatica.

Un elemento di particolare valore aggiunto   l'aspetto della spiegabilit . La funzione `select_best_categories` non restituisce solo i codici selezionati, ma anche una reason, ovvero una motivazione testuale che collega il codice a un passaggio preciso del racconto dell'utente. Questo significa che il sistema non solo classifica, ma giustifica le proprie scelte. Ad esempio, alla selezione di B14 - Conoscenze matematiche, l'LLM pu  associare la motivazione: "L'utente ha scritto di aver seguito corsi avanzati di statistica".

Questo meccanismo costituisce un punto di forza enorme rispetto ai sistemi tradizionali: l'utente pu  comprendere come e perch  le proprie parole abbiano portato a certe raccomandazioni, aumentando la fiducia e la percezione di equit  del processo.

La profilazione non si ferma all'estrazione di competenze e attitudini puntuali. Un ulteriore passo è affidato alla funzione `classify_user_category`, che astrae il profilo a un livello superiore, collocandolo nelle macro-categorie ISTAT. Questo filtro strategico permette di limitare il ventaglio delle professioni candidate alle sole aree effettivamente pertinenti. In termini architetturali, si tratta di una prima forma di pre-filtraggio semantico, che aumenta l'efficienza delle fasi successive e riduce il rischio di suggerimenti fuori contesto.

Una volta completata la profilazione semantica, il sistema dispone di un profilo strutturato: un insieme di codici di competenze, attitudini e attività, accompagnati da motivazioni. Questo profilo costituisce la base per la fase successiva, dedicata al recupero delle professioni.

Il percorso primario di recupero utilizza le API INAPP per arricchire il profilo con professioni reali. Il ciclo implementato in `backend_analysis.py` invoca le funzioni `chiamata_api` e `get_explicit_professions`, che a loro volta interrogano l'endpoint di INAPP con parametri differenti.

Grazie alla libreria `concurrent.futures`, le chiamate sono eseguite in parallelo, ottimizzando i tempi di risposta e garantendo che l'utente non debba attendere a lungo per ottenere i primi risultati. Le API restituiscono liste di professioni con codice ISTAT e descrizione, che vengono aggregate in un set preliminare.

Non sempre, però, i servizi esterni sono disponibili e pertanto è necessario implementare un paracadute in questa situazione: infatti il sistema integra un meccanismo di resilienza basato sulla funzione `find_professions_locally_as_fallback`. In caso di fallimento delle API, questa funzione confronta direttamente il profilo utente con la base dati locale contenuta in `profession_data.py`.

Questo file include una costante che rappresenta l'intero repertorio delle professioni ISTAT al terzo digit, con descrizioni, esempi e dettagli. In tal modo, anche in assenza di API, il sistema è in grado di restituire un elenco coerente di occupazioni. Pur mancando l'aggiornamento dinamico garantito

dalle chiamate remote, il fallback assicura continuità di servizio e mantiene l'aderenza agli standard ufficiali.

Possiamo concludere che il modulo di profilazione utente basato su LLM e recupero professioni rappresenta dunque la spina dorsale della pipeline di Career Compass AI. Attraverso la combinazione di analisi semantica, vocabolario controllato, motivazioni testuali, classificazione macro e arricchimento via API/fallback, esso trasforma il racconto libero di un utente in un set strutturato e spiegabile di professioni candidate.

La forza di questo approccio risiede nella sua natura ibrida: non si limita a interpretare il testo, ma lo ancora a codici ufficiali; non dipende esclusivamente da servizi esterni, ma integra un database locale di fallback; non restituisce semplici etichette, ma fornisce motivazioni testuali. È proprio questa architettura a garantire che il sistema non si riduca a un esercizio di text mining, ma si configuri come un vero e proprio strumento di orientamento responsabile, trasparente e ancorato alla realtà di classificazioni lavorative ufficiali [8].

3.4 Modulo di Ranking Finale basato su LLM

La fase conclusiva della pipeline di Career Compass AI è dedicata al ranking qualitativo delle professioni candidate. Dopo che l'utente ha fornito il proprio racconto e il sistema ha costruito un profilo strutturato, la pipeline restituisce una lista preliminare di circa 40 professioni compatibili. Tuttavia, un insieme così ampio risulta di difficile interpretazione e rischia di ridurre l'utilità pratica dello strumento. È quindi necessario un ulteriore passaggio di affinamento, che selezioni soltanto le 5 professioni più pertinenti, accompagnandole da motivazioni chiare e da una valutazione etica.

Dal punto di vista qualitativo è presente un approccio a due stadi. Il modulo di ranking finale si fonda su un approccio a due stadi. In un primo momento viene applicato un pre-filtraggio quantitativo, che ordina le professioni candidate in base a parametri oggettivi (importanza, complessità). In un secondo momento, la lista così ordinata viene sottoposta a un agente LLM

specializzato, incaricato di valutare semanticamente la coerenza tra il profilo utente e le descrizioni delle professioni.

Questa architettura mista consente di sfruttare sia la precisione numerica dei punteggi quantitativi sia la capacità interpretativa degli LLM, ottenendo un equilibrio tra efficienza algoritmica e giudizio qualitativo.

La prima fase di raffinamento è implementata dalla funzione `aggregate_best_jobs`. Questo componente riceve i risultati aggregati dalle API INAPP e calcola, per ciascuna professione, un punteggio numerico complessivo.

Il punteggio è calcolato combinando diversi fattori:

- la pertinenza rispetto alle categorie estratte dal profilo utente;
- i valori di importanza e complessità forniti dalle API;
- una logica di ponderazione che privilegia le professioni accessibili, riducendo il peso di quelle con importanza e complessità eccessivamente elevate.

Il risultato è una lista ordinata di circa 40 professioni, che rappresentano il sottoinsieme più promettente da sottoporre a un'analisi qualitativa successiva.

La fase più rilevante è quella affidata alla funzione `rank_professions`, che invia la lista dei 40 candidati a un agente LLM con un prompt mirato. Il compito di questo agente non è soltanto ordinare, ma simulare il giudizio di un esperto di orientamento professionale.

Il modello riceve in input sia il racconto originale dell'utente sia la lista delle professioni con i loro metadati. A ciascuna professione assegna un `relevance_score` compreso tra 1 e 10 e produce una motivazione testuale (reason) fondamentale per spiegare il suo ragionamento e quindi giustificare la valutazione. In questo modo, il sistema non solo restituisce un ordine, ma anche una spiegazione leggibile che permette all'utente di comprendere il percorso logico seguito.

Un aspetto cruciale è l’inserimento di regole etiche nel prompt, l’agente è istruito a ignorare fattori come genere o età, a non penalizzare profili NEET e a valorizzare il potenziale espresso, non soltanto le esperienze pregresse. Inoltre, vengono escluse professioni che richiedono esplicitamente attività di insegnamento o ricerca se l’utente non ha manifestato interesse in tale direzione o comunque non ha dichiarato un percorso di studi, un utente che ha concluso un percorso di studi universitario tenderà a farlo presente.

Il risultato finale di questa fase è una lista ridotta alle 5 professioni più pertinenti, ciascuna accompagnata da:

- codice ISTAT;
- descrizione testuale;
- punteggio di pertinenza (0.0–1.0, scalato dal `relevance_score`);
- motivazione esplicita.

Il ranking qualitativo non costituisce l’ultimo passaggio. La funzione `perform_fairness_audit` introduce una fase aggiuntiva di verifica etica, coerente con i principi di Responsible AI cercando di evitare alcuni tipi di bias.

Ogni professione selezionata viene analizzata da un secondo agente LLM, specializzato in etica e fairness algoritmica. Questo agente ha il compito di valutare se la professione possa comportare bias o barriere d’accesso per specifici sottogruppi (ad esempio, giovani under 25, lavoratori over 50, donne in ruoli tecnici, candidati provenienti da background socio-economici svantaggiati).

L’output dell’audit è un JSON che riporta:

- un riassunto dei bias potenziali;
- i sottogruppi coinvolti;
- una motivazione esplicativa.

Questa fase non modifica il ranking, ma lo arricchisce con un livello di trasparenza ulteriore, permettendo all'utente di essere consapevole delle eventuali criticità sistemiche legate alle professioni suggerite.

Il modulo di ranking finale pertanto rappresenta il passaggio più sofisticato della pipeline di Career Compass AI. Attraverso un approccio a due stadi - quantitativo e qualitativo - il sistema riduce l'ampiezza della lista preliminare a un set ristretto di professioni pertinenti, spiegate e sottoposte a verifica etica.

Questo garantisce che l'output non sia un semplice elenco di opportunità, ma un insieme ragionato, giustificato e responsabile di suggerimenti professionali. La combinazione di scoring numerico, giudizio semantico e audit di fairness conferisce al sistema un livello di affidabilità superiore, trasformandolo in uno strumento di orientamento che coniuga rigore tecnico e sensibilità sociale [8].

3.5 Modulo di Identificazione Professioni Affini

Un sistema di orientamento professionale non può limitarsi a indicare un'unica risposta, quasi fosse un destino prestabilito. La realtà del lavoro è dinamica, e spesso i percorsi professionali non seguono linee rette ma traiettorie fatte di deviazioni, esplorazioni e cambi di ruolo. Per questa ragione, Career Compass AI include un modulo opzionale per l'identificazione delle professioni affini, pensato per aprire nuove prospettive e offrire all'utente un ventaglio di opportunità correlate ai suggerimenti principali.

Il concetto alla base del modulo è quello di esplorazione guidata. Un buon orientatore professionale (umano o artificiale) non si limita a fornire una sola raccomandazione, ma incoraggia il soggetto a valutare anche percorsi alternativi e vicini. Questo approccio risponde a due esigenze fondamentali:

- **Flessibilità:** il mercato del lavoro è in costante evoluzione, e una professione oggi in crescita potrebbe domani ridursi. Offrire professioni affini consente all'utente di avere sempre una "seconda scelta" plausibile.

- Personalizzazione: non tutti i candidati si riconoscono nella professione raccomandata come prima opzione; vedere ruoli simili può stimolare nuove idee e favorire un orientamento più consapevole.

Il modulo delle professioni affini si basa sull'idea di ampliare l'orizzonte di professioni possibili, trasformando il sistema da strumento prescrittivo a compagno di esplorazione.

Dal punto di vista implementativo, esistono diversi approcci per identificare professioni affini. Nel backend attuale il sistema fa riferimento su un'affinità tassonomica: due professioni sono considerate affini se appartengono alla stessa famiglia ISTAT o se condividono gran parte del percorso gerarchico fino al terzo digit.




Figura 7 - Visualizzazione dei percorsi professionali correlati suggeriti dal prototipo Career Compass AI a partire dal profilo utente.¹²

Come si evince dall'immagine si mantiene coerenza con le tassonomie ufficiali le affinità non sono arbitrarie, ma basate su codici ISTAT.

¹² Screen test prototipo. Sviluppato da A. Baragona

[https://github.com/Alessandro765/TESI_MAGISTRALE_BARAGONA]

Dal punto di vista dell'utente, il modulo delle professioni affini ha una funzione cruciale: incoraggiare l'esplorazione di percorsi alternativi. Le ragioni principali sono almeno tre:

- Gestione dell'incertezza: chi si trova in una fase di transizione (ad esempio un NEET o un lavoratore in riconversione) può non avere ancora chiaro il proprio obiettivo. Offrire opzioni vicine aumenta le possibilità di identificare un percorso realistico.
- Formazione continua: professioni affini possono indicare aree in cui piccoli investimenti formativi aggiuntivi (es. un corso di formazione in linea con le aspirazioni dell'utente) aprono a nuove opportunità lavorative.
- Mobilità professionale: in un mercato sempre più fluido, sapere che dal ruolo A è facile spostarsi al ruolo B rappresenta un'informazione di grande valore strategico.

L'integrazione delle professioni affini permette quindi di trasformare Career Compass AI in uno strumento che non solo assegna un "match" immediato, ma supporta la pianificazione dinamica della carriera, offrendo scenari e possibilità che l'utente potrebbe non aver considerato.

Il modulo delle professioni affini rappresenta un complemento strategico al ranking finale. Non incide direttamente sulla selezione delle 5 professioni principali, ma arricchisce il risultato finale, rendendo Career Compass AI non solo un sistema di matching, ma come un compagno di orientamento, in grado di guidare l'utente nell'esplorazione di un mondo del lavoro complesso, dinamico e in continua trasformazione [8].

CAPITOLO 4: Implementazione

4.1 Ambiente di Sviluppo e Tecnologie

Lo sviluppo del prototipo Career Compass AI si è basato su una serie di scelte tecnologiche mirate a garantire stabilità, scalabilità e facilità di manutenzione. In questa sezione vengono illustrate nel dettaglio le componenti principali dell'ambiente di sviluppo: il linguaggio di programmazione e il runtime, le librerie chiave utilizzate, gli strumenti di gestione dell'ambiente virtuale e delle variabili d'ambiente, l'ambiente di lavoro locale (IDE: Integrated Development Environment), e le strategie di versionamento adottate con Git e GitHub. L'obiettivo non è soltanto descrivere gli strumenti impiegati, ma anche evidenziare le motivazioni che hanno guidato queste scelte, in linea con i principi di trasparenza e replicabilità che permeano l'intero progetto.

Linguaggio e Runtime

Il prototipo è stato sviluppato in Python che offre compatibilità con librerie moderne e garantisce il supporto a costrutti sintattici avanzati introdotti nelle ultime release. La scelta di Python non è casuale: il linguaggio si caratterizza per tre elementi fondamentali che lo rendono particolarmente adatto a un progetto come Career Compass AI.

1. Accessibilità e leggibilità del codice. Python è noto per la sua sintassi chiara e vicina al linguaggio naturale, che riduce la barriera d'ingresso per nuovi collaboratori e permette di mantenere il codice più comprensibile anche a distanza di tempo. In un progetto accademico, questo aspetto assume particolare rilevanza, poiché consente di rendere l'implementazione leggibile anche da chi non è specialista in programmazione.
2. Ecosistema di librerie. Python è oggi uno degli ecosistemi più ricchi in termini di pacchetti dedicati al machine learning, al natural language processing e alla gestione di API. L'adozione di Python ha permesso di integrare senza problemi librerie come openai e langchain, necessarie per la comunicazione con i Large Language

Models, ma anche strumenti consolidati come requests per le chiamate HTTP o pandas per la manipolazione tabellare dei dati.

3. **Compatibilità con framework moderni.** Lo sviluppo dell'interfaccia utente è stato realizzato con Streamlit, una framework open-source che permette di trasformare script in python in applicazioni web interattive in grado di costruire applicazioni web interattive in maniera rapida e intuitiva. Questo framework ha reso possibile realizzare un prototipo funzionante senza dover passare per stack tecnologici più complessi, come React o Angular, mantenendo un ambiente di lavoro professionale e snello.

L'utilizzo di Python ha inoltre garantito il supporto a ottimizzazioni a livello di performance; in particolare, il progetto sfrutta la concorrenza tramite multi-threading (`concurrent.futures`) per parallelizzare le chiamate API esterne, riducendo drasticamente i tempi di attesa. L'affidabilità del codice è invece assicurata da una solida gestione degli errori e da un robusto meccanismo di fallback che garantisce la continuità del servizio anche in caso di indisponibilità dei servizi esterni.

4.1.1 Librerie Chiave

Il progetto è costituito dall'impiego di un insieme di librerie che assolvono a compiti specifici e complementari. La loro integrazione ha reso possibile la realizzazione di una pipeline modulare, capace di gestire dati strutturati e non strutturati, comunicare con servizi esterni e restituire risultati in formato standardizzato.

JSON

Il formato JSON (JavaScript Object Notation) è stato scelto come struttura di rappresentazione principale per i dati interni ed esterni. In particolare:

- I file JSON locali (conoscenze, competenze, attitudini e attività generalizzate) fungono da vocabolario controllato, vincolando l'output del modello linguistico a categorie predefinite.

- Le risposte delle API INAPP vengono restituite in formato JSON, rendendo naturale l'integrazione con il backend.
- L'output finale verso l'utente è un oggetto JSON strutturato, che garantisce uniformità e facilità di parsing anche in scenari futuri di interoperabilità.

La libreria json di Python è stata utilizzata per il parsing e la serializzazione dei dati. Grazie alla sua semplicità e alla compatibilità nativa con il linguaggio, ha consentito di mantenere un flusso dati coerente e facilmente tracciabile lungo tutta la pipeline.

Requests

Per le chiamate ai servizi esterni è stata utilizzata la libreria requests, uno standard de facto in Python per l'esecuzione di richieste HTTP. Nel contesto del progetto, requests è stata impiegata per interrogare le API di INAPP, recuperando informazioni aggiornate sulle professioni collegate alle competenze estratte dal profilo utente.

L'uso di requests ha garantito affidabilità e semplicità di implementazione, permettendo di gestire in maniera chiara parametri, header e codici di risposta. Associata a meccanismi di parallelizzazione (concurrent.futures), ha reso possibile ridurre drasticamente la latenza complessiva, un aspetto cruciale per la fruibilità del sistema in tempo reale.

OpenAI

L'accesso ai Large Language Models (LLM) di OpenAI è gestito attraverso la libreria di integrazione langchain-openai, utilizzata per compiti di validazione, estrazione semantica, classificazione e ranking. Attraverso questa interfaccia, il sistema invia prompt progettati con tecniche di prompt engineering e riceve in risposta output strutturati, poi trasformati in JSON interpretabili.

L'uso dei modelli OpenAI è stato integrato con il framework LangChain, che ha permesso di orchestrare le chiamate in pipeline e di abilitare funzionalità avanzate come il tracing e il monitoraggio tramite LangSmith. Questo

connubio ha reso possibile costruire un sistema modulare e spiegabile, in cui ogni invocazione dell'LLM è tracciata e giustificata.

Altre librerie di supporto

Oltre a quelle appena descritte, il progetto si avvale di ulteriori librerie che svolgono funzioni di contorno ma non meno importanti:

- `dotenv`: gestione sicura delle variabili d'ambiente tramite file `.env`.
- `streamlit`: necessaria al fine di comunicare con il framework omonimo e per la realizzazione dell'interfaccia utente interattiva.
- `langchain` e `langsmith`: orchestrazione delle chiamate agli LLM e monitoraggio avanzato di costi, latenza e utilizzo dei token.

Queste librerie, integrate in maniera coerente, hanno consentito di mantenere un equilibrio tra semplicità di utilizzo e potenza espressiva.

4.1.2 Ambiente di Sviluppo

Visual Studio Code

L'ambiente di sviluppo scelto è Visual Studio Code (VSCode), uno degli IDE più diffusi e versatili, particolarmente adatto a progetti Python. La scelta è stata motivata da diverse ragioni:

- **Estendibilità**: VSCode offre un vasto ecosistema di estensioni, tra cui quelle dedicate a Python, Git, Streamlit e al supporto di ambienti virtuali.
- **Integrazione con Git**: la gestione del versionamento è stata semplificata grazie a un'interfaccia grafica intuitiva, che consente di eseguire commit, merge e push direttamente dall'IDE.
- **Debugging avanzato**: gli strumenti di debug hanno facilitato l'individuazione e la risoluzione di errori sia nel backend che nel frontend.

Ambiente Virtuale (venv)

Per garantire l'isolamento delle dipendenze è stato adottato un ambiente virtuale (venv). Questo approccio ha permesso di:

- Separare le dipendenze del progetto da quelle installate globalmente sul sistema.
- Garantire la riproducibilità dell'ambiente di esecuzione, essenziale per un lavoro di ricerca.
- Facilitare il deployment su macchine diverse, assicurando che ogni installazione utilizzi le stesse versioni di librerie dichiarate in requirements.txt.

In particolare, come spiegato più avanti, il venv non è presente nella cartella su Github pertanto la cartella dovrà essere creata localmente installando le dipendenze necessarie specificate nel file requirements.txt.

File .env

Un altro elemento cruciale dell'ambiente di sviluppo è la gestione delle variabili sensibili attraverso un file .env. All'interno di questo file sono state memorizzate le chiavi API di OpenAI e LangSmith, evitando di inserirle direttamente nel codice. Questa scelta garantisce sicurezza, manutenibilità e conformità a buone pratiche di sviluppo. Poiché il file .env contiene credenziali sensibili, non è presente nel repository consultabile al seguente link:

https://github.com/Alessandro765/TESI_MAGISTRALE_BARAGONA.

Per il corretto funzionamento del prototipo, è essenziale creare questo file localmente; il requisito minimo è che contenga una chiave OpenAI valida.

Il file .env, collocato nella directory principale, viene caricato tramite la libreria dotenv, questo meccanismo consente di condividere il codice sorgente senza esporre credenziali sensibili, migliorando la sicurezza complessiva.

Versioning e GitHub

La gestione del codice sorgente è stata realizzata tramite Git, con repository ospitato su GitHub. L'adozione di questo strumento ha permesso di:

- Mantenere uno storico completo delle modifiche.
- Lavorare in maniera incrementale, con la possibilità di tornare a versioni precedenti in caso di errori.
- Facilitare l'eventuale collaborazione tra più sviluppatori.

File .gitignore

Un ruolo fondamentale è stato svolto dal file `.gitignore`, che ha escluso dal tracciamento elementi non rilevanti o potenzialmente dannosi per la sicurezza. Tra questi:

- La cartella `venv/`, per evitare di caricare l'intero ambiente virtuale.
- Il file `.env`, che contiene chiavi e credenziali sensibili.
- File temporanei generati da Python o da VSCode (ad esempio, `__pycache__`, `.vscode/`).

Questa configurazione ha garantito un repository pulito, sicuro e facilmente replicabile da chiunque desideri ricreare il progetto a partire dal codice sorgente.

Strategie di branching

Pur trattandosi di un progetto accademico sono state adottate pratiche tipiche dello sviluppo collaborativo:

- Branch principale (main): Contiene unicamente il codice stabile e funzionante, rappresentando di fatto l'ambiente di "produzione" del progetto.
- Branch di sviluppo (dev): Utilizzato per le sperimentazioni e l'implementazione di nuove funzionalità. Le modifiche sono state integrate nel branch main solo dopo test e validazioni. Attualmente,

essendo la versione considerata stabile, il branch dev è stato unito a main e rimosso.

Questa organizzazione, sebbene semplice, ha permesso di mantenere un buon livello di ordine e di ridurre il rischio di introdurre errori nel codice principale.

4.1.3 Riflessione metodologica

La combinazione di linguaggio, librerie e strumenti di sviluppo non è stata dettata unicamente da considerazioni tecniche, ma anche metodologiche. L'uso di Python e delle librerie descritte ha reso possibile costruire un sistema modulare, spiegabile e facilmente replicabile. L'adozione di ambienti virtuali e di un file .gitignore ha garantito la sicurezza e la portabilità del progetto, mentre Git e GitHub hanno fornito un quadro di versionamento trasparente.

Il prossimo paragrafo illustrerà in dettaglio le funzioni principali del backend dell'applicazione Career Compass AI [8,29,32].

4.2 Struttura del Codice e Funzioni Chiave

L'implementazione del prototipo Career Compass AI si concretizza in una serie di funzioni organizzate in maniera modulare e coerente, che riflettono la logica multi-stadio introdotta nel capitolo precedente. In questa sezione si analizzerà nel dettaglio la struttura del codice, mettendo in evidenza la funzione principale, quelle che compongono la pipeline di analisi e quelle dedicate al meccanismo di fallback. L'obiettivo è mostrare come la progettazione teorica si traduca in un'implementazione concreta, evidenziando i passaggi chiave e le scelte di design che hanno guidato lo sviluppo. Le funzioni di seguito descritte sono consultabili al seguente link: https://github.com/Alessandro765/TESI_MAGISTRALE_BARAGONA.

4.2.1 Funzione principale

Al centro dell'architettura si trova la funzione `run_full_analysis_pipeline`, implementata nel file `backend_analysis.py`. Essa svolge il ruolo di orchestratore, coordinando l'intera sequenza di operazioni necessarie per

trasformare il testo libero fornito dall'utente in un output strutturato e spiegabile.

Il flusso di lavoro seguito da questa funzione può essere descritto in quattro fasi principali:

1. Validazione dell'input: verifica della qualità e sufficienza del testo inserito dall'utente.
2. Analisi semantica e classificazione: estrazione di competenze, attitudini e interessi, con successiva mappatura alle categorie ISTAT.
3. Recupero delle professioni: interrogazione delle API INAPP o, in caso di fallimento, utilizzo del database locale di fallback.
4. Ranking e audit etico: selezione delle professioni più pertinenti, accompagnata da un controllo di fairness.

La funzione `run_full_analysis_pipeline` incapsula dunque l'intero processo decisionale, garantendo un flusso lineare ma al contempo modulare, in cui ogni sottofunzione ha un compito preciso e indipendente.

In particolare, la fase di Recupero delle professioni è orchestrata in modo da ottimizzare le performance. Per ogni competenza estratta, l'orchestratore invoca in modo concorrente e parallelo la funzione di utilità chiamata `api`. Quest'ultima agisce come una funzione "operaia", la cui unica responsabilità è eseguire una singola richiesta HTTP all'API di INAPP per una specifica competenza. L'esecuzione parallela di più istanze di `chiamata_api`, gestita tramite `concurrent.futures`, permette di ridurre drasticamente la latenza complessiva.

Il suo ruolo di orchestratore è evidente nella sequenza di chiamate che esegue, come illustrato nel seguente frammento di codice semplificato:

@traceable

```
def run_full_analysis_pipeline(user_input_text, force_fallback=False):
```

```
    """
```

Esegue l'intera pipeline di analisi, dall'input utente al risultato finale.

```
"""
```

```
# FASE 1: Validazione dell'input
```

```
# FASE 2: Analisi semantica e classificazione
```

```
selected_categories_with_reasons, usage1 = select_best_categories(...)
```

```
user_category, usage2 = classify_user_category(...)
```

```
# FASE 3: Recupero delle professioni (con logica di fallback)
```

```
try:
```

```
    # Esegue chiamate API in parallelo a INAPP...
```

```
    #Uso funzione chiamata _api
```

```
    best_professions = aggregate_best_jobs(...)
```

```
except Exception as api_error:
```

```
    # Se le API falliscono, si attiva il fallback locale
```

```
    best_professions = find_professions_locally_as_fallback(...)
```

```
# Controllo ulteriore e attivazione del fallback se nessun risultato
```

```
if not best_professions:
```

```
    best_professions = find_professions_locally_as_fallback(...)
```

```
# FASE 4: Ranking e audit etico
```

```
ranked_results, usage3 = rank_professions(user_input_text,  
best_professions)
```

```
audited_ranked_results, usage4 =  
perform_fairness_audit(user_input_text, ranked_results)
```

```
# ... aggregazione finale e restituzione dei risultati
```

```

final_results = {
    "audited_ranked_professions": audited_ranked_results,
    # ... altri dati ...
}

return final_results

```

4.2.2 Funzioni della pipeline di analisi

La pipeline di analisi è composta da una serie di funzioni specializzate, ognuna delle quali corrisponde a un passaggio distinto della logica operativa progettata.

validate_user_input

La funzione `validate_user_input` rappresenta il vero e proprio gatekeeper della pipeline: il suo compito è impedire che input poveri, privi di significato o non pertinenti inneschino l'intero processo di analisi, con conseguente spreco di risorse computazionali e costi impiegati per ottenere un risultato inconsistente.

A differenza di un controllo superficiale basato esclusivamente sulla lunghezza del testo, questa funzione si avvale di un LLM istruito tramite prompt dedicato, che viene esplicitamente incaricato di assumere il ruolo di “validatore severo”. Le regole fornite al modello sono volutamente rigide:

- Rifiuto immediato di nonsense o saluti: input come “ciao”, “trovami un lavoro” o sequenze prive di senso (“asdasd”) non vengono accettati.
- Controllo di sufficienza minima: per essere validato, l'input deve contenere almeno un riferimento concreto a un'esperienza, una competenza, una passione o un obiettivo professionale.
- Il gatekeeper è severo, ma giusto: temperatura impostata a 0.0.

Per assicurare la massima affidabilità nell'integrazione con il resto della pipeline, la funzione vincola l'LLM a restituire sempre la risposta in un formato JSON predefinito, della forma:

```
{  
  "is_sufficient": true/false,  
  "feedback": "..."  
}
```

- Il campo `is_sufficient` indica se l'input supera la soglia di validazione.
- Il campo `feedback` fornisce un commento sintetico, utile a informare l'utente in caso di rifiuto (es. "Il testo è troppo breve, descrivi almeno una tua esperienza lavorativa o un obiettivo professionale").

Questo meccanismo ha una duplice funzione: da un lato previene l'avvio di analisi complesse su input non idonei, dall'altro restituisce un feedback immediato e costruttivo all'utente, orientandolo nella scrittura di un testo più adatto.

L'adozione di un LLM come validatore, sebbene possa sembrare ridondante rispetto a un controllo sintattico tradizionale, si giustifica per la capacità del modello di cogliere sfumature semantiche. Un input come "Mi piace lavorare in team, ma non ho esperienza" non sarebbe validato da una semplice soglia di caratteri, ma viene correttamente interpretato come sufficiente dal validatore, perché contiene un'indicazione chiara di inclinazione e contesto.

`validate_user_input` costituisce un filtro di qualità una prima barriera che l'utente deve superare se ha l'intenzione di ottenere una classificazione ISTAT in linea con il suo profilo e pertanto innalza anche il livello dell'interazione con l'utente, rendendo l'intera pipeline più robusta e affidabile.

`select_best_categories`

La funzione `select_best_categories(user_text, json_data)` costituisce il primo passo e dell'analisi semantica. Il suo scopo è tradurre il racconto libero e

informale dell'utente in un profilo di competenze strutturato e standardizzato, che possa essere confrontato con la tassonomia ufficiale delle professioni ISTAT.

A differenza di approcci basati su tecniche di estrazione automatica di parole chiave, questa funzione utilizza tecniche di prompt engineering al fine di guidare l'LLM attraverso un compito ben definito:

1. **Contesto.** Il testo dell'utente viene passato al prompt come contesto su cui il modello deve lavorare.
2. **Etichette.** L'LLM viene istruito a individuare le due categorie più pertinenti in ciascuna delle seguenti aree: conoscenze (B), skill (C), attitudini (D) e attività (G). Per ridurre l'arbitrarietà delle risposte, il prompt include l'intero contenuto dei file JSON locali (conoscenze.json, skills.json, attivita_generalizzate.json, attitudini.json). In questo modo l'LLM è vincolato a scegliere esclusivamente etichette presenti nella lista predefinita, garantendo coerenza con gli standard ISTAT e validità per le successive chiamate API tramite l'utilizzo di questo vocabolario controllato.
3. **Spiegabilità.** Per ciascuna categoria selezionata, il modello è obbligato a fornire una motivazione concisa, basata su elementi espliciti del testo utente. Questo meccanismo rende il processo trasparente e permette al frontend di restituire feedback chiari (Per esempio: “questa competenza è stata associata perché hai menzionato...”).
4. **Regole etiche.** Il prompt integra istruzioni esplicite per ignorare fattori sensibili (genere, età, background) e concentrarsi unicamente su competenze, esperienze e aspirazioni, prevenendo distorsioni legate a bias impliciti.

L'output della funzione è un oggetto JSON strutturato, con la seguente forma:

```
{  
  "best_conoscenze": [  

```

```

    {"code": "Bxx", "reason": "Motivazione..."},
    {"code": "Bxx", "reason": "Motivazione..."}
  ],
  "best_skills": [...],
  "best_attitudini": [...],
  "best_attivita": [...],
  "explicit_job_keyword": "..."
}

```

Questo oggetto costituisce la base di tutto il processo successivo: i codici selezionati alimentano le chiamate API INAPP, il ranking e l'analisi di fairness, mentre le motivazioni fanno parte della spiegabilità del sistema. La funzione è centrale al fine della profilazione semantica: trasforma un testo libero in un profilo coerente, interpretabile e trasparente, bilanciando vincoli formali (vocabolario controllato, formato JSON), parole chiavi associate alla professione o agli interessi indicati dall'utente e principi di Responsible AI (spiegabilità, mitigazione dei bias).

classify_user_category

La funzione `classify_user_category` rappresenta un passaggio strategico di pre-filtraggio, dopo che il sistema ha analizzato il testo dell'utente ed estratto competenze, conoscenze e attitudini specifiche, è necessario collocare il profilo in un quadro generale: capire cioè a quali macro-aree professionali ISTAT esso appartenga.

Il funzionamento si articola in tre momenti distinti:

1. Recupero delle macro-categorie ufficiali. Attraverso la funzione ausiliaria `get_istat_categories`, viene effettuata una chiamata all'API INAPP che restituisce l'elenco aggiornato dei nove “grandi gruppi” della classificazione ISTAT. Queste categorie costituiscono il livello

più alto della tassonomia (ad esempio: 2 - Professioni intellettuali, scientifiche e di elevata specializzazione).

2. Classificazione guidata dall'LLM. L'elenco delle macro-categorie viene incluso in un prompt dedicato, che incarica il modello linguistico di agire come un esperto di classificazione. Il compito è selezionare le due categorie più pertinenti rispetto al profilo utente, basandosi esclusivamente sulle competenze e sulle aspirazioni esplicitamente menzionate.
3. Output pulito. Per garantire un parsing privo di ambiguità, il prompt è ingegnerizzato in modo da vincolare l'LLM a restituire un formato rigidissimo: due numeri separati da una virgola, senza alcun testo aggiuntivo. Il risultato è quindi facilmente interpretabile dal sistema, ad esempio ['2', '6'].

Il valore prodotto da `classify_user_category` non viene esposto direttamente all'utente, ma funge da filtro strategico per le fasi successive. Solo le professioni i cui codici ISTAT iniziano con uno dei due numeri selezionati vengono considerate nella fase di aggregazione. Questo passaggio è cruciale: consente di restringere in maniera significativa il ventaglio delle opzioni, assicurando che i suggerimenti finali non siano soltanto coerenti con le singole skill estratte, ma anche con l'area professionale complessiva a cui l'utente appartiene.

In tal modo, la funzione garantisce un equilibrio tra granularità (competenze specifiche) e visione d'insieme (macro-categorie), migliorando sia l'efficienza computazionale della pipeline sia la qualità dei risultati.

aggregate_best_jobs

La funzione `aggregate_best_jobs` si configura come un aggregatore incaricato di trasformare l'insieme eterogeneo e frammentato dei risultati provenienti dalle chiamate API INAPP in una lista unificata e ponderata di professioni candidate. Si tratta di un passaggio centrale della pipeline, poiché segna il momento in cui le informazioni sulle competenze vengono effettivamente tradotte in un primo elenco di opzioni lavorative.

A differenza di altre funzioni del backend, `aggregate_best_jobs` non esegue alcuna chiamata all'LLM. Il suo funzionamento è basato esclusivamente su logica Python, attraverso un algoritmo iterativo elegante e deterministico che garantisce la replicabilità dei risultati: a parità di input, l'output prodotto sarà sempre lo stesso. Questo approccio la distingue nettamente dalle funzioni che fanno ricorso a modelli linguistici, introducendo un livello di calcolo puramente algoritmico nella pipeline.

Il funzionamento può essere descritto attraverso tre passaggi chiave:

1. Iterazione sulle competenze estratte. La funzione utilizza una serie di cicli `for` annidati per scorrere sistematicamente i risultati ottenuti dalle chiamate parallele per ciascuna categoria di competenze: conoscenze (B), skill (C), attitudini (D) e attività (G). In questo modo, ogni professione individuata dalle API viene processata secondo le stesse regole di filtraggio e scoring.
2. Filtraggio strategico tramite macro-categorie. Per ciascuna professione trovata, viene applicato il filtro derivante dalla funzione `classify_user_category`. Questo passaggio è fondamentale per eliminare il “rumore” e conservare soltanto i risultati tematicamente coerenti.
3. Calcolo di un punteggio ponderato di affinità. Per ogni professione che supera il filtro, la funzione calcola un punteggio composito, basato su due metriche fornite dalle API INAPP:
 - Importanza: misura quanto una competenza sia cruciale per quella professione.
 - Complessità: misura quanto sia difficile padroneggiare la competenza nel contesto lavorativo.

L'algoritmo combina questi due fattori con i pesi assegnati alle categorie di competenze (w_B , w_C , w_D , w_G). Si tratta di una logica deterministica e trasparente: i punteggi sono calcolati matematicamente e non dipendono da processi stocastici.

Al termine del processo, `aggregate_best_jobs` restituisce una lista ordinata delle 40 professioni con il punteggio più alto, costituendo un ponte tra il recupero grezzo e l'analisi qualitativa: da un lato depura e filtra i dati in modo algoritmico e ripetibile, dall'altro prepara il terreno all'intervento successivo del modello linguistico. La sua natura deterministica ne fa un elemento essenziale di stabilità all'interno della pipeline, complementare alle funzioni guidate dall'intelligenza artificiale. La lista dei codici associati alla tassonomia ISTAT rappresenta il set preliminare di opzioni lavorative, pulito e pre-qualificato, che viene poi passato alla funzione `rank_professions` per il ranking qualitativo finale da parte dell'LLM.

Di seguito è riportata quasi interamente la funzione descritta:

```
def aggregate_best_jobs(api_results, user_category, w_B, w_C, w_D, w_G):  
    # Struttura dati per accumulare i punteggi di ogni professione  
  
    job_scores = defaultdict(lambda: {"desc": "", "total_score": 0,  
    "importanza": 0, "complessita": 0})  
  
    # 1. Cicla attraverso i risultati API per ogni tipo di competenza (pesata)  
    for category, weight in [("Conoscenze", w_B), ("Skills", w_C),  
    ("attitudini", w_D), ("attivita", w_G)]:  
        if category in api_results:  
            for key, jobs in api_results[category].items():  
                if jobs:  
                    for job in jobs.values():  
                        code = job.get("pkLivello", "")  
  
    # 2. Applica il filtro strategico delle macro-categorie ISTAT  
    if any(code.startswith(num) for num in user_category):
```

```

job_scores[code]["desc"] = job.get("desc_livello", "")

importanza = float(job.get("importanza", 0))
complessita = float(job.get("complessita", 0))
job_scores[code]["importanza"] = importanza
job_scores[code]["complessita"] = complessita

# 3. Calcola il punteggio ponderato
score = weight * (100 - importanza) + (100 - complessita)
job_scores[code]["total_score"] += score

# Ordina le professioni in base al punteggio totale decrescente
sorted_jobs = sorted(job_scores.items(), key=lambda x: -
x[1]["total_score"])

# Restituisce una lista pulita delle top 40 professioni candidate
return [{"code": code, "desc": job["desc"], ...} for code, job in
sorted_jobs][:40]

```

get_explicit_professions

La funzione `get_explicit_professions` è stata progettata per gestire un caso d'uso specifico ma cruciale: il riconoscimento e il rispetto delle intenzioni esplicite espresse dall'utente. Mentre la maggior parte della pipeline si concentra sull'analisi semantica del testo libero, inferendo competenze e aspirazioni in modo deduttivo, questa funzione entra in gioco quando il sistema rileva la presenza di una menzione diretta a una professione o a un settore.

Esempi tipici sono frasi come «vorrei lavorare come barista» oppure «mi interessa diventare infermiere». In questi casi, l'obiettivo non è soltanto mappare le skill sottese, ma riconoscere che l'utente ha già dichiarato una preferenza concreta. La funzione risponde dunque a un principio di centralità dell'utente, arricchendo l'analisi deduttiva con un approccio dichiarativo, così da migliorare la personalizzazione e la pertinenza dei risultati.

Il processo operativo di `get_explicit_professions` si articola in tre fasi principali:

1. Interrogazione dell'API per ricerca testuale. La funzione riceve in input la *keyword* esplicita estratta dalla fase di analisi semantica. Sulla base di questa keyword, costruisce una query mirata verso l'endpoint dedicato alla ricerca testuale delle professioni messo a disposizione dall'API INAPP, contraddistinto dal parametro `flag=26`. A differenza delle chiamate basate su codici di competenza, questa richiesta simula una ricerca full-text sull'intero database delle professioni, con l'obiettivo di catturare tutte le occorrenze pertinenti alla parola chiave fornita.
2. Pulizia robusta dei dati di risposta. L'endpoint interrogato non restituisce un JSON già formattato, bensì una stringa testuale irregolare, che può contenere elementi HTML, caratteri di escape (`\n`, `\t`) e simboli non standard. Per trasformare questa risposta grezza in un formato trattabile, la funzione implementa un'intensa fase di *data cleaning* basata su espressioni regolari (`re.sub`). Questo passaggio è fondamentale: consente di normalizzare la risposta, ottenendo una stringa JSON valida e garantendo che il sistema resti robusto anche in presenza di input imperfetti o non conformi agli standard attesi.
3. Estrazione e strutturazione dell'output. Una volta ottenuta una stringa pulita, la funzione utilizza `json.loads` per effettuare il parsing. Naviga quindi la struttura nidificata dei dati, estraendo per ciascuna professione trovata il codice ISTAT (`pkLivello`) e la descrizione

(desc_livello). Poiché l'endpoint non fornisce i valori di “importanza” e “complessità”, questi vengono impostati a un valore fisso di 50. Tale standardizzazione assicura che l'output della funzione mantenga la stessa struttura delle altre funzioni di recupero, garantendo omogeneità e interoperabilità all'interno della pipeline.

La funzione `get_explicit_professions` non opera in isolamento, ma svolge un ruolo complementare e strategico all'interno della pipeline. I risultati che produce vengono infatti integrati nella lista di professioni candidate generata dall'analisi basata sulle competenze e sul lavoro dell'LLM.

In questo modo, l'elenco di quaranta professioni che viene trasmesso a `rank_professions` non contiene soltanto le opzioni “dedotte” dalle competenze inferite, ma è arricchito anche dalle preferenze esplicitamente dichiarate dall'utente. Questo approccio ibrido garantisce che il sistema non solo analizzi il profilo in modo oggettivo, ma anche ascolti le intenzioni dirette di chi lo utilizza. La funzione rafforza la dimensione user-centered del prototipo: bilancia le raccomandazioni algoritmiche con i desideri dichiarati, migliorando la personalizzazione dei suggerimenti e aumentando la probabilità che i risultati finali siano percepiti come realmente pertinenti.

`rank_professions`

La funzione `rank_professions` risulta centrale nel processo di ranking qualitativo della pipeline. Se `aggregate_best_jobs` agisce come un motore quantitativo, basato su metriche deterministiche e filtri algoritmici, `rank_professions` assume invece il ruolo del consulente di carriera basato su AI: non conta o pesa competenze, ma applica un giudizio contestuale e motivato per individuare le cinque professioni finali da suggerire all'utente.

Il funzionamento della funzione può essere descritto in quattro passaggi principali:

1. Creazione di un contesto ricco. La funzione costruisce un prompt che mette a disposizione dell'LLM due elementi fondamentali:

- il profilo originale e completo dell'utente, per preservare tutte le sfumature del suo racconto;
 - la lista pre-filtrata di al più quaranta professioni candidate, presentata in formato chiaro e strutturato (codice ISTAT, nome, importanza, complessità).
2. Assegnazione di un ruolo esperto. L'LLM viene incaricato di agire come un "esperto di orientamento professionale, etico e imparziale". Questo accorgimento di prompt engineering è cruciale: non solo orienta il modello verso un registro consulenziale, ma lo vincola a un approccio responsabile e a una valutazione non arbitraria.
3. Compiti di alto livello. L'LLM non si limita a ordinare le professioni, ma svolge compiti qualitativi più complessi:
- assegna a ciascuna professione un punteggio di pertinenza (*relevance_score*) da 1 a 10, valutando la compatibilità con il profilo utente;
 - fornisce una motivazione (*reason*) esplicita per ogni punteggio, collegando in maniera diretta gli elementi del racconto personale dell'utente con le caratteristiche della professione suggerita;
 - scarta le opzioni meno pertinenti, restringendo progressivamente la lista.
4. Regole etiche e di buon senso. Il prompt integra istruzioni mirate per garantire un'analisi responsabile e priva di stereotipi:
- ignorare fattori sensibili. come genere, età o background socioeconomico (inclusa la condizione di NEET);
 - valutare il potenziale dell'utente, non solo lo stato attuale delle sue esperienze;
 - applicare regole pragmatiche, ad esempio scartando professioni legate all'insegnamento se non menzionate dall'utente, così da evitare suggerimenti generici o incoerenti.

L'output della funzione è una lista JSON strutturata con le cinque professioni finali, ciascuna corredata da codice ISTAT, descrizione, punteggio di pertinenza e motivazione. Questo formato rende i risultati spiegabili e trasparenti, permettendo al frontend di presentare non solo i suggerimenti, ma anche le ragioni alla base della scelta.

In questo punto della pipeline avviene la trasformazione di un elenco preliminare di opzioni in un set finale qualificato e personalizzato, valorizzando la dimensione qualitativa e spiegabile dell'analisi. È in questo punto della pipeline che il sistema smette di "calcolare" e inizia realmente a "consigliare", ponendosi come un consulente di carriera virtuale capace di argomentare le proprie raccomandazioni.

perform_fairness_audit

La funzione `perform_fairness_audit` rappresenta il cuore etico dell'applicazione ed è l'elemento che concretizza, all'interno della pipeline, i principi di Responsible AI. Se le fasi precedenti si concentrano sull'identificazione delle competenze, sulla classificazione e sul ranking delle professioni più pertinenti, questa funzione aggiunge uno strato ulteriore di analisi, finalizzato a garantire che le raccomandazioni non siano soltanto tecnicamente corrette, ma anche eque, consapevoli e socialmente responsabili.

Lo scopo non è valutare l'utente, ma piuttosto interrogarsi sulle potenziali barriere sistemiche che possono rendere alcune professioni meno accessibili a specifici sottogruppi della popolazione. In questo senso, la funzione trasforma il sistema da semplice strumento di orientamento a catalizzatore di consapevolezza, restituendo all'utente una visione più ampia e realistica del mondo del lavoro, con le sue opportunità ma anche con le sue criticità.

Il processo di audit etico è iterativo e viene applicato a ciascuna delle cinque professioni finali individuate dalla fase di ranking qualitativo. Per ogni professione selezionata, la funzione procede in tre fasi:

1. Incarico di revisione specializzata. L'LLM viene invocato con un ruolo specifico: quello di un revisore etico e imparziale, esperto in

analisi di fairness multigruppo. Attraverso tecniche di prompt engineering mirate, il modello è spinto a ragionare non come un consulente di carriera, ma come un analista critico incaricato di individuare potenziali bias.

2. Analisi multidimensionale del bias. L'analisi si sviluppa lungo tre assi fondamentali, ispirati ai framework consolidati di fairness algoritmica:

- Bias legati all'età: individuazione di eventuali svantaggi per fasce anagrafiche specifiche (giovani in ingresso nel mercato o lavoratori senior).
- Bias di genere: esplorazione di stereotipi che possono influenzare la distribuzione delle opportunità tra uomini e donne.
- Bias legati al background socio-economico: valutazione di requisiti impliciti (percorsi formativi costosi, network professionali esclusivi, barriere culturali) che potrebbero ostacolare soggetti provenienti da contesti meno favoriti.

3. Produzione di un output strutturato. Per ciascuna professione, l'LLM è obbligato a restituire una risposta in formato JSON con tre campi chiave:

- `potential_bias_summary`: un riassunto conciso che segnala la presenza o meno di criticità.
- `affected_subgroups`: l'elenco dei sottogruppi demografici potenzialmente penalizzati.
- `reasoning`: una spiegazione sintetica ma chiara delle ragioni per cui tali bias potrebbero emergere, basata su conoscenze generali del mercato del lavoro.

Questa struttura garantisce che i risultati siano chiari, uniformi e facilmente integrabili nell'output finale.

L'output della funzione `perform_fairness_audit` viene integrato direttamente nel dizionario di ciascuna professione suggerita. Di conseguenza, ogni

raccomandazione non è mai presentata da sola, ma sempre accompagnata dal proprio audit di fairness, che ne evidenzia eventuali punti critici.

Questo approccio ha una duplice valenza: da un lato incrementa la trasparenza del sistema, mostrando non solo cosa viene raccomandato, ma anche perché e con quali possibili limitazioni; dall'altro rafforza la fiducia dell'utente, che percepisce la raccomandazione come frutto non di un calcolo opaco, ma di un processo consapevole e responsabile. La funzione rappresenta la svolta etica della pipeline: non si limita a individuare professioni coerenti con le competenze, ma mette in luce i possibili ostacoli, rendendo il sistema non solo un motore di raccomandazione, ma uno strumento di orientamento critico e informato, capace di illuminare le strade professionali con consapevolezza e responsabilità.

get_affine_professions

La funzione `get_affine_professions` arricchisce il report finale introducendo una dimensione esplorativa che va oltre la raccomandazione diretta. Se le funzioni precedenti si focalizzano sull'individuazione delle professioni più pertinenti al profilo dell'utente, questa funzione ha l'obiettivo di ampliare l'orizzonte, rispondendo a una domanda implicita ma cruciale: *Quali altri percorsi professionali, simili o correlati a quelli suggeriti, potrebbero costituire un'opportunità interessante?*.

Il valore strategico di questa funzione è duplice:

- Offrire alternative. L'utente non riceve un'unica lista di opzioni "ottimali", ma una sorta di mappa delle carriere affini, che lo incoraggia a esplorare possibilità vicine, magari non immediatamente considerate, ma che richiedono set di competenze simili.
- Aumentare la resilienza del suggerimento. Se una delle professioni principali non convince pienamente l'utente, le professioni affini offrono alternative concrete e pertinenti, rendendo l'intero processo di orientamento più flessibile e utile.

In questo senso, `get_affine_professions` trasforma la lista di raccomandazioni da semplice output statico a ecosistema dinamico di opportunità professionali interconnesse.

Dal punto di vista tecnico, il cuore della funzione è l'ottimizzazione tramite concorrenza. Poiché deve interrogare l'API INAPP per ciascuna delle cinque professioni finali, un'esecuzione sequenziale comporterebbe un tempo di attesa pari alla somma dei tempi di tutte le singole chiamate. Per evitare questa latenza, la funzione implementa una robusta architettura basata su multi-threading.

Il processo si articola nei seguenti passaggi:

1. Definizione di un worker interno. Viene definita una funzione di supporto (`fetch_affine_for_code`) il cui compito è eseguire una singola chiamata all'endpoint dedicato (`flag=31`) per recuperare le professioni affini a un dato codice ISTAT. Questa funzione è progettata per essere resiliente: in caso di errore di rete o di parsing, restituisce una lista vuota senza bloccare l'intero processo.
2. Creazione di un pool di thread. Tramite la classe `ThreadPoolExecutor` del modulo `concurrent.futures`, viene creato un pool di thread lavoratori (fino a cinque), pronti a eseguire le chiamate API in parallelo.
3. Sottomissione simultanea dei task. Le chiamate necessarie vengono sottomesse contemporaneamente al pool: invece di avviare le richieste una alla volta, tutte partono quasi istantaneamente, ciascuna gestita dal proprio thread.
4. Raccolta asincrona dei risultati. Il costrutto `concurrent.futures.as_completed` permette di processare i risultati man mano che arrivano, indipendentemente dall'ordine di avvio, riducendo ulteriormente i tempi di attesa.
5. Gestione dei duplicati. Per garantire che la lista finale sia pulita e non contenga ripetizioni (né delle professioni affini trovate, né delle

professioni principali già restituite), viene utilizzata una struttura dati set (`seen_codes`). Questo consente di verificare in tempo costante se un codice è già stato inserito, garantendo l'unicità dei risultati.

Grazie a questa architettura, il tempo totale di esecuzione della funzione non è più la somma delle singole chiamate, ma è approssimativamente pari al tempo della chiamata più lenta, con un guadagno significativo in termini di reattività e usabilità. Integrazione è la parola chiave che descrive il ruolo strategico di `get_affine_professions`. La funzione non sostituisce le raccomandazioni principali, ma le arricchisce con percorsi alternativi, rafforzando l'affidabilità del sistema e ampliando la prospettiva dell'utente. In questo modo, la pipeline non si limita a proporre un set ristretto di opzioni, ma diventa uno strumento di orientamento capace di suggerire ecosistemi professionali in cui muoversi e crescere.

4.2.3 Funzioni per il meccanismo di fallback

Un elemento distintivo del sistema è la capacità di garantire continuità operativa anche in caso di indisponibilità delle API esterne. Questo è reso possibile dal meccanismo di fallback, implementato attraverso due funzioni principali: `find_professions_locally_as_fallback` e `get_affine_professions_locally`. La prima consulta il file `profession_data.py`, che contiene un repertorio locale delle professioni ISTAT a tre digit, e si attiva automaticamente quando le chiamate all'API INAPP falliscono o restituiscono liste vuote. In tale scenario, il profilo estratto viene confrontato con le descrizioni presenti nel dizionario locale e l'LLM è istruito a eseguire un matching semantico tra competenze e descrizioni, restituendo comunque un elenco coerente di professioni candidate. Poiché i dati locali non includono le metriche di importanza e complessità, la funzione assegna a questi campi valori standard (pari a 50), così da mantenere la compatibilità strutturale con gli output delle altre funzioni della pipeline. La seconda funzione, `get_affine_professions_locally`, completa questa logica gestendo il recupero delle professioni affini quando l'API dedicata non è disponibile. In questo caso, la prossimità viene determinata in base al prefisso dei codici ISTAT: due professioni sono considerate affini se condividono le prime due

cifre (ad esempio, tutte quelle appartenenti al gruppo 2.2). Questo criterio, pur semplice, si è rivelato efficace nel proporre percorsi alternativi coerenti, offrendo all'utente la possibilità di esplorare ruoli professionali simili a quelli suggeriti come principali. In questo modo il fallback garantisce da un lato la resilienza del sistema, poiché l'utente non si trova mai di fronte a un vuoto di risposta, e dall'altro l'aderenza agli standard, perché le raccomandazioni restano sempre ancorate alla tassonomia ufficiale ISTAT anche in assenza di dati aggiornati. Lungi dall'essere un ripiego, il fallback rappresenta dunque una componente architeturale deliberata, concepita per rafforzare l'affidabilità complessiva dell'applicazione e garantire un'esperienza continua e priva di interruzioni.




Figura 8- Esecuzione di un test di fallback in caso di errore nella chiamata API INAPP. È possibile selezionare l'opzione nel riquadro situato sotto il titolo della sezione “Report di Analisi.”¹³

4.2.4 Aspetti trasversali

Di seguito vengono riportate alcune considerazioni che toccano più funzioni che compongono la pipeline descritta precedentemente. Uno degli elementi

¹³ Screen test prototipo. Sviluppato da A. Baragona

[https://github.com/Alessandro765/TESI_MAGISTRALE_BARAGONA]

più innovativi dell'implementazione riguarda la costruzione del prompt. Ogni funzione che interagisce con l'LLM non si limita a trasmettere l'input utente, ma costruisce un prompt multi-componente articolato in tre dimensioni: il ruolo e l'obiettivo, così che il modello sappia chi è e perché sta eseguendo una determinata operazione; il contesto, che include le tassonomie ISTAT, l'input dell'utente e le strutture dati necessarie; e le istruzioni sequenziali, che guidano il modello passo dopo passo nell'estrarre competenze, confrontarle con le professioni, selezionare i codici più pertinenti, attribuire punteggi e motivare le scelte. Questo approccio consente di simulare un ragionamento strutturato, riducendo l'opacità tipica dei modelli generativi e rendendo più trasparente il processo di analisi.

Il sistema riceve dall'utente un testo libero, che può contenere descrizioni non standardizzate, e lo elabora attraverso le diverse funzioni della pipeline fino a normalizzarlo e tradurlo in codici ufficiali. L'output finale è un oggetto JSON strutturato, che per ogni professione restituisce codice ISTAT, descrizione, punteggio di pertinenza e motivazione. Questo formato standardizzato non solo garantisce l'interoperabilità con altri sistemi, ma facilita anche l'estensibilità futura dell'applicazione, rendendo semplice l'aggiunta di nuove fonti dati o la modifica dei modelli di analisi.

Infine, la decisione di suddividere l'implementazione in funzioni modulari riflette un principio metodologico chiaro: favorire la manutenibilità, la trasparenza e la scalabilità. Ogni funzione è indipendente e sostituibile, il che consente di introdurre miglioramenti incrementali o varianti sostanziali, come nuovi algoritmi di ranking o l'integrazione di ulteriori fonti informative, senza compromettere l'intera pipeline. Questa scelta di design garantisce quindi non solo solidità nel presente, ma anche adattabilità e longevità del sistema [8].

4.3 LangSmith: Osservabilità e Valutazione dei Sistemi LLM

4.3.1 Introduzione allo strumento

Lo sviluppo di applicazioni basate su modelli linguistici di grandi dimensioni (LLM) pone una sfida non solo sul piano dell'accuratezza tecnica, ma anche su quello della trasparenza, della spiegabilità e della capacità di valutazione.

A differenza dei software tradizionali, le applicazioni LLM non producono risultati interamente deterministici: le risposte dipendono dal contesto, dalla formulazione dei prompt, dai parametri di generazione e persino dalla sequenza delle interazioni. Per questa ragione, strumenti di observability assumono un ruolo centrale nello sviluppo responsabile e nella manutenzione di sistemi di intelligenza artificiale.

In questo contesto si inserisce LangSmith, piattaforma progettata per fornire un'infrastruttura unificata di monitoraggio, tracciamento e valutazione per applicazioni che utilizzano LLM. LangSmith nasce con l'obiettivo di colmare il divario tra ciò che accade “dietro le quinte” di un modello linguistico e ciò che l'utente finale percepisce, offrendo agli sviluppatori la possibilità di osservare e comprendere l'intero ciclo di funzionamento delle loro applicazioni.

La logica di LangSmith può essere interpretata lungo tre direttrici principali:

- Osservabilità: ogni chiamata al modello, ogni funzione di supporto e ogni passaggio intermedio della pipeline può essere tracciato e reso visibile come parte di una “traccia” completa. Questo permette di individuare colli di bottiglia, errori di ragionamento o costi eccessivi, migliorando la capacità di debugging.
- Valutazione sistematica: LangSmith non si limita a registrare, ma consente di confrontare versioni diverse di prompt, modelli o strategie di orchestrazione. In questo modo diventa possibile sperimentare, misurare e iterare con metodo, introducendo un approccio quasi scientifico allo sviluppo dei sistemi AI.
- Trasparenza e Responsible AI: il tracciamento dettagliato delle decisioni e la possibilità di allegare spiegazioni o metriche a ogni run trasformano LangSmith in uno strumento utile non solo per gli sviluppatori, ma anche per gli utenti e gli stakeholder, che possono valutare non solo l'output, ma anche il processo che lo ha generato.

Dal punto di vista accademico, LangSmith può essere letto come la risposta a un problema epistemologico delle AI generative: come rendere osservabile l'invisibile. Mentre le architetture LLM operano come sistemi complessi e

opachi, LangSmith costruisce un livello di meta-analisi che permette di interpretarne i comportamenti in chiave empirica. Si tratta dunque di un passaggio metodologico importante: non più solo sviluppo basato sull'intuizione del prompt engineer, ma sviluppo guidato da dati, evidenze e confronti strutturati.

Dal punto di vista progettuale, la piattaforma consente di trasformare una pipeline di raccomandazione basata su LLM da semplice "black box" a sistema auditabile, misurabile e migliorabile. In questo senso, LangSmith si pone come tecnologia abilitante per l'adozione di pratiche di Responsible AI, affiancando l'accuratezza tecnica con criteri di trasparenza e replicabilità.

LangSmith può essere definito come un framework di osservabilità e valutazione per sistemi LLM, che integra monitoraggio, tracciamento e sperimentazione in un unico ambiente. La sua importanza risiede nella capacità di portare i principi della responsabilità, della trasparenza e della valutazione empirica all'interno di applicazioni che, per natura, sono soggette a variabilità e opacità. Lungi dall'essere un semplice strumento accessorio, LangSmith si configura quindi come una componente essenziale nello sviluppo di applicazioni AI moderne, fornendo la base concettuale e infrastrutturale per un uso più consapevole e controllato dei modelli generativi.

4.3.2 Integrazione di LangSmith nel prototipo Career Compass AI

Dopo aver delineato i principi generali di LangSmith, è fondamentale illustrare come lo strumento sia stato concretamente integrato nel prototipo Career Compass AI. L'adozione non è stata una fase di test isolata, ma una componente architetturale integrante della pipeline, finalizzata a garantire osservabilità completa e monitoraggio continuo.

L'integrazione è stata abilitata tramite la configurazione di variabili d'ambiente dedicate nel file `.env` (`LANGCHAIN_TRACING_V2`, `LANGCHAIN_API_KEY`, `LANGCHAIN_PROJECT`). Poiché l'intero sistema utilizza un client LangChain (ChatOpenAI) per interagire con il modello OpenAI, questa semplice configurazione è sufficiente per tracciare automaticamente ogni singola invocazione dell'LLM. Ogni prompt inviato,

risposta ricevuta, consumo di token e latenza viene registrato di default, senza necessità di log manuali.

Per estendere l'osservabilità oltre le sole chiamate LLM e includere la logica custom del backend, è stato utilizzato il decoratore `@traceable`. Questo meccanismo è stato applicato a funzioni cruciali della pipeline, come `run_full_analysis_pipeline` e le funzioni di fallback, in modo che ogni loro esecuzione sia registrata come un *run* contenitore. Tali *run* assumono una funzione gerarchica, organizzando le chiamate interne in una struttura a grafo in cui ogni step appare come “figlio” della funzione che lo ha invocato. Questa rappresentazione non solo offre una visione chiara delle dipendenze e dei flussi di esecuzione, ma consente anche di attribuire responsabilità puntuali a ciascun blocco della pipeline. In pratica, diventa immediato distinguere quale parte del sistema ha generato un errore o un costo eccessivo: ad esempio, un problema di parsing emerso nel fallback è stato rapidamente isolato, senza confondere il resto della pipeline.

Come mostrato nella figura X e nella figura X, la dashboard di LangSmith offre una visione completa della cronologia delle esecuzioni. È possibile ispezionare ogni run per analizzare l'input utente, l'output generato e le metriche quantitative associate (costo, latenza, token). Questa capacità di “zoomare” all'interno della catena di chiamate è stata essenziale per il debugging e per l'ottimizzazione dei prompt, permettendo di confrontare versioni diverse della stessa pipeline e di valutarne in tempo reale l'efficienza.




Figura 9 – Dashboard principale di LangSmith con il progetto *Career-Compass-AI* e statistiche di osservabilità (numero di run, errori e latenza media).¹⁴

Come dichiarato precedentemente l'integrazione di LangSmith ha portato diversi vantaggi fondamentali. Trasparenza del processo: ogni decisione del sistema, dalla selezione delle competenze al ranking finale, è diventata tracciabile e ispezionabile, aumentando la fiducia nel processo. Affidabilità e debugging: eventuali errori o anomalie sono stati registrati e contestualizzati, semplificando drasticamente la diagnosi e la risoluzione dei problemi. Ottimizzazione guidata dai dati: la raccolta automatica di statistiche ha permesso di valutare l'impatto economico e prestazionale delle diverse strategie di prompting, guidando le scelte progettuali verso un uso più efficiente delle risorse.

In conclusione, LangSmith ha trasformato la pipeline di *Career Compass AI* da una sequenza di operazioni a un sistema pienamente osservabile, misurabile e spiegabile, allineando la robustezza tecnica ai principi metodologici della Responsible AI [8,30].

¹⁴ LangChain LangSmith, piattaforma per il debugging, il testing e il monitoraggio di applicazioni basate su LLM. Disponibile su: <https://www.langchain.com/langsmith>




Figura 10 - Visualizzazione di un run completo della pipeline `run_full_analysis_pipeline` su LangSmith, con input utente, output generato e metriche di esecuzione (token, costo, latenza).¹⁵

¹⁵ LangChain LangSmith, piattaforma per il debugging, il testing e il monitoraggio di applicazioni basate su LLM. Disponibile su: <https://www.langchain.com/langsmith>

CAPITOLO 5: Discussione e prospettive future

5.1 Valutazione oggettiva del prototipo: punti di forza e limitazioni

La valutazione del prototipo Career Compass AI mette in evidenza un equilibrio tra elementi di originalità, che ne rafforzano la validità metodologica, e limiti strutturali, che ne tracciano al tempo stesso i margini di miglioramento.

Sul versante dei punti di forza, il contributo più rilevante è rappresentato dall'inedita integrazione tra l'analisi semantica di un Large Language Model e la tassonomia formale ISTAT. Il sistema non si limita a impiegare un modello linguistico in modo generico, ma lo utilizza come un "ponte" per tradurre il linguaggio naturale e non strutturato degli utenti in codici e categorie ufficiali, rafforzando così l'aderenza agli standard istituzionali. Questo approccio è sostenuto da un'architettura multi-stadio, in cui ogni modulo della pipeline (validazione, retrieval, ranking, audit etico) possiede responsabilità chiare e isolate. Tale modularità è resa ancora più solida dall'osservabilità end-to-end garantita da LangSmith, che consente di monitorare costi, latenze e decisioni, trasformando quella che normalmente sarebbe una "scatola nera" in un processo ispezionabile e controllabile. A ciò si aggiunge la robustezza metodologica, concretizzata da meccanismi come il sistema di fallback, che preserva la continuità operativa, e dall'integrazione di un audit di fairness, che allinea il progetto ai principi della Responsible AI.

Sul versante delle limitazioni, emergono tre aspetti principali. Anzitutto, l'efficacia complessiva della pipeline dipende fortemente dalla qualità e dalla granularità dell'input fornito dall'utente. Sebbene la funzione di validazione agisca da filtro preliminare, profili incompleti o fuorvianti possono generare estrazioni di competenze imprecise e raccomandazioni subottimali. In secondo luogo, nonostante l'uso di chiamate concorrenti, il sistema resta inevitabilmente esposto alla latenza delle API esterne (INAPP e OpenAI), un fattore esogeno solo parzialmente mitigabile. Infine, la criticità più significativa riguarda il potenziale bias intrinseco del modello linguistico. L'audit implementato rappresenta un passo importante per la rilevazione

delle distorsioni, ma non ne consente l'eliminazione: i pregiudizi presenti nei dati di addestramento possono influenzare, anche in modo sottile, le fasi di classificazione e di ranking.

Un'analisi critica dei risultati, con particolare riferimento alla Figura 7 - Visualizzazione dei percorsi professionali correlati suggeriti dal prototipo, consente di individuare le cause strutturali alla base delle deviazioni talvolta osservate nelle raccomandazioni. In primo luogo, un fattore determinante risiede nella natura dei dati esterni e nella mappatura ufficiale ISTAT/INAPP, che associa le competenze a un ampio ventaglio di professioni non sono sempre percepite come coerenti dall'utente. Ne consegue che il sistema, pur operando correttamente in termini di adesione alle tassonomie, può restituire connessioni considerate poco intuitive. In secondo luogo, l'interpretazione operata dall'LLM rappresenta un'ulteriore fonte di variabilità: l'adozione del modello "gpt-4o-mini", sebbene ottimale per il rapporto costo-prestazioni, comporta una minore capacità di cogliere sfumature semantiche e può condurre sia all'estrazione non ottimale di competenze marginali, sia a errori di classificazione nelle macro-categorie ISTAT, con effetti sull'intero flusso di selezione. Un terzo elemento riguarda la logica di aggregazione e ranking, fondata su una somma dei contributi parziali delle competenze: ciò favorisce l'emersione di professioni generaliste con molte corrispondenze deboli a discapito di profili specialistici caratterizzati da poche corrispondenze forti. Infine, una causa specifica per la generazione delle "professioni affini" risiede nella struttura gerarchico-settoriale della classificazione ISTAT, che definisce l'affinità sulla base della prossimità dei codici piuttosto che sulla somiglianza percepita delle mansioni. In sintesi, le deviazioni osservate non sono riconducibili a malfunzionamenti puntuali, ma riflettono l'interazione tra vincoli dei dati istituzionali, limiti interpretativi del modello linguistico, scelte metodologiche di aggregazione e criteri normativi di affinità: fattori che, nel loro insieme, spiegano la distanza talvolta percepita e spesso non presente tra le raccomandazioni del sistema e le aspettative degli utenti.

Career Compass AI si configura come un prototipo funzionale e metodologicamente solido. I limiti individuati non ne compromettono la

validità complessiva, ma definiscono traiettorie concrete di perfezionamento, sia sul piano tecnico sia sul piano etico-metodologico, aprendo la strada a sviluppi futuri [8].

5.2 Considerazioni etiche e bias

5.2.1 Il quadro normativo europeo e le sue implicazioni etiche

L'Artificial Intelligence Act dell'Unione Europea rappresenta il primo tentativo organico, a livello globale, di disciplinare l'intelligenza artificiale con un approccio orizzontale e uniforme. Si tratta di una normativa pionieristica che nasce dall'esigenza di tutelare i diritti fondamentali delle persone e di assicurare che l'impiego dei sistemi di IA sia conforme ai principi di sicurezza, trasparenza e responsabilità. La filosofia alla base dell'AI Act è quella del cosiddetto risk-based approach: non tutte le applicazioni di IA comportano lo stesso grado di rischio; pertanto, le misure regolatorie devono essere proporzionate al livello di impatto potenziale sui cittadini e sulla società. Per tale ragione, l'atto classifica i sistemi in quattro livelli di rischio: inaccettabile, alto, limitato e minimo. I sistemi ritenuti a rischio inaccettabile, come quelli di manipolazione cognitiva subliminale o di sorveglianza sociale di massa, vengono vietati. Per contro, la maggior parte delle applicazioni a rischio minimo o limitato rimangono soggette a obblighi ridotti o a requisiti di trasparenza leggera. È nella categoria dei sistemi ad alto rischio che si concentra l'attenzione normativa e dove si colloca il progetto Career Compass AI, in quanto strumento che incide direttamente sull'accesso all'inquadramento professionale e al lavoro, rientrando espressamente nelle ipotesi previste dall'articolo 6 e dall'Allegato III.

La classificazione come sistema ad alto rischio ha conseguenze significative. In primo luogo, essa riconosce che le decisioni o raccomandazioni fornite da tali sistemi possono determinare effetti rilevanti sulla vita delle persone, condizionando traiettorie professionali e opportunità di crescita. La scelta del legislatore europeo di inserire l'orientamento al lavoro tra gli ambiti sensibili risponde a una precisa visione etica: il lavoro è considerato non solo un mezzo di sostentamento, ma un diritto fondamentale legato alla dignità

umana, alla non discriminazione e all'uguaglianza di accesso. Pertanto, l'impiego di sistemi automatizzati in questo dominio deve avvenire con presidi normativi rigorosi che riducano al minimo i rischi di esclusione e discriminazione, prevenendo effetti indesiderati di automazione opaca e bias algoritmici.

L'AI Act, nel dettaglio, stabilisce una serie di obblighi stringenti per i sistemi ad alto rischio. L'articolo 9 introduce il principio della gestione del rischio, imponendo che i fornitori adottino un sistema documentato e continuo per l'identificazione, l'analisi e la mitigazione dei rischi durante l'intero ciclo di vita dell'applicazione. Ciò significa che l'IA non può essere intesa come un prodotto statico rilasciato sul mercato, ma come un processo dinamico soggetto a monitoraggio costante. Dal punto di vista etico, questo si traduce nell'assunzione di responsabilità preventiva: non basta reagire a posteriori agli effetti indesiderati, ma occorre predisporre strumenti di prevenzione capaci di anticipare l'emersione di bias e discriminazioni.

L'articolo 10 si concentra sulla qualità e sulla governance dei dati, stabilendo che i dataset utilizzati per l'addestramento, la validazione e l'impiego operativo siano completi, rappresentativi e pertinenti, evitando così lacune sistematiche e distorsioni che potrebbero tradursi in pregiudizi. Questo requisito richiama il principio etico della giustizia sostanziale: l'accuratezza delle raccomandazioni dipende direttamente dalla capacità dei dati di riflettere la diversità reale della popolazione. Utilizzare dati incompleti o distorti significa, di fatto, perpetuare squilibri e disuguaglianze.

Un altro punto centrale è rappresentato dall'articolo 13, che impone obblighi di trasparenza e di informazione agli utenti. Secondo il regolamento, le persone che interagiscono con un sistema di IA devono essere messe in grado di sapere che stanno dialogando con una tecnologia e devono comprendere, in modo chiaro e accessibile, le capacità, i limiti e i criteri di funzionamento del sistema. Si tratta di un elemento cruciale per sistemi come Career Compass AI, che forniscono raccomandazioni in ambiti sensibili: la trasparenza consente di ridurre l'asimmetria informativa tra sviluppatori e utilizzatori, favorendo fiducia e consapevolezza critica. Senza questa

chiarezza, l'utente rischia di percepire le raccomandazioni come verità indiscutibili, mentre esse derivano da processi probabilistici e soggetti a margini di errore.

L'articolo 14 prevede che i sistemi ad alto rischio siano soggetti a sorveglianza umana effettiva, garantendo che la responsabilità ultima delle decisioni non venga mai delegata interamente alla macchina. Il legislatore introduce qui un principio cardine di accountability: l'essere umano deve restare "nel ciclo", con possibilità di intervenire, correggere o bloccare esiti indesiderati. In ambito di orientamento professionale, ciò implica che le raccomandazioni generate dall'IA non possano essere considerate prescrittive o vincolanti, ma debbano rimanere integrate in un processo di supporto decisionale supervisionato da operatori qualificati.

L'articolo 15, infine, stabilisce che i sistemi ad alto rischio debbano garantire accuratezza, robustezza e sicurezza cibernetica. Ciò comporta che le performance siano affidabili e costanti, che l'applicazione sia resiliente di fronte a errori o condizioni di utilizzo impreviste e che sia protetta da attacchi che potrebbero manipolare i risultati. Questo requisito non ha solo una valenza tecnica, ma anche etica, in quanto la fiducia dell'utente dipende dalla stabilità e dalla sicurezza del sistema. Un orientatore che genera raccomandazioni incoerenti o vulnerabili a manipolazioni perderebbe legittimità e rischierebbe di produrre conseguenze negative sulle scelte di vita delle persone.

Questi articoli delineano una cornice normativa che riflette principi etici consolidati: responsabilità, trasparenza, prevenzione della discriminazione e tutela dei diritti fondamentali. L'AI Act non si limita a stabilire requisiti formali, ma traduce in obblighi giuridici valori di equità e fiducia. In tale prospettiva, la classificazione di Career Compass AI come sistema ad alto rischio non è una penalizzazione, ma un riconoscimento della delicatezza del suo ruolo e della necessità di svilupparlo in linea con standard di massima responsabilità.

Il quadro si arricchisce se si mette a confronto l'AI Act con le Ethics Guidelines for Trustworthy AI pubblicate dalla Commissione Europea nel 2019. Le linee guida, di natura non vincolante, identificano tre principi cardine: liceità, eticità e robustezza. Esse ribadiscono che i sistemi devono rispettare la normativa vigente, essere sviluppati in accordo con principi etici condivisi e funzionare in modo tecnicamente solido e sicuro. L'AI Act recepisce questa impostazione e la trasforma in un regime vincolante: ciò che prima era "soft law" diventa ora diritto positivo. Questa evoluzione normativa mostra come l'Europa stia consolidando la propria visione di un'IA antropocentrica, centrata sull'uomo e orientata alla protezione dei diritti.

Il Regolamento europeo sull'intelligenza artificiale costituisce non solo uno strumento di compliance giuridica, ma anche un ancoraggio etico per lo sviluppo di sistemi come Career Compass AI. La sua applicazione garantisce che l'orientamento professionale automatizzato avvenga in un quadro di responsabilità, prevenzione e tutela, riducendo al minimo il rischio che le tecnologie riproducano o amplifichino disuguaglianze esistenti. Collocarsi entro questa cornice normativa significa, per il prototipo, non solo rispettare obblighi formali, ma aderire a un modello di intelligenza artificiale che mira a essere al servizio delle persone e della società, rafforzando fiducia e legittimità [31].

5.2.2 Il quadro accademico della fairness: dal binario al multiclasse e multigruppo

Il dibattito accademico sulla fairness algoritmica ha conosciuto negli ultimi anni una crescita esponenziale, trainata dalla consapevolezza che i sistemi di intelligenza artificiale, in particolare quelli di raccomandazione e user modeling, non siano semplicemente strumenti neutri di supporto decisionale, ma attori in grado di condizionare attivamente percorsi individuali e dinamiche sociali. In questo contesto si colloca l'articolo di Purificato, Boratto e De Luca (2024), che affronta uno dei nodi più delicati della valutazione etica dei sistemi basati su modelli grafici e reti neurali: la riduzione artificiosa degli attributi sensibili a categorie binarie e i rischi che

tale prassi comporta. La letteratura tradizionale, infatti, ha consolidato l'uso di metriche di fairness fondate su una visione dicotomica degli attributi, tipicamente declinati in coppie come uomo/donna, maggioranza/minoranza, under/over 30. Questa semplificazione ha avuto l'indubbio vantaggio di rendere trattabili problemi complessi, consentendo l'applicazione di formule statistiche consolidate, ma al prezzo di un drastico impoverimento concettuale. Gli autori sottolineano come questa pratica non solo alteri le condizioni originarie, ma rischi di mascherare discriminazioni sottili, occultandole dietro l'illusione di una parità apparente tra due soli gruppi. La riduzione binaria, lungi dall'essere una neutralizzazione, è in realtà una distorsione: comprime la varietà dei sottogruppi e finisce per celare le forme più insidiose di disparità, quelle che si manifestano non tra macro-categorie aggregate, ma all'interno delle stesse, lungo linee di frattura più sottili.

Per argomentare questa tesi, gli autori fanno riferimento a due concetti centrali della letteratura sulla fairness: il *disparate impact* e il *disparate mistreatment*. Il primo misura l'equità distributiva delle decisioni algoritmiche, osservando se la probabilità di ottenere un esito favorevole varia significativamente tra gruppi definiti da attributi sensibili. Il secondo valuta invece la distribuzione degli errori, mettendo in luce se certi gruppi subiscono un tasso più elevato di falsi positivi o falsi negativi. In entrambi i casi, l'applicazione standard di tali metriche presuppone che i gruppi siano due, e che le differenze da indagare siano polarizzabili lungo una linea di separazione binaria. Questa impostazione, sostengono gli autori, non è più sufficiente a descrivere scenari reali, nei quali gli attributi sensibili hanno natura multiclasse (si pensi alle fasce di età, ai livelli di istruzione, alle appartenenze culturali) e le decisioni da valutare non si riducono a un esito binario, ma possono assumere molteplici valori. Continuare a utilizzare metriche binarie in un mondo multiclasse significa perpetuare un'asimmetria metodologica che, lungi dal garantire equità, rischia di perpetuare disuguaglianze invisibili.

L'innovazione proposta dall'articolo consiste nell'estensione di un insieme di metriche consolidate - *statistical parity*, *equal opportunity*, *overall accuracy*

equality e treatment equality - a scenari multiclasse e multigruppo. Tale estensione, di natura sia concettuale sia matematica, consente di valutare se l'algoritmo mantenga un comportamento equo non solo tra due gruppi aggregati, ma tra l'insieme articolato delle categorie che compongono l'attributo sensibile. In questo modo è possibile verificare, ad esempio, se una raccomandazione penalizza sistematicamente una specifica fascia d'età, o se gli errori di classificazione si concentrano su un particolare sottogruppo culturale, anche quando l'analisi binaria globale suggerirebbe un equilibrio complessivo. Il contributo metodologico risiede dunque nella possibilità di ottenere un'analisi fine-grained, capace di intercettare discriminazioni nascoste e di restituire un'immagine più aderente alla complessità sociale.

L'applicazione concreta di questo approccio avviene nel dominio dello user modeling basato su Graph Neural Networks (GNN), una delle aree più promettenti ma anche più delicate dell'intelligenza artificiale contemporanea. Le GNN, grazie alla loro capacità di modellare relazioni complesse e interazioni multilivello, sono sempre più utilizzate per costruire profili utente e per generare raccomandazioni personalizzate. Tuttavia, proprio la loro potenza espressiva aumenta il rischio che i bias presenti nei dati o nella struttura del grafo vengano amplificati, producendo effetti discriminatori difficilmente rilevabili con strumenti tradizionali. Purificato, Boratto e De Luca applicano le metriche estese a contesti reali, utilizzando modelli come CatGCN e RHGN e dataset di ampia scala (tra cui Alibaba, JD, Pokec, NBA). I risultati sperimentali mostrano in maniera convincente come la valutazione binaria tenda a celare criticità che emergono invece con forza nell'analisi multiclasse. Un sistema può apparire "fair" se giudicato solo sulla base di una dicotomia uomo/donna, ma rivelarsi discriminatorio se si considerano sottogruppi più specifici, come fasce d'età intermedie o gruppi sociali meno numerosi. Questa evidenza empirica dimostra che la binarizzazione non è soltanto una limitazione metodologica, ma una vera e propria forma di opacità etica, in quanto priva la comunità di una visione autentica delle disparità in atto.

L'impatto del lavoro non si esaurisce nella dimensione tecnica. Gli autori insistono sulla necessità di intendere la fairness come parte integrante di una progettazione responsabile, in linea con i principi della Responsible AI e della Human-Centered AI. L'adozione di metriche multiclasse e multigruppo non è soltanto una questione di accuratezza più raffinata, ma un passo verso la giustizia sostanziale: significa riconoscere la pluralità delle identità umane e garantire che nessun sottogruppo resti invisibile all'analisi. In altre parole, la fairness responsabile non si accontenta di mostrare un equilibrio apparente tra due poli, ma mira a restituire un quadro completo e articolato, capace di far emergere disuguaglianze strutturali e di orientare strategie di mitigazione più efficaci.

Questo approccio ha implicazioni profonde per il dominio dell'orientamento professionale. Un sistema che si limiti a garantire parità tra due macro-categorie rischia di trascurare i bisogni di gruppi minoritari o di individui situati ai margini delle classificazioni tradizionali. Viceversa, un'analisi multiclass consente di individuare con precisione dove si concentrano le esclusioni e di intervenire in modo mirato per ridurle. L'etica della fairness, in questa prospettiva, diventa un esercizio di responsabilità sociale, volto a garantire che le tecnologie di raccomandazione non amplifichino disuguaglianze già esistenti, ma si pongano come strumenti di inclusione e giustizia.

Il contributo accademico di Purificato, Boratto e De Luca segna un avanzamento significativo nella riflessione sulla fairness algoritmica. La critica alla binarizzazione e la proposta di estensione multiclasse e multigruppo rappresentano un passo essenziale per superare approcci riduttivi e per ancorare la valutazione dell'IA a principi di equità più robusti e responsabili. Collocato all'interno del dibattito internazionale, questo lavoro non solo fornisce strumenti concettuali e metriche più efficaci, ma afferma un principio etico di fondo: la giustizia non può essere compressa in una dicotomia, ma deve essere valutata nella sua complessità, riconoscendo la pluralità dei soggetti e la diversità delle esperienze. È in questa direzione che l'accademia contribuisce a definire i contorni di una intelligenza

artificiale realmente centrata sull'uomo, capace di integrare rigore metodologico e responsabilità sociale [3,4].

5.3 Miglioramenti e sviluppi futuri

5.3.1 Miglioramenti funzionali e metodologici

Un primo insieme di sviluppi futuri riguarda l'evoluzione funzionale e metodologica del prototipo, con l'obiettivo di consolidarne l'affidabilità e di arricchirne l'esperienza d'uso. Una naturale traiettoria di crescita consiste nell'integrazione di funzionalità tipiche dei chatbot conversazionali, così da permettere all'utente di interagire con il sistema in modo più fluido e naturale. A questo scopo si immagina l'introduzione di moduli per la gestione delle registrazioni e dei login, che consentano di profilare gli utenti in maniera personalizzata e sicura, nonché la possibilità di mantenere uno storico delle conversazioni, così da dare continuità all'interazione e contestualizzare le risposte. L'evoluzione verso una dimensione conversazionale costituirebbe la naturale prosecuzione dell'approccio finora adottato, e consentirebbe di arricchire la pipeline con funzionalità di memoria e di contestualizzazione dinamica.

Un secondo ambito di miglioramento riguarda la gestione delle deviazioni osservate nei risultati, come evidenziato nella Figura 7 - Visualizzazione dei percorsi professionali correlati suggeriti dal prototipo Career Compass AI a partire dal profilo utente. Nella figura, infatti, emerge una professione affine che appare incoerente con il contesto, fenomeno che richiede una riflessione metodologica per comprenderne le cause e ridurre l'incidenza futura. L'analisi condotta ha messo in luce diversi fattori che concorrono a spiegare tali anomalie. La prima e più significativa causa risiede nella natura dei dati esterni su cui il sistema si appoggia. La mappatura ufficiale ISTAT/INAPP tra competenze e professioni, pur essendo standardizzata e istituzionalmente riconosciuta, non è sempre intuitiva dal punto di vista dell'utente. Una singola competenza può infatti essere collegata a professioni appartenenti a settori anche molto distanti tra loro. Quando la funzione di estrazione seleziona una competenza, la chiamata all'API restituisce tutte le professioni

ad essa associate, incluse quelle che appaiono “fuori tema”. Se tali professioni ottengono un punteggio elevato nella fase di aggregazione, finiscono per emergere nei risultati finali. In questo senso il sistema non sbaglia, ma si limita a riflettere fedelmente connessioni già presenti nella base dati ufficiale, sebbene percepite come incoerenti dall’utente.

Una seconda causa può essere ricondotta ai limiti interpretativi del modello linguistico adottato. L’attuale configurazione si basa su una versione “mini” che, pur eccellente per rapporto costo-prestazioni, è meno capace di cogliere sfumature sottili e contesti complessi rispetto a modelli più estesi. Ciò può condurre a errori di estrazione, in cui viene enfatizzata una competenza solo marginalmente citata dall’utente ma fortemente pesata dal database, con effetti distorsivi sulle raccomandazioni. Può inoltre verificarsi un errore di classificazione, nel quale il modello colloca il profilo in una macro-categoria ISTAT sbagliata: in questo caso, la logica di filtraggio delle professioni a valle esclude opzioni corrette e include invece categorie non pertinenti.

Un terzo elemento critico è costituito dalla logica di aggregazione e ranking. L’algoritmo che calcola i punteggi tende a sommare i contributi di tutte le competenze estratte, il che può favorire l’emersione di professioni generaliste che, pur presentando corrispondenze mediocri su più competenze, ottengono un punteggio complessivo superiore a professioni altamente coerenti con poche competenze chiave. In questo modo, la struttura stessa del ranking può far emergere risultati percepiti come meno rilevanti o addirittura fuorvianti.

Infine, un’ulteriore fonte di deviazioni è specifica della funzione di individuazione delle “professioni affini”. L’ISTAT definisce la vicinanza tra professioni sulla base della somiglianza dei codici, secondo una logica gerarchica e settoriale. Ne consegue che professioni molto diverse sul piano delle mansioni possono risultare affini perché appartenenti allo stesso gruppo classificatorio. Ciò spiega perché il sistema possa restituire come affini professioni che, dal punto di vista dell’utente, appaiono radicalmente diverse.

Questi fenomeni, nel loro complesso, non devono essere interpretati come malfunzionamenti, ma come l’esito di scelte metodologiche e di vincoli

strutturali. Nei passi futuri sarà tuttavia essenziale introdurre meccanismi che riducano l'incidenza di queste anomalie, ad esempio mediante un affinamento della logica di aggregazione, una ponderazione più sofisticata dei punteggi e, se necessario, l'impiego di modelli linguistici più potenti. In prospettiva, il miglioramento del prototipo passerà dunque per tre direttrici complementari: l'arricchimento delle funzionalità conversazionali, la gestione più accurata delle deviazioni derivanti dalle basi dati istituzionali e dai limiti del modello linguistico, e l'ottimizzazione della logica di ranking. Tali sviluppi, nel loro insieme, contribuiranno a rendere il sistema più robusto, coerente e capace di rispondere alle aspettative degli utenti, rafforzando così la sua credibilità come strumento di orientamento professionale responsabile [8].

5.3.2 Sviluppi futuri ispirati al quadro accademico

Lo sviluppo futuro più rilevante per il prototipo Career Compass AI riguarda l'evoluzione dell'approccio alla fairness, passando da un audit puramente qualitativo a una valutazione quantitativa basata su metriche oggettive. Attualmente, la funzione `perform_fairness_audit` chiede al modello linguistico di ragionare in maniera discorsiva sugli eventuali bias presenti nelle raccomandazioni. Si tratta di una soluzione importante, che ha il merito di introdurre consapevolezza e di comunicare in termini accessibili all'utente potenziali criticità, ma che rimane ancorata a un livello descrittivo e qualitativo. Il progetto accademico di riferimento dimostra invece come sia possibile e auspicabile ancorare la fairness a metriche matematiche formalizzate, capaci di restituire un quadro misurabile, verificabile e riproducibile delle disparità. Questo passaggio costituisce la trasformazione più significativa che il prototipo dovrà intraprendere per acquisire maggiore rigore scientifico e conformità rispetto alle pratiche più avanzate della ricerca.

Le metriche quantitative implementate nel progetto di ricerca - tra cui *statistical parity*, *equal opportunity*, *overall accuracy equality* e *treatment equality* - rappresentano un insieme coerente di strumenti per la misurazione del bias. La *statistical parity* analizza la probabilità che diversi gruppi

ricevano esiti favorevoli, confrontando la distribuzione delle raccomandazioni per verificare se esista un equilibrio proporzionale. La equal opportunity valuta invece se le persone appartenenti a diversi sottogruppi abbiano pari probabilità di ricevere una raccomandazione corretta in presenza delle stesse condizioni di partenza. La overall accuracy equality estende questo concetto verificando che la precisione complessiva del sistema sia uniforme tra i gruppi, mentre la treatment equality misura la simmetria nella distribuzione degli errori, osservando se un gruppo subisca in misura sproporzionata falsi positivi o falsi negativi. L'introduzione di queste metriche nel prototipo significherebbe affiancare alla valutazione qualitativa un set di indicatori numerici che rendono la fairness una proprietà osservabile, replicabile e monitorabile nel tempo.

L'integrazione concreta di tali metriche richiede alcuni passaggi metodici. Il primo passo riguarda la raccolta di dati sensibili, da effettuare in modo opzionale e con il pieno consenso dell'utente, nel rispetto delle normative sulla privacy e del principio di autodeterminazione informativa. Variabili come l'età, il genere o il background formativo potrebbero essere richieste esclusivamente per finalità di valutazione interna, con la possibilità per l'utente di rifiutare senza subire alcuna limitazione nei servizi offerti. In secondo luogo, questi dati andrebbero utilizzati per costruire un dataset di valutazione con cui condurre test di stress sul sistema, simulando scenari d'uso eterogenei e controllando come le raccomandazioni varino al mutare dei gruppi di appartenenza. Una volta raccolto un campione adeguato, sarebbe possibile applicare le metriche quantitative e calcolare, ad esempio, la deviazione della parità statistica per una determinata fascia di età o la differenza nei tassi di errore tra utenti con background diversi.

Il passo successivo consisterebbe nella traduzione di queste valutazioni in una forma comunicabile e comprensibile, capace di restituire all'utente e agli stakeholder istituzionali non solo un giudizio qualitativo, ma anche un'evidenza numerica. L'idea è quella di introdurre una sezione avanzata del report generato dal sistema, dove accanto alle spiegazioni discorsive offerte dal modello si presenti un pannello con indicatori sintetici e visualizzazioni

grafiche. Ad esempio, si potrebbe includere un istogramma che mostri la deviazione percentuale dalla parità statistica tra fasce d'età, o una tabella che confronti i tassi di errore per diversi gruppi. In questo modo, la fairness non sarebbe più percepita come un'opinione del sistema, ma come un attributo misurabile, con valori concreti che possono essere confrontati nel tempo o tra diverse versioni del prototipo.

Un ulteriore elemento da ereditare dal progetto di ricerca riguarda la possibilità di estendere queste metriche oltre la logica binaria, applicandole a scenari multiclasse e multigruppo. La letteratura ha ampiamente dimostrato che la riduzione di attributi complessi a dicotomie semplificate tende a mascherare disuguaglianze più sottili e interne ai gruppi. Per questa ragione, l'adozione di metriche multiclasse consentirebbe di analizzare l'equità delle raccomandazioni lungo più dimensioni, identificando con maggiore precisione i sottogruppi penalizzati. In termini pratici, questo significa che il sistema non si limiterebbe a verificare, ad esempio, la parità tra uomini e donne, ma sarebbe in grado di distinguere come le raccomandazioni variano tra fasce d'età specifiche, livelli educativi o combinazioni di caratteristiche. L'estensione multigruppo permette inoltre di osservare l'interazione tra più attributi sensibili, restituendo un quadro realistico delle discriminazioni intersezionali.

L'inserimento di metriche quantitative di fairness nel prototipo trasformerebbe l'intera architettura metodologica, con benefici tangibili in termini di rigore e credibilità. La misurazione oggettiva permetterebbe di monitorare l'evoluzione del sistema nel tempo, individuando eventuali derive discriminatorie e intervenendo in modo mirato per correggerle. Inoltre, offrirebbe la possibilità di confrontare le prestazioni di diverse versioni o configurazioni del sistema sulla base di criteri non solo tecnici, ma anche etici, rendendo la fairness un parametro integrato nel ciclo di sviluppo. Dal punto di vista della ricerca, questo approccio consentirebbe di collocare Career Compass AI in continuità con i contributi più avanzati della comunità scientifica, dimostrando la capacità di recepire e implementare standard metodologici di frontiera.

Accanto a questa evoluzione centrale, altri due filoni di sviluppo futuri possono essere tratti dal progetto accademico. Il primo riguarda l'introduzione di un ranking ibrido che combini punteggi oggettivi e valutazioni qualitative. Attualmente, il ranking del prototipo si articola in due fasi: un'aggregazione quantitativa basata sulla rilevanza delle competenze e un ordinamento finale operato dal modello linguistico. Il progetto suggerisce la possibilità di fondere queste due logiche, introducendo un punteggio di affidabilità del matching calcolato sulla base di metriche ISTAT e utilizzando l'LLM non per sovrascrivere, ma per rifinire l'ordinamento. Una formula ibrida, che ponderi il punteggio oggettivo con il relevance score qualitativo, permetterebbe di rendere le raccomandazioni meno dipendenti dalla soggettività del modello e più ancorate a criteri trasparenti, migliorando al tempo stesso coerenza e spiegabilità.

Il secondo filone, di più lungo termine, riguarda la possibilità di utilizzare i grafi come struttura portante del sistema, introducendo modelli di Graph Neural Network per apprendere dalle relazioni tra utenti, competenze e professioni. L'attuale architettura, basata su analisi indipendenti e stateless, potrebbe evolvere in un grafo della conoscenza in cui nodi e archi rappresentano rispettivamente entità e relazioni. Tale rappresentazione consentirebbe di sfruttare non solo il profilo del singolo utente, ma anche le connessioni tra individui con competenze simili e traiettorie professionali correlate. L'adozione di GNN, in una fase più avanzata, permetterebbe di predire collegamenti mancanti e suggerire percorsi professionali emergenti, trasformando il prototipo da un consulente "one-shot" a un sistema dinamico e collettivo, capace di apprendere continuamente dalle interazioni.

Lo sviluppo futuro di Career Compass AI si articola in tre traiettorie interconnesse: il passaggio cruciale dall'audit qualitativo a metriche quantitative di fairness, l'adozione di un ranking ibrido che bilanci oggettività e contesto qualitativo, e l'esplorazione dell'uso dei grafi per modellare le relazioni tra utenti, competenze e professioni. Tra queste, la priorità assoluta è rappresentata dall'integrazione delle metriche di fairness, perché è da questo salto metodologico che dipende la credibilità etica e

scientifica del prototipo. Rendere la fairness una proprietà misurabile e non solo descritta significa trasformare un esercizio di consapevolezza in una pratica di responsabilità, avvicinando il progetto a una vera conformità con i principi della Responsible AI e ai più avanzati standard accademici [3,4].

CAPITOLO 6: Conclusioni

6.1 Sintesi del lavoro svolto

L'intero lavoro di ricerca e di progettazione qui esposto ha avuto come obiettivo principale quello di indagare, progettare e dimostrare la fattibilità di un sistema di classificazione professionale basato sull'impiego dei Large Language Models (LLM), arricchiti dall'integrazione con tassonomie ufficiali e fonti istituzionali, al fine di restituire uno strumento che non sia soltanto tecnologicamente avanzato, ma che ponga le basi verso i principi della Responsible AI. La tesi ha preso avvio dal riconoscimento di un contesto socio-economico caratterizzato da profonde trasformazioni: la crescente digitalizzazione, l'evoluzione del mercato del lavoro, la discontinuità dei percorsi professionali e l'emergere di nuove competenze richieste in settori ad alto dinamismo. In tale scenario, la capacità di accompagnare individui e organizzazioni nella scelta consapevole e informata di traiettorie professionali rappresenta una sfida cruciale, tanto per i singoli quanto per la collettività.

La trattazione ha mostrato come l'orientamento non possa più essere ridotto a un mero esercizio di matching tra competenze dichiarate e professioni disponibili, bensì debba essere concepito come un processo complesso e multilivello, nel quale si intrecciano fattori individuali, cognitivi e motivazionali, con dimensioni esterne quali le dinamiche di mercato, i vincoli territoriali e le condizioni istituzionali. L'adozione di modelli linguistici di grandi dimensioni risponde a questa esigenza nella misura in cui consente di rappresentare e interpretare linguaggi naturali complessi, rendendo possibile una mediazione tra il vissuto soggettivo dell'utente e la rigidità delle classificazioni ufficiali. Al contempo, il lavoro ha evidenziato che l'impiego di tali modelli non può prescindere da un'integrazione strutturata con basi di conoscenza validate e condivise: da qui la scelta di fondare il sistema su codifiche ISTAT e INAPP, così da garantire all'output un ancoraggio istituzionale e una traducibilità immediata in percorsi concreti.

La parte centrale del lavoro ha descritto l'architettura del prototipo "Career Compass AI", illustrando come esso si articoli in più moduli: dalla profilazione iniziale, che cattura inclinazioni, competenze e aspirazioni, alla fase di retrieval e ranking, fino all'introduzione di moduli opzionali, quali quello per le professioni affini. Quest'ultimo, in particolare, si è rivelato un elemento distintivo, in grado di mostrare percorsi alternativi e di ampliare l'orizzonte delle opportunità senza rinchiudere l'utente entro schemi rigidi. Tale approccio ha consentito di rispondere a una delle principali lacune emerse dalla letteratura scientifica analizzata: la difficoltà di conciliare personalizzazione e trasparenza, esplorando vie che possano essere al tempo stesso innovative e fedeli a principi di equità.

La sperimentazione ha altresì mostrato come l'integrazione con fonti esterne comporti inevitabilmente rischi di incoerenza e di rumorosità. Alcuni casi di suggerimenti apparentemente lontani dalle aspettative dell'utente sono stati interpretati come effetto di mappature istituzionali non sempre intuitive, a conferma di quanto l'intelligenza artificiale, pur sofisticata, sia profondamente dipendente dalla qualità e dalla struttura dei dati di partenza. Tale constatazione non deve essere letta come un limite insormontabile, ma come una direzione di ricerca futura, orientata a un progressivo affinamento delle interfacce tra modelli linguistici e sistemi di classificazione esterni.

Nel corso della tesi è stato dato ampio spazio al tema della Responsible AI, con particolare riferimento ai rischi di bias, disparità e mancanza di trasparenza. L'analisi dei contributi teorici e delle metriche di fairness applicabili ha sottolineato che l'adozione di LLM in ambito di orientamento professionale porta con sé questioni etiche non eludibili: la possibilità che determinate categorie di utenti vengano penalizzate, che si riproducano schemi di disuguaglianza preesistenti o che la logica algoritmica resti opaca agli occhi di chi riceve le raccomandazioni. Per tale ragione, il progetto ha posto l'accento non solo sull'accuratezza tecnica, ma anche sulla spiegabilità delle decisioni e sull'inclusione di strumenti di monitoraggio delle prestazioni.

Le analisi condotte, sia a livello concettuale sia tecnico, hanno quindi dimostrato che un sistema di orientamento basato su LLM può rappresentare una valida innovazione nel panorama dei servizi di supporto alla carriera, purché venga continuamente bilanciato da una cornice etica e regolatoria. In questo senso, la tesi si inserisce all'interno di un filone di ricerca più ampio, quello dei sistemi di raccomandazione lavorativa, contribuendo ad esso con un approccio originale: l'integrazione tra modelli di intelligenza artificiale di ultima generazione e tassonomie ufficiali, mediata da principi di responsabilità e centratura sull'utente.

Un altro elemento di rilievo emerso dalla trattazione riguarda la dimensione della human-centredness. L'orientamento professionale non può ridursi a un calcolo statistico o a un output deterministico: deve restituire all'utente il senso di un percorso personalizzato, rispettoso delle sue aspirazioni e capace di essere compreso. Da qui deriva la scelta di dotare il prototipo di funzionalità conversazionali, che, seppur ancora in una fase embrionale, hanno mostrato le potenzialità di un'interazione naturale, in grado di favorire fiducia e coinvolgimento. È proprio questa capacità di restituire agency all'utente che segna la differenza tra un mero strumento di matching e un vero e proprio assistente digitale orientativo.

In prospettiva, i miglioramenti futuri individuati si collocano lungo tre assi principali. Il primo riguarda il potenziamento dei modelli sottostanti, con l'adozione di versioni più robuste e specializzate, capaci di mitigare gli errori di inferenza e di gestire meglio la complessità delle classificazioni esterne. Il secondo concerne l'arricchimento dei dati e la riduzione delle incoerenze derivanti da mappature ufficiali non sempre trasparenti, attraverso un lavoro di co-progettazione con enti istituzionali e di continuo aggiornamento delle basi informative. Il terzo asse, infine, riguarda la dimensione etica e regolatoria: sarà fondamentale affiancare allo sviluppo tecnologico strumenti di audit, di valutazione dell'impatto sociale e di governance che permettano di mantenere alta la fiducia degli utenti e di promuovere un utilizzo responsabile.

In definitiva, la tesi ha inteso dimostrare come l'unione tra intelligenza artificiale, tassonomie ufficiali e principi di responsabilità possa dare origine a un sistema innovativo e sostenibile di orientamento professionale. L'obiettivo non è stato quello di fornire una soluzione definitiva, ma di aprire una strada di ricerca e di sperimentazione: una strada che vede l'AI non come sostituto del giudizio umano, ma come suo alleato, capace di amplificare opportunità, di ridurre barriere informative e di contribuire a una società più equa e inclusiva.

Il lavoro svolto, pur con i suoi limiti, rappresenta dunque un tassello in un campo ancora in piena evoluzione. Esso pone al centro l'idea che un sistema di orientamento debba essere, prima di tutto, umanamente rilevante: capace di accompagnare, spiegare e supportare, senza imporre percorsi predefiniti, ma restituendo all'individuo la libertà e la responsabilità della scelta. È in questa prospettiva che la tecnologia trova la sua massima dignità: non nell'essere fine a sé stessa, ma nell'essere strumento di crescita, emancipazione e consapevolezza [8].

6.2 Riflessioni Finali

Al termine di questo percorso di ricerca e sviluppo, la riflessione conclusiva non può che vertere sulla natura stessa dell'orientamento. L'intero lavoro si è fondato sul tentativo di costruire un "ponte", come menzionato negli obiettivi, non solo tra l'universo quantitativo dei dati e la ricchezza qualitativa del vissuto individuale, ma tra la potenza computazionale dell'intelligenza artificiale e la fragile ma insostituibile autonomia della scelta umana. Al di là dell'architettura tecnica, l'ambizione più profonda è stata quella di rifiutare un modello tecnologico prescrittivo, che offre risposte definitive, per abbracciarne uno maieutico, che accompagna e stimola la riflessione.

Questo approccio risuona profondamente con il consiglio che il poeta Rainer Maria Rilke offriva a un giovane incerto sul proprio futuro, un'esortazione a valorizzare il processo di ricerca più della risposta stessa:

«Versuchen Sie, die Fragen selbst liebzuhaben... Und leben Sie vielleicht allmählich, ohne es zu merken, eines fernen Tages in die Antwort hinein.»¹⁶

(Cerchi di amare le domande stesse... E forse, così, a poco a poco, senza accorgersene, si troverà a vivere, un giorno lontano, fino a entrare nella risposta.)

Questa tesi e il prototipo *Career Compass AI* che ne è scaturito si collocano esattamente in questa prospettiva. Il sistema non è stato progettato per fornire "la" risposta, ma per aiutare l'utente ad "amare le domande" sul proprio futuro professionale, offrendo dati, scenari e connessioni che arricchiscano il processo interrogativo. La tecnologia, in questo senso, non agisce come un oracolo, ma come un compagno di esplorazione che illumina i possibili percorsi senza imporli. Il suo scopo ultimo non è fornire una certezza immediata, ma favorire quel lento e graduale "vivere fino a entrare nella risposta" di cui parla Rilke. Il vero successo di un tale strumento non risiederà, pertanto, nella precisione statistica dei suoi suggerimenti, ma nella sua capacità di aver promosso un atto di consapevolezza e di aver restituito all'individuo il ruolo di autentico protagonista del proprio divenire.

¹⁶ R. M. Rilke, *Lettere a un giovane poeta*, trad. it. di Leone Traverso, Adelphi, Milano, 1980

Strumenti utilizzati

1. Per la stesura della tesi è stato utilizzato il supporto di strumenti di Intelligenza Artificiale generativa, impiegati come ausilio alla stesura. Per lo sviluppo e l'esecuzione del prototipo è stata invece impiegata la chiave API di OpenAI, necessaria all'integrazione del modello linguistico all'interno del sistema progettato.
2. L'ambiente di sviluppo utilizzato è Visual Studio Code, scelto per la sua versatilità e per il supporto nativo a Python e alle estensioni dedicate al versionamento e al debugging.
3. per le attività di osservabilità, monitoraggio e valutazione del comportamento del sistema basato su LLM, è stato impiegato LangSmith, piattaforma che consente di tracciare le chiamate ai modelli, misurare le prestazioni e ottimizzare i prompt.
4. Per la creazione dei diagrammi architetturali presenti in questa tesi è stato utilizzato lo strumento online Mermaid Live Editor, disponibile su <https://mermaid.live/>.

Bibliografia

- [1] S. A. LEUNG, New Frontiers in Computer-Assisted Career Guidance Systems (CACGS): Implications From Career Construction Theory, in «Frontiers in Psychology», 2022.
- [2] V. DIGNUM, Responsible Artificial Intelligence: How to Develop and Use AI in a Responsible Way, Springer, 2019.
- [3] J. M. JÖRS, E. W. DE LUCA, Measuring the Experience of Eudaimonic Virtues in Technology Interaction: Development and Validation of the Eudaimonic Interaction Inventory (EII), in «Weizenbaum Journal of the Digital Society», 2025.
- [4] E. PURIFICATO, L. BORATTO, E. W. DE LUCA, Toward a Responsible Fairness Analysis: From Binary to Multiclass and Multigroup Assessment in

- GNN-Based User Modeling Tasks, in «Minds and Machines», 2024, p. 3.
[<https://github.com/erasmopurif/toward-responsible-fairness-analysis>].
- [5] S. RUSSELL, Human Compatible: Artificial Intelligence and the Problem of Control, Penguin, 2019.
- [6] B. SHNEIDERMAN, Human-Centered AI, Oxford University Press, 2022.
- [7] T. GEBRU, “Datasheets for Datasets” e altri contributi sul bias algoritmico, 2021.
- [8] A. BARAGONA, Career Compass AI, prototipo sviluppato per la presente tesi di tesi, 2025.
[https://github.com/Alessandro765/TESI_MAGISTRALE_BARAGONA].
- [9] INAPP – ISTITUTO NAZIONALE PER L’ANALISI DELLE POLITICHE PUBBLICHE, Classificazione e banche dati professionali.
[<https://api.inapp.org>].
- [10] ISTAT – ISTITUTO NAZIONALE DI STATISTICA, Classificazione delle professioni CP2021.
[<https://www.istat.it/classificazione/classificazione-delle-professioni/>].
- [11] ISTAT, Nomenclatura e classificazione delle Unità Professionali - Edizione 2021.
[<https://professioni.istat.it/sistemainformativoprofessioni/cp/index.php>].
- [12] Job recommender systems: a systematic literature review, applications, open issues, and challenges, in «Journal of Big Data», 2021.
- [13] Fairness in AI-Driven Recruitment: Challenges, Metrics, Methods, and Future Directions, in «ACM Computing Surveys», 2022.
- [14] J. BIMROSE, J. KETTUNEN, T. GODDARD, ICT – The New Frontier?, in «International Journal for Educational and Vocational Guidance», 2015.

- [15] A. GUGNANI, H. MISRA, Implicit Skills Extraction Using Document Embedding and Its Use in Job Recommendation, in AA.VV., AAAI Conference on Innovative Applications of Artificial Intelligence, 2020.
- [16] K. L. ABHISHEK et al., Developing an Intelligent Resume Screening Tool with AI-Driven Analysis and Recommendation Features, in «Applied AI Letters», 2025.
- [17] D. ÇELİK ERTUĞRUL, S. BITIRIM, Job Recommender Systems: Challenges and Future, in «Journal of Big Data», 2025.
- [18] F. P.-W. LO et al., AI Hiring with LLMs: A Context-Aware and Explainable Multi-Agent Framework for Resume Screening, arXiv preprint, 2025.
- [19] OPENAI, A practical guide to building agents, in «OpenAI Cookbook», GitHub Repository, 2024. [https://github.com/openai/openai-cookbook/blob/main/examples/assistants_api_overview.ipynb].
- [20] OPENAI, A Practical Guide to Building Agents, 2024. [<https://cdn.openai.com/business-guides-and-resources/a-practical-guide-to-building-agents.pdf>].
- [21] OPENAI, Multi-Agent Portfolio Collaboration with OpenAI Agents SDK Example, in «OpenAI Cookbook», GitHub Repository, 2024. [Multi-Agent Portfolio Collaboration with OpenAI Agents SDK].
- [22] T. BROWN et al., Language Models are Few-Shot Learners, in AA.VV., NeurIPS 34, 2020.
- [23] R. BOMMASANI et al., On the Opportunities and Risks of Foundation Models, Stanford CRFM Report, 2021.
- [24] OPENAI, GPT-4 Technical Report, arXiv preprint, 2023.
- [25] S. VATSAL, H. DUBEY, A Survey of Prompt Engineering Methods in Large Language Models for Different NLP Tasks, arXiv preprint, 2024.
- [26] J. WEI et al., Chain-of-Thought Prompting Elicits Reasoning in Large Language Models, arXiv preprint, 2022.

- [27] MICROSOFT, Prompt Engineering Techniques, Azure OpenAI Service Docs, 2023.
- [28] OPENAI, Best Practices for Prompting, Technical Documentation, 2023.
- [29] STREAMLIT, Streamlit Documentation. [<https://streamlit.io/>].
- [30] LANGCHAIN, LangSmith Documentation. [<https://docs.langchain.com/langsmith/home>].
- [31] UNIONE EUROPEA, Regolamento sull'Intelligenza Artificiale (AI Act). [Testo del regolamento sull'IA come sito web chiaro].
- [32] PYTHON SOFTWARE FOUNDATION, Python Language Reference. [<https://docs.python.org/3/>].

Ringraziamenti

Giunto al termine di questo percorso, desidero esprimere la mia sincera gratitudine a tutte le persone che, in modi diversi, hanno reso possibile la realizzazione di questa tesi.

Un ringraziamento speciale va al Professore Ernesto William De Luca, che mi ha accompagnato con competenza, disponibilità e stimolo costante lungo tutte le fasi del lavoro. La possibilità di poter collaborare ancora con lui in futuro rappresenta per me non solo un motivo di orgoglio, ma anche un'opportunità preziosa per approfondire e ampliare le prospettive aperte da questa ricerca.

Un pensiero riconoscente va alla mia famiglia e in particolare ai miei genitori, per il sostegno incondizionato e la vicinanza che non mi hanno mai fatto mancare. Alla mia ragazza, Crocca, devo invece un grazie affettuoso: per il supporto costante e per la pazienza con cui mi ha sopportato nei momenti più intensi di questo percorso.

Desidero ringraziare anche i miei colleghi in BIP, che hanno condiviso con me giornate di lavoro e di crescita. Un ringraziamento particolare va ai miei responsabili, in ordine cronologico, Daniele, Paolo e Leandro, che hanno sempre saputo venirmi incontro e mi hanno permesso di conciliare studio e lavoro, offrendo al tempo stesso la chiave d'accesso a esperienze e strumenti essenziali per la realizzazione del prototipo. Non posso dimenticare l'affetto e il sostegno dei colleghi più vicini in quest'ultimo anno, Diego e Raul, sempre al mio fianco con amicizia.

Un pensiero speciale va anche ai miei amici più intimi, il gruppo Steve, che porto sempre nel cuore, in particolare Giacomino, compagno d'arme, e agli amici dell'università, tra cui spicca il caro Antonio, grande compagno di avventure insieme ai ragazzi di Mr. Ibis. Infine, un pensiero va a quel che resta delle Brigate, con la speranza di ritrovarci presto ancora una volta insieme. A loro si unisce Michele, che mi ha dato un supporto fondamentale nella fase conclusiva di questo percorso. E non posso dimenticare il gruppo della pazienza, con cui è sempre un piacere farsi uno spritz.

A ciascuno di voi va la mia più profonda gratitudine: questa tesi è anche il frutto del vostro sostegno, della vostra fiducia e della vostra presenza.